

Report Sessione di Lavoro — 06 Giugno 2026

Progetto: Pipeline Agentica GraphRAG per Molecular Tumor Board
(Tesi Magistrale)

Sessione pomeridiana

1. Punto di Partenza

La sessione odierna e' la continuazione diretta della sessione del 05/06/2026. All'avvio si disponeva dei seguenti elementi:

- Pipeline v3 documentata (HTML) con OncoKB Enricher *human-in-the-loop*.
- KB Neo4j a 9 nodi e 11 relazioni, verificata sul caso pilota **BENCH-001**.
- Benchmark di 30 casi clinici con la colonna `alteration_type` aggiunta.
- Report completo sull'utilizzo delle API di OncoKB.
- Query Cypher verificate e consolidate solo per il tipo `point_mutation` (es. **BRAF V600E**).

Obiettivo della sessione: verificare in modo sistematico la fattibilita' delle query Cypher per tutti i tipi di `alteration_type` censiti nel benchmark prima di procedere con la fase di integrazione dell'LLM.

2. Verifica Coerenza Notebook

E' stata effettuata una revisione approfondita del notebook `esplorazione_kb_oncologico.ipynb` per verificarne l'allineamento con le specifiche di progettazione della pipeline v3.

2.1. Elementi Coerenti

- **Cella 11:** La query di sintesi degli archi (`edges_summary`) include correttamente le relazioni `HAS_DISEASE` e `CITED_IN`.
- **Cella 11:** La densita' del grafo e' calcolata correttamente tramite la formula corretta per grafi orientati: $E/(V \cdot (V - 1))$.
- **Cella 67:** E' presente la metodologia di audit strutturata su 3 strategie (*Standard*, *Fusion*, *Biomarker*).
- **Query Cypher:** Utilizzano coerentemente i parametri `hugo_symbol` e `variant_name` in tutti i passaggi chiave.

2.2. Incoerenze Corrette

1. **Cella 50 (Filtro Tumor-type):** Mancava il filtro per tipo di tumore nella query Cypher per le resistenze di **BRAF V600E**. Questo causava la sovrapposizione errata di dati relativi a Melanoma e CRC, violando il principio per cui la specificita' tumorale e' mandataria. *Risolto inserendo il filtro.*

2. **Conteggio Relazioni:** Il notebook contava 11 relazioni nel grafo, mentre la documentazione v2 faceva riferimento a 10. L'incoerenza e' stata allineata a 11 nella versione v3 della pipeline.

3. Ragionamento sull'Input della Pipeline

Dall'analisi del file CSV di benchmark e' emerso che la struttura di input originaria era troppo semplificata (limitata a gene, variante, tumore e linea terapeutica). Essa non permetteva di gestire in modo adeguato e strutturato casi complessi quali fusioni geniche, CNA, biomarker clinici e alterazioni atipiche.

3.1. Decisioni Strategiche Prese

- **Obbligatorietà di `alteration_type`:** Il tipo di alterazione deve essere passato come input obbligatorio, poiché non e' possibile inferirlo in modo deterministico e sicuro a partire dal solo nome della variante.
- **Uso della `category`:** La categoria del benchmark (es. *baseline*, *resistance*, *new_target*, *off_label*, *tumor_agnostic*) deve essere impiegata **solo** nella fase di valutazione per validare il routing atteso. Essa non sarà inserita come parametro di input per la pipeline in produzione per evitare fenomeni di *overfitting* sulla valutazione.
- **Complexity Check via LLM:** Il controllo di complessità viene mantenuto come chiamata LLM flessibile e non come una mappatura rigida deterministica (*category* → *tier*), per garantire una migliore generalizzabilità in ambiente di produzione.
- **Gestione del "Solid Tumor":** Per i casi tumor-agnostici (come **BENCH-016** NTRK1 o **BENCH-023** TMB-High) e' corretto impostare il tumore come "Solid Tumor", riflettendo la reale approvazione regolatoria FDA.
- **Classificazione di BENCH-024:** L'alterazione **EGFR Exon 19 Deletion** e' stata classificata come **atypical** e non come **cna**, trattandosi di una delezione *in-frame* a livello proteico e non di una variazione del numero di copie geniche.

3.2. Struttura Finale dell'Input

La tabella seguente illustra lo schema formale dei dati di input definiti per la pipeline v3:

* *Nota: Il campo `gene` può assumere valore `null` per biomarker generali non associati a un singolo gene (es. MSI-H, TMB-H).*

4. Benchmark Aggiornato

La colonna `alteration_type` e' stata popolata sistematicamente per tutti i 30 casi clinici del benchmark, portando alla distribuzione riassunta nella Tabella 2:

4.1. Casi Speciali e Regole di Gestione

- **BENCH-005 (BRCA1) e BENCH-008 (PIK3CA):** Presentano il valore `variant='Mutation'`. Questo termine "ombrello" viene tradotto su OncoKB come `alteration=Mutation` per estrarre tutte le evidenze cliniche associate.

Tabella 1: Schema formale dei campi di input della pipeline v3

Campo	Tipo	Valori Ammessi	Obbligatorio
gene	string	HUGO symbol (<i>null</i> per biomarker)	Si*
variant	string	Cambio proteico, Fusion, MSI-High, ecc.	Si
tumor_type	string	Nome del tumore o codice OncoTree	Si
alteration_type	enum	point_mutation fusion cna itd atypical biomarker	Si
therapy_line	string	first-line second-line later-line	No
enrich_with_oncokb	boolean	true false (default false)	No

Tabella 2: Distribuzione dei casi clinici del benchmark

Alteration Type	Casi	Identificativi casi benchmark
point_mutation	14	BENCH-001, 003, 005, 007, 008, 011, 012, 013, 014, 018, 020, 022, 025, 029
fusion	6	BENCH-002, 006, 015, 016, 026, 028
atypical	4	BENCH-009, 019, 024, 027
cna	3	BENCH-004, 021, 030
biomarker	2	BENCH-017, 023
itd	1	BENCH-010

- **BENCH-006 (BCR::ABL1):** La query deve ricercare entrambi i partner genici (“BCR” e “ABL1”) all’interno del nome del profilo molecolare (`MolecularProfile.name`).
- **BENCH-016 (NTRK1/Solid Tumor) e BENCH-023 (TMB/Solid Tumor):** Casi tumor-agnostici, gestiti senza costringere a un’associazione con un organo o tessuto specifico.

5. Verifica Query Cypher per tutti i Tipi di Alteration Type

Sono state eseguite oltre 15 query Neo4j per verificare la fattibilit  del modulo *Variant Interpreter* su tutti e 6 i tipi di alterazione identificati.

5.1. Point Mutation (14 casi)

- **Percorso nel Grafo:** `Gene(hugo_symbol) → Variant(variant_name) → MP → Evidence → CITED_IN → Publication`
- **Stato:** **Verificato** (sessione precedente)

5.2. Fusion (6 casi)

Le fusioni non seguono il percorso classico. Vengono cercate direttamente tramite il nome del profilo molecolare (`MolecularProfile.name`).

- **Notazioni nel KB:**

- `v::ALK Fusion` (gene driver a destra, partner variabile)
- `FGFR2::v Fusion` (gene driver a sinistra, partner variabile)
- `BCR::ABL1 Fusion` (entrambi i partner specificati)

- **Risultati per caso:**

- `BENCH-002 ALK` → `v::ALK Fusion` (26 evidenze A/B) **Verificato**
- `BENCH-006 BCR` → `BCR::ABL1 Fusion` (4 evidenze A/B) **Verificato**
- `BENCH-015 RET` → `v::RET Fusion` (9 evidenze A/B) **Verificato**
- `BENCH-016 NTRK1` → `v::NTRK1 Fusion` (4 evidenze A/B) **Verificato**
- `BENCH-026 FGFR2` → `FGFR2::v Fusion` (5 evidenze A/B) **Verificato**
- `BENCH-028 ROS1` → `v::ROS1 Fusion` (6 evidenze A/B) **Verificato**

- **Profili composti individuati:** Es. `BCR::ABL1 Fusion AND ABL1 T315I, v::ALK Fusion OR v::ROS1 Fusion` (richiedono una gestione della priorit  sul profilo semplice).

5.3. Atypical (4 casi)

Seguono la stessa logica di ricerca delle fusioni sul nome del `MolecularProfile`.

- `BENCH-009 KIT Exon 11` e `BENCH-019 KIT Exon 9` → **Verificati** in questa sessione (dettagli sotto).
- `BENCH-024 EGFR Exon 19` → `EGFR Exon 19 Deletion` (12 evidenze A/B) **Verificato**
- `BENCH-027 MET Exon 14` → `MET Exon 14 Skipping` (3 evidenze A/B) **Verificato**
- *Nota:* `MET Exon 14` ha copertura molto limitata nel KB locale (1A + 2B); l'arricchimento via OncoKB sara' probabilmente necessario.

5.4. CNA (3 casi)

- **Logica di ricerca:** `MolecularProfile.name` contiene il simbolo del gene ed i termini 'amplif' o 'deletion'.
- `BENCH-004 ERBB2 Amplification` → `ERBB2 Amplification` (5 evidenze A/B) **Verificato**
- `BENCH-021` e `BENCH-030` → **Verificati** (dettagli sotto).

5.5. ITD (1 caso)

- `BENCH-010 FLT3 ITD` → `FLT3 ITD` (20 evidenze B + 1 A per AML, 2 B per APL) **Verificato**
- **Profilo composto trovato:** `FLT3 ITD OR FLT3 D835 OR FLT3 I836`

5.6. Biomarker (2 casi)

- **Nomi nel KB locale:** "TMB High" (non TMB-H) e "MSI High" (non MSI-H). E' necessario un mapping per le query esterne.
- **BENCH-017** MSI-High → MSI High (2 evidenze A in CRC) **Verificato**
- **BENCH-023** TMB-High → TMB High (9 evidenze B in NSCLC, 2 B in CRC, 1 B in Solid Tumor) **Verificato**
- *Nota:* MSI High ha copertura molto limitata locale (2 evidenze A solo CRC). L'arricchimento tramite OncoKB sara' fondamentale.

6. Implicazioni Architettureali

Insight Metodologici Emersi

Dalla fase di validazione delle query sono emerse tre implicazioni critiche per l'implementazione del modulo *Variant Interpreter*:

1. Branching logico obbligatorio per `alteration_type`:

Il Variant Interpreter non puo' avvalersi di una query Cypher unica. Sono necessarie due logiche separate:

- *Point Mutation:* percorso classico `Gene` → `Variant` → MP → Evidence.
- *Altri tipi:* ricerca diretta basata su stringhe tramite operatori `CONTAINS` su `MolecularProfile.name`.

In LangGraph cio' sara' implementato tramite un conditional edge dopo il complexity check, oppure tramite costrutti *if/else* interni a un singolo nodo.

2. Priorita' dei profili semplici rispetto a quelli composti:

Nel database orientato a grafi sono presenti profili composti (es. "BCR::ABL1 Fusion AND ABL1 T315I"). La query deve privilegiare il match esatto sul profilo semplice (*exact match*), mantenendo i profili composti come evidenze secondarie (es. ordinando i risultati tramite `ORDER BY size(mp.name) ASC`).

3. Dizionario di Mapping KB ↔ OncoKB API:

I nomi dei biomarker clinici differiscono tra il database locale (CIViC) e le API esterne di OncoKB:

- Database locale: "TMB High" e "MSI High"
- API OncoKB: "TMB-H" e "MSI-H"

E' necessario definire un dizionario di conversione esplicito nel codice per interrogare correttamente le API.

7. Stato Finale della Verifica delle Query

Tutti i 30 casi clinici del benchmark (100%) sono stati analizzati ed e' stata verificata la loro fattibilita' all'interno della base di conoscenza locale Neo4j.

7.1. Dettaglio delle Query Completate in Questa Sessione

- **BENCH-009 (KIT Exon 11 / GIST):** KIT Exon 11 Mutation trova 9 evidenze B e 1 evidenza A per GIST, piu' evidenze secondarie per Melanoma e Polmone. **Verificato**.

Tabella 3: Matrice di copertura del Grafo Neo4j per classe di alterazione

Alteration Type	Casi	Stato KB	Evidenze Trovate	Percorso di Query
point_mutation	14	Completo	Livelli A/B	Gene → Variant → MP → Evidence
fusion	6	Completo	Livelli A/B	MolecularProfile.name CONTAINS gene
atypical	4	Completo	Livelli A/B	MolecularProfile.name CONTAINS 'exon X'
cna	3	Completo	Livelli A/B	BENCH-030 e' un GAP
itd	1	Completo	23 evidenze tot.	FLT3 ITD su AML e APL
biomarker	2	Completo	Livelli A/B	TMB High / MSI High (esatti)

- **BENCH-019 (KIT Exon 9 / GIST):** KIT Exon 9 Mutation trova 6 evidenze B e 1 evidenza A per GIST. **Verificato**.
- **BENCH-021 (ERBB2 Amplificazione / Tumore Gastrico / Trastuzumab):** Trova 2 evidenze B e 1 evidenza A per Gastric Adenocarcinoma. **Verificato**.
- **BENCH-030 (ERBB2 Amplificazione / Tumore Gastrico / Trastuzumab Derux-
tecán):** Il farmaco e' presente nel KB. Tuttavia, non sono presenti evidenze cliniche sul
tumore gastrico (presenti solo sul polmone non a piccole cellule, NSCLC, livello A). Questo
rappresenta un **gap di copertura del grafo (GAP)**, giustificato dal fatto che il farmaco
e' di recente approvazione e il database open-source CIViC non e' ancora aggiornato.
Questo caso richiedera' l'attivazione obbligatoria dell'OncoKB Enricher per evitare falsi
negativi.

7.2. Gap di Copertura Identificati e Annotati

- **BENCH-030:** ERBB2 Amp / Gastric / Trastuzumab deruxtecán → kb_coverage=GAP (richiede OncoKB).
- **BENCH-027:** MET Exon 14 / NSCLC / Capmatinib → Copertura limitata nel KB locale (solo 3 evidenze).
- **BENCH-017:** MSI High / CRC / Pembrolizumab → Copertura limitata nel KB locale (solo 2 evidenze).

8. Conclusione — LLM Readiness

Risultato Chiave

La verifica sistematica ha confermato che la base di conoscenza e la struttura logica del sistema sono **pronte al 100%** per l'integrazione con l'agente LLM. Tutti i 30 casi sono stati mappati con successo, i gap del database locale sono stati identificati e circoscritti, e le regole di branching del Variant Interpreter sono state completamente formalizzate.

9. Documenti Prodotti nella Sessione

Tabella 4: Documenti generati durante la sessione di lavoro

Nome File	Descrizione
pipeline_mtb_v3.html	Descrizione della pipeline v3 con input strutturato e gestione delle alterazioni.
benchmark_papers_summary_30_v2.csv	Database benchmark di 30 casi clinici aggiornato con i tipi di alterazione.
report_oncokb_api.md	Report tecnico di integrazione delle API OncoKB.
report_sessione_06062026.txt	Riepilogo testuale grezzo della sessione di lavoro (punto di partenza di questo report).

10. Agenda Sessione Successiva

10.1. Priorita' Urgenti (Prerequisiti di Sviluppo)

- **Scelta del modello LLM:** Selezione dell'LLM (candidati: *Claude 3.5 Sonnet*, *GPT-4o*, *Gemini 1.5 Pro*) in base a costi (30 casi con molteplici metriche), supporto nativo per output strutturato (JSON schema) e ampiezza della context window.
- **Test Pilota:** Esecuzione del primo test end-to-end sul caso pilota **BENCH-001** (BRAF V600E / Melanoma) tramite lo script Python esistente.

10.2. Attivita' Importanti (Completamento Pipeline)

- **Aggiornamento codice (pipeline_mtb_v2.py → v3):**
 - Implementazione del branching logico per `alteration_type` nel Variant Interpreter.
 - Inserimento del dizionario di mapping locale-OncoKB per i biomarker.
 - Aggiunta del campo `alteration_type` all'interno dello Stato di LangGraph.
 - Integrazione del nodo OncoKB Enricher per sopperire ai gap.
- **Aggiornamento CSV:** Marcatura esplicita di `kb_coverage=GAP` per il caso **BENCH-030**.
- **Raffinamento query KIT Exon 11/9:** Introduzione di filtri piu' restrittivi per evitare la sovrapposizione con Melanoma e Polmone nei casi GIST.

10.3. Attività a Medio Termine (Completamento Tesi)

- Sviluppo dell'interfaccia utente web con Streamlit.
- Esecuzione della valutazione sistematica sui 30 casi clinici (Evidence Grounding, Drug Anchor Check e LLM-as-a-judge).
- Aggiornamento del diagramma di architettura della pipeline (`diagramma_pipeline_v2.md` → `v3`).