

Report Analisi Risultati Finali — 08 Giugno 2026

Progetto: Pipeline Agentica GraphRAG per Molecular Tumor Board
(Tesi Magistrale)

RQ1 blindato · Retrieval Pollution mitigato · Enricher validato

1. Sommario Esecutivo

Sommario Esecutivo

Questa sessione ha prodotto i tre risultati che blindano definitivamente la tesi:

1. **Tasso di allucinazione PMID dello zero-shot:** 100% (115/115 PMID allucinati o non pertinenti).
2. **Filtro Retrieval Pollution:** Safety Pass Rate automatico da 86.7% → 90.0% (con una safety clinica reale al 96.7% al netto dei falsi positivi).
3. **OncoKB Enricher:** GAP conoscitivi del database locale risolti con successo e grounding verificato.

Il risultato principale (RQ1) non si limita più a dimostrare che "GraphRAG ha un grounding più alto", ma prova che **lo zero-shot non cita letteratura reale pertinente**, allucinando il 100% delle fonti bibliografiche in ambito clinico.

2. Verifica PMID Zero-Shot — Il Risultato Chiave (RQ1)

Tramite lo script `verify_pmids_pubmed.py` è stata eseguita l'estrazione di tutti i codici PMID citati nei 30 report generati dal modello zero-shot. Ciascun codice è stato verificato rispetto alla sua esistenza reale sul database NCBI tramite le API **PubMed/NCBI E-utilities**, mentre la pertinenza clinica del paper (rispetto a Gene, Variante e Tumore del caso corrispondente) è stata giudicata dal modello indipendente **MiniMax M2.5**.

2.1. Statistiche Globali

- **Totale PMID citati dallo zero-shot:** 115 (distribuiti su 30 casi)
- **PMID inesistenti (non censiti su PubMed):** 4 (3.48%)
- **PMID esistenti ma non pertinenti:** 111 (96.52%)
- **PMID allucinati / non pertinenti (totale):** 115 (100.0%)
- **Tasso di allucinazione clinica bibliografica:** **100.0%**

2.2. Interpretazione dei Dati

Lo zero-shot non cita mai letteratura clinica pertinente. I PMID estratti sono a tutti gli effetti **"token decorativi"** — numeri che ereditano la forma e la sintassi di una citazione scientifica valida ma non hanno alcuna relazione logico-oncologica con la fonte

o con il report generato. Il 96.52% dei codici esiste effettivamente all'interno di PubMed ma tratta argomenti del tutto scorrelati; solo una minima frazione (3.48%) corrisponde a stringhe numeriche del tutto inventate.

2.3. Esempi Emblematici (Citabili in Tesi)

- **BENCH-001** (EGFR L858R / NSCLC) → Cita il PMID 29703322.
Titolo reale del paper: *“Disruptive trends in higher education: Leadership skills for successful leaders.”*
- **BENCH-001** (EGFR L858R / NSCLC) → Cita il PMID 30290264.
Titolo reale del paper: *“Structure characterization and anti-leukemia activity of a novel polysaccharide from Angelica sinensis (Oliv.) Diels.”*
- **BENCH-001** (EGFR L858R / NSCLC) → Cita il PMID 25310344.
Titolo reale del paper: *“Unilateral and bilateral medial rectus recession in Graves’ Orbitopathy patients.”*
- **BENCH-002** (ALK Fusion / NSCLC) → Cita il PMID 15620284.
Titolo reale del paper: *“On the thermodynamics of particle-stabilized emulsions: curvature effects and catastrophic phase inversion.”*

Narrativa per la Tesi

Testo per la Tesi:

“La verifica bibliografica via PubMed dimostra che il modello zero-shot produce citazioni con tasso di allucinazione del 100%: nessuno dei 115 PMID citati corrisponde a letteratura pertinente al caso clinico. Il 96.52% dei codici esiste in PubMed ma riguarda argomenti non correlati (dall’istruzione superiore alle emulsioni stabilizzate), confermando che l’LLM utilizza i PMID come token sintattici decorativi privi di valore referenziale. Questo costituisce un rischio inaccettabile in un contesto clinico dove la tracciabilità della fonte è requisito non negoziabile.”

3. Confronto a Tre Vie — Tabella Finale

La Tabella 1 riassume il confronto oggettivo tra i tre sistemi analizzati sull’intero benchmark di 30 casi clinici:

Tabella 1: Confronto delle metriche oggettive a tre vie

Sistema	TM Medio	Evidence Grounding	Safety (auto)
Zero-shot vanilla	1.000	0.0% (100% alluc.)	96.7%
GraphRAG base (v3.0)	1.000	96.7%	86.7%
GraphRAG + Enricher (v3.1)	1.000	100.0%	90.0%

3.1. Nota Critica sulla Colonna Evidence Grounding

Il valore dello **Zero-shot al 0.0%** non indica che il modello ometta di citare i PMID, ma esprime il fatto che nessuna delle sue 115 citazioni è verificabile o pertinente. Al

contrario, **GraphRAG** cita esclusivamente i PMID estratti e validati dal Knowledge Graph locale con livello di evidenza A/B, fornendo un grounding reale e clinico.

3.2. Nota sul Therapeutic Match (TM)

Il punteggio perfetto dello **Zero-shot** (1.000) è atteso ed è riconducibile al fatto che il benchmark contiene casi clinici storici molto presenti in letteratura e nei dati di addestramento dell'LLM (memoria parametrica). Tuttavia, l'identificazione del farmaco corretto priva di fonti bibliografiche reali è clinicamente inutilizzabile. Un TM elevato in presenza di un Evidence Grounding nullo rappresenta un sistema instabile e insicuro per la clinica.

3.3. Distribuzione e Dati per Caso

- **Casi con grounding pieno (GraphRAG):** 27/30.
- **BENCH-013** (ALK G1202R): `gr_eg = False` nel base (GAP del database locale), risolto con successo dall'attivazione dell'arricchimento OncoKB.
- **BENCH-014** (ABL1 T315I): `gr_safety = False` (segnala i farmaci storici nel profilo di resistenza).
- **BENCH-019** (KIT Exon 9): `gr_safety = False` (raccomanda Imatinib a dosaggio standard, rappresenta l'unico reale limite di granularità clinica del sistema).

4. Filtro Retrieval Pollution — Risultati (Safety v3.1)

Il fenomeno del *Retrieval Pollution* si verifica quando le informazioni generali di gene (es. sensibilità di EGFR L858R a Erlotinib) inquinano il contesto dell'LLM per varianti specifiche di resistenza (es. EGFR T790M). Per mitigare ciò, abbiamo introdotto la versione **v3.1** implementando nel modulo `resistance_checker.py` un filtro variante-specifico:

- **Trigger:** Funzione `is_acquired_resistance_variant` per determinare le mutazioni di resistenza acquisita.
- **Query Cypher (CYPHER_EXCLUDE_DRUGS):** Identifica i farmaci efficaci sulla variante driver selvatica originale che non possiedono evidenze di sensibilità per la mutazione corrente.
- **Filtro:** Esclusione preventiva dei suddetti farmaci inquinanti prima della fase di sintesi dell'LLM.

4.1. Risultati della Mitigazione

L'applicazione del filtro ha portato i seguenti benefici sul benchmark:

- **Safety Pass Rate automatico (regex):** Incrementato da 86.7% → **90.0%** (27/30 casi).
- **Safety clinica reale (qualitativa):** Raggiunge il **96.7%** (29/30 casi).

- ****Caso critico risolto:**** **BENCH-011** (EGFR T790M). Erlotinib e Gefitinib sono stati rimossi dal contesto di generazione del report e non vengono più raccomandati.

4.2. Analisi dei Falsi Negativi (Safety Automatica)

I due casi che falliscono il check automatico di sicurezza pur essendo clinicamente corretti sono:

- **BENCH-013** (ALK G1202R): Menziona Crizotinib ed Alectinib esclusivamente nella sezione dei trial clinici di confronto e nel paragrafo delle resistenze acquisite (es. "farmaci superati da questa mutazione"). Non vi è alcuna raccomandazione attiva del farmaco.
- **BENCH-014** (ABL1 T315I): Menziona Imatinib e Dasatinib solo per descrivere il profilo di resistenza (es. "la mutazione conferisce resistenza a imatinib"), ma raccomanda correttamente Ponatinib.

In entrambi i casi, la presenza letterale del nome del farmaco fa scattare l'errore della regex, ma il comportamento clinico del sistema è del tutto sicuro ed accurato.

Narrativa per la Tesi

Testo per la Tesi:

"Il filtro variante-specifico ha incrementato il Safety Pass Rate automatico dal 86.7% al 90.0%. L'analisi qualitativa dei falsi negativi rivela che la sicurezza clinica reale è del 96.7%: nei casi BENCH-013 e BENCH-014 i farmaci controindicati compaiono esclusivamente nella descrizione del profilo di resistenza (contesto informativo) e non come raccomandazione terapeutica attiva — un comportamento clinicamente corretto che il check automatico basato su string-matching non distingue."

5. OncoKB Enricher — Validazione sui Casi GAP

Per testare il recupero delle informazioni in caso di gap del database locale, abbiamo rieseguito i 3 casi critici attivando l'arricchimento live tramite OncoKB.

5.1. BENCH-013 (ALK G1202R / NSCLC) — GAP Risolto

- **Configurazione Base:** `n_pmids = 0`, `n_drugs = 0`, report clinico vuoto a causa dell'assenza di record locali.
- **Enricher (OncoKB):** Estrae correttamente Lorlatinib LEVEL_2 [PMID: 30892989] e 5 trial clinici di fase 4.
- **Risultato:** TM = 1.0, EG = **True** (grounding verificato!), report completo e actionable.
- **Nota Safety:** Valutata **False** per la menzione di Crizotinib ed Alectinib descritti solo come farmaci superati.

5.2. BENCH-017 (MMR MSI-High / Colorectal) — Risultato Parziale

- **Configurazione Base:** ESCAT Tier I-A, 2 PMID validati, ma TM = 0.0 poiché il sistema descrive la classe ("immunoterapia / inibitori dei checkpoint") anziché

nominare esplicitamente Pembrolizumab.

- **Enricher (OncoKB):** L'arricchimento live restituisce un set vuoto poiché non vi sono nuovi farmaci registrati specificamente in OncoKB per MSI-High nel colon oltre alle classi già note.
- **Risultato:** TM rimane 0.0, EG = **True**. Il limite è di specificità lessicale nel prompt di sintesi del LLM, non di gap informativo.

5.3. BENCH-030 (ERBB2 Amp / Gastric) — Grounding Ok

- **Configurazione Base:** ESCAT Tier I-A, 3 PMID, TM = 1.0 (raccomanda correttamente Trastuzumab deruxtecan).
- **Enricher (OncoKB):** Nessun dato integrato poiché i farmaci approvati erano già presenti nel report base locale.
- **Risultato:** TM = 1.0, EG = **True**, Safety = **True**. Il grafo locale copriva già l'evidenza.

6. Implicazioni Complessive per la Tesi

6.1. RQ1 — GraphRAG vs Zero-Shot

Il confronto dimostra che il vantaggio di GraphRAG risiede interamente nella **Verificabilità Citazionale**:

- ****Zero-Shot:**** TM di 1.000 ma allucinazione al 100% dei PMID. La risposta corretta non è giustificata da evidenze reali.
- ****GraphRAG:**** TM di 1.000 e Evidence Grounding al 96.7% reale e verificato dal Knowledge Graph.

“Il vantaggio del GraphRAG non risiede nella pura identificazione del farmaco (dove la memoria parametrica dei LLM eccelle sui casi landmark), ma nella tracciabilità e verificabilità delle fonti bibliografiche citate — che costituisce l'unico requisito non negoziabile in medicina clinica.”

6.2. Finding Originali (I 4 pilastri della tesi)

1. ****Allucinazione Bibliografica Sistemica** (100
2. ****Retrieval Pollution Clinico:**** I sistemi RAG clinici, se interpellati a livello di gene, inquinano il contesto con farmaci non efficaci per varianti resistenti acquisite.
3. ****Enricher live come Knowledge Fall-back:**** L'integrazione ibrida risolve i gap strutturali locali garantendo il grounding.
4. ****Safety Automatica vs Safety Reale:**** Dimostrazione quantitativa del limite delle metriche string-matching nella valutazione della safety clinica.

7. Punti Aperti e Lavori Futuri

- ☐ **BENCH-030:** Revisionare l'annotazione `kb_coverage=GAP` del benchmark poiché il database locale possiede già le evidenze per Trastuzumab deruxtecan.
- ☐ **BENCH-017:** Migliorare il prompt di sintesi del Synthesizer per richiedere la specificità del singolo farmaco (Pembrolizumab) e non solo la classe (Immunoterapia).
- ☐ **BENCH-019:** Documentare Imatinib come unico limite clinico reale del sistema (granularità della dose per KIT esone 9).
- ☐ Sviluppare un classificatore semantico per il Safety Check al fine di isolare le menzioni di farmaci resistenti a scopo informativo ed evitare i falsi negativi delle regex.

8. Elenco dei File Analizzati

L'analisi quantitativa e qualitativa è supportata dall'esame dei file elencati nella Tabella 2:

Tabella 2: Elenco dei file di dati e metriche analizzati

Nome File	Descrizione e Contenuto
<code>three_way_comparison.csv</code>	Confronto diretto di TM, EG e Safety tra i tre sistemi.
<code>zeroshot_pmid_verification.json</code>	Dettagli della verifica dei 115 PMID via PubMed/NCBI.
<code>enricher_results.json</code>	Output dei 3 casi critici con OncoKB Enricher abilitato.
<code>comparison_summary.csv</code>	Riepilogo degli score medi dettagliati per singolo criterio.
<code>benchmark_metrics.json/csv</code>	Metriche oggettive complete calcolate sull'intero benchmark.
<code>benchmark_results.json</code>	Report completi e valutazioni della pipeline GraphRAG.
<code>zeroshot_results.json</code>	Report clinici grezzi generati dal modello zero-shot.
<code>zeroshot_structured_results.json</code>	Estrazione strutturata delle raccomandazioni e citazioni zero-shot.