

Riflessioni sui Paper di Riferimento

Sistema GraphRAG Agentico per Molecular Tumor Board

Nota Metodologica

Le riflessioni seguenti collocano ogni paper nel contesto specifico della tesi, evidenziando i contributi rilevanti e le implicazioni operative. Le citazioni testuali sono indicate tra virgolette con riferimento autore/anno; tutto il resto è parafrasi o analisi originale.

1 From Local to Global: A GraphRAG Approach to Query-Focused Summarization

Edge et al., Microsoft Research, arXiv:2404.16130v2, 2025

1.1 Contributo principale e rilevanza per la tesi

Il paper introduce GraphRAG come soluzione al limite fondamentale del RAG vettoriale classico: l'incapacità di rispondere a query che richiedono una comprensione globale dell'intero corpus invece che il recupero di frammenti locali. Gli autori definiscono queste query "sensemaking queries" e osservano che i sistemi RAG convenzionali non le supportano.

Citazione di riferimento (Edge et al., 2025, Introduction)

"vector RAG approaches do not support sensemaking queries, meaning queries that require global understanding of the entire dataset"

Questa distinzione è direttamente applicabile al contesto MTB: quando un oncologo chiede "quali sono tutte le resistenze note associate a questo profilo molecolare?" o "esistono trial clinici attivi che includono questo gene con questa variante in questo istotipo?", sta formulando una *sensemaking query* sul corpus delle evidenze oncologiche — non una ricerca puntuale di un fatto singolo. Il RAG vettoriale classico recupera i frammenti più simili alla query ma non sintetizza la visione d'insieme. Il Knowledge Graph strutturato, invece, permette esattamente questo tipo di navigazione relazionale globale.

1.2 Validazione scientifica di LLM-as-judge

Il contributo metodologico più rilevante per la tesi non è tecnico ma valutativo: Edge et al. sviluppano e applicano sistematicamente l'approccio LLM-as-judge per confrontare sistemi RAG su domande di sensemaking globale, dove non esiste una risposta gold-standard verificabile. Lo applicano su tre criteri — *Comprehensiveness* (completezza), *Diversity* (varietà delle prospettive), *Empowerment* (capacità di supportare giudizi informati) — e validano i risultati con misure quantitative basate sull'estrazione di claim fattuali dagli output.

Questa è la risposta diretta allo scetticismo del relatore sull'LLM-as-judge: non è un approccio "soft" proposto nella tesi per comodità, ma la metodologia di valutazione adottata da Microsoft Research in un paper che sta diventando uno standard di riferimento per i sistemi GraphRAG. Citarlo esplicitamente in tesi, con i criteri specifici e il processo di validazione claim-based, lo rende difendibile in sede di discussione.

1.3 Implicazione architetturale

L’approccio map-reduce di GraphRAG — che genera risposte parziali da ogni community summary e le aggrega in una risposta globale — è concettualmente coerente con la pipeline multi-agente della tesi. Il *Variant Interpreter*, l’*Evidence Synthesizer* e il *Trial Matcher* corrispondono a fasi distinte di questo processo: recupero locale delle evidenze specifiche per profilo (map), sintesi globale con contesto di resistenze e trial (reduce).

2 Medical Graph RAG: Towards Safe Medical Large Language Model via Graph Retrieval-Augmented Generation

Wu et al., University of Oxford / CMU / University of Edinburgh, arXiv:2408.04187v2, 2024

2.1 Contributo principale e vicinanza all’architettura della tesi

MedGraphRAG è il paper più vicino per dominio e architettura al sistema sviluppato in questa tesi. Introduce due contributi tecnici — *Triple Graph Construction* e *U-Retrieval* — che trovano un corrispondente diretto nella KB oncologica già costruita.

La *Triple Graph Construction* crea strutture tripartite che collegano i dati utente a fonti scientifiche credibili e a vocabolari medici controllati. Nel grafo della tesi questa struttura esiste già: il percorso **MolecularProfile** → **Evidence** → **Publication** con PMID realizza esattamente il collegamento [*dato clinico* → *evidenza* → *fonte primaria*] che MedGraphRAG propone come contributo innovativo. La differenza è che nel grafo della tesi questa struttura è pre-costruita da fonti curate (CIViC, OncoKB) invece di essere estratta on-the-fly da un LLM — il che la rende più affidabile in un contesto clinico ad alto rischio.

Citazione di riferimento (Wu et al., 2024, Abstract)

“MedGraphRAG consistently outperforms state-of-the-art models across all benchmarks, while also ensuring that responses include credible source documentation and definitions”

2.2 Metriche di valutazione: citation precision/recall e il loro limite

La valutazione umana di MedGraphRAG introduce cinque dimensioni misurate da un panel di sette clinici certificati e cinque non esperti: pertinenza, correttezza, *citation precision* (CP), *citation recall* (CR) e comprensibilità. CP e CR misurano rispettivamente quante fonti citate dal sistema sono corrette e quante fonti rilevanti il sistema ha incluso.

Queste metriche sono robuste e presenti in letteratura, ma applicarle direttamente alla tesi richiede una precisazione critica: la *citation recall* presuppone di conoscere a priori l’insieme completo delle fonti rilevanti per ogni caso. MedGraphRAG ha potuto costruire questo insieme perché ha coinvolto sette clinici certificati nella valutazione di 1015 coppie paziente-criterio — uno sforzo di curazione manuale fuori scala per una tesi magistrale.

Il benchmark dei 30 casi contiene un PMID per caso, che rappresenta il paper fondante della raccomandazione clinica (es. FLAURA per BENCH-001, studio BRIM-3 per BENCH-003). Questo PMID è l’ancora della ground-truth, non l’insieme esaustivo delle fonti rilevanti. Usarlo per calcolare *citation recall* produrrebbe una misura conservativa (*lower bound*) ma non informativa sulla completezza del ragionamento del sistema.

2.3 Evidence Grounding: la metrica originale della tesi

Il limite della *citation recall* tradizionale diventa un vantaggio quando si riconosce che la tesi dispone di qualcosa che MedGraphRAG non ha: un Knowledge Graph pre-costruito con evidenze

verificate e integrità referenziale certificata. Questo permette di definire una metrica originale e più informativa: l'Evidence Grounding.

Definizione operativa

Per ogni caso benchmark, l'Evidence Grounding misura la proporzione di evidenze clinicamente rilevanti presenti nel grafo per quel profilo molecolare (gene + variante + tumore) che il sistema ha effettivamente recuperato e incluso nell'output.

Esempio concreto su BENCH-001 (EGFR L858R / NSCLC)

Il grafo contiene — ipotizziamo — 8 evidenze Predictive/Sensitivity per questo profilo: Osimertinib (A), Erlotinib (A), Gefitinib (A), Afatinib (B), Dacomitinib (B), Erlotinib (B, Breast Cancer), Neratinib (C), Lapatinib (D).

- Se il sistema cita Osimertinib (A), Erlotinib (A), Gefitinib (A) e Afatinib (B), l'Evidence Grounding grezzo è $4/8 = 50\%$.
- Se si restringe la misura alle sole evidenze ad alto rigore (livelli A e B per il tumore corretto), il sistema ha recuperato 4 su 5 = 80%.

Questa metrica è calcolabile automaticamente perché:

- Il grafo sa esattamente quante e quali evidenze esistono per ogni profilo (query Cypher deterministica).
- L'output del sistema elenca le evidenze citate in formato strutturato.
- Il confronto è un semplice *set intersection*, non richiede giudizio umano.

Perché è superiore alla citation recall di MedGraphRAG nel contesto della tesi

- **Non richiede curazione manuale** dell'insieme delle fonti rilevanti.
- **Misura qualcosa di clinicamente significativo:** quanto bene il sistema sfrutta la KB che è stata costruita.
- **È specifica per l'architettura a grafo:** un sistema RAG testuale non potrebbe calcolarla perché non ha un insieme chiuso di evidenze verificate.
- **Può essere raffinata** per livello di evidenza (solo A/B vs tutti i livelli) e per pertinenza tumorale (solo NSCLC vs tutti i tumori).

2.4 Punto di differenziazione architetturale

Wu et al. costruiscono il grafo in tempo reale dall'estrazione di entità da documenti grezzi tramite LLM, con tutti gli errori di estrazione che questo comporta. La tesi adotta un approccio opposto: separazione netta tra costruzione offline della KB (curata, multi-fonte, con integrità referenziale verificata) e interrogazione agentica runtime. Questa separazione è più appropriata in oncologia di precisione, dove un errore di relazione nel grafo — ad esempio classificare una resistenza come sensibilità — ha implicazioni cliniche dirette. Ed è proprio questa separazione che abilita l'Evidence Grounding come metrica: il grafo pre-costruito è il metro di misura, non il prodotto del sistema che si sta valutando.

3 MDAgents: An Adaptive Collaboration of LLMs for Medical Decision-Making

Kim et al., MIT / Google Research / Seoul National University, NeurIPS 2024

3.1 Contributo principale: orchestrazione adattiva basata su complessità

MDAgents risponde direttamente alla domanda del relatore sull'alternativa al MoE Router: una pipeline di orchestrazione agentica che assegna dinamicamente la struttura di collaborazione in base alla complessità del caso clinico.

Il framework opera in quattro stadi:

1. **Medical Complexity Check:** un agente moderatore classifica la query come Low, Moderate o High complexity;
2. **Expert Recruitment:** in base alla complessità, attiva un singolo agente PCP, un *Multi-disciplinary Team* (MDT) con discussione iterativa, o un *Integrated Care Team* (ICT) con team sequenziali;
3. **Analysis and Synthesis:** esecuzione della pipeline appropriata;
4. **Final Decision:** il moderatore sintetizza il risultato.

Citazione di riferimento (Kim et al., 2024, Abstract)

“MDAgents achieved the best performance in seven out of ten benchmarks on tasks requiring an understanding of medical knowledge”

3.2 Applicazione al contesto MTB della tesi

La mappatura sull'architettura della tesi è diretta:

Low complexity → **agente singolo:** corrisponde ai casi baseline Tier I-A con variante attinente classica e standard di cura noto (BENCH-001, EGFR L858R). Il *Variant Interpreter* e l'*Evidence Synthesizer* operano in sequenza lineare.

Moderate complexity → **MDT:** corrisponde ai casi off-label o di nuova approvazione dove il matching tumore-farmaco non è diretto (BENCH-020, BRAF V600E in NSCLC). Richiede un ciclo di verifica tra *Variant Interpreter*, *Source Router* (CIViC vs OncoKB) ed *Evidence Synthesizer* con iterazione.

High complexity → **ICT:** corrisponde ai casi di resistenza acquisita rara (BENCH-013, ALK G1202R) o biomarker funzionale (BENCH-017, MSI-High). Richiede la pipeline completa: *Variant Interpreter* → *Source Router* con escalation a OncoKB → *Evidence Synthesizer* → *Trial Matcher* → report strutturato con disclaimer esplicito sulla qualità delle evidenze.

3.3 Differenza rispetto al MoE Router e vantaggio del Complexity Check

La differenza concettuale rispetto al MoE Router è rilevante: il MoE Router è una scelta statica di esperto basata sul tipo di input (fusione → agente fusioni; biomarker → agente biomarker). Il *Complexity Check* di MDAgents è una valutazione dinamica della difficoltà del caso specifico, che può variare anche per lo stesso tipo di variante. ALK Fusion in prima linea è Low; ALK Fusion con resistenza G1202R acquisita è High. Questa distinzione è clinicamente più corretta e corrisponde a come funziona realmente un MTB.

3.4 Limitazione da dichiarare in tesi

MDAgents viene valutato su dataset di multiple-choice Q&A (MedQA, USMLE) dove la risposta corretta è una lettera tra quattro opzioni. Il task della tesi è generazione di output strutturato multi-componente con evidenze, resistenze, trial e fonti — un task generativo sostanzialmente più complesso. Questa differenza va dichiarata esplicitamente in tesi per evitare confronti impropri:

le performance di MDAgents non sono direttamente comparabili con i risultati del sistema sviluppato.

4 Matching Patients to Clinical Trials with Large Language Models (TrialGPT)

Jin et al., NIH/NCBI - NCI - University of Pittsburgh, Nature Communications (2024) 15:9074

4.1 Contributo principale e corrispondenza con il Trial Matcher

TrialGPT fornisce il blueprint implementativo per l'agente *Trial Matcher* della tesi. Il framework è composto da tre moduli sequenziali — *Retrieval*, *Matching*, *Ranking* — che corrispondono alle tre funzioni che il Trial Matcher deve svolgere: identificare i trial rilevanti nel grafo, valutare l'eleggibilità del profilo paziente criterio per criterio, e ordinare i trial per pertinenza.

Citazione di riferimento (Jin et al., 2024, Abstract)

“TrialGPT can reduce the screening time by 42.6% in patient recruitment”

Questo è il dato che un ospedale comprende immediatamente: non accuracy, non F1, ma risparmio di tempo verificato in uno studio reale con medici del National Cancer Institute. È anche il tipo di evidenza che la riflessione sulla proponibilità clinica della tesi indicava come prerequisito per il passaggio da prototipo a strumento adottabile.

4.2 Il Matching criterio per criterio come standard

Il contributo più operativamente rilevante è il *TrialGPT-Matching*: invece di classificare il paziente come eligible/ineligible in modo binario, il sistema analizza ogni criterio di inclusione e ogni criterio di esclusione separatamente, assegnando etichette strutturate:

- **Criteri di inclusione:** {Included, Not included, Not enough information, Not applicable}
- **Criteri di esclusione:** {Excluded, Not excluded, Not enough information, Not applicable}

Questa granularità trasforma il Trial Matcher da un filtro binario a uno strumento esplicativo: l'oncologo non riceve “questo trial non è adatto” ma “il paziente soddisfa i criteri di inclusione X e Y, non soddisfa Z per mancanza di informazioni, è escluso dal criterio W per la terapia pregressa”. Questo è esattamente l'output clinicamente utile identificato nella riflessione sull'output ideale del sistema.

4.3 Metriche di valutazione: NDCG@10, P@10, AUROC

TrialGPT introduce metriche specifiche per il ranking e l'esclusione dei trial: NDCG@10 (Normalized Discounted Cumulative Gain) per la qualità del ranking, Precision@10 per la precisione delle prime dieci raccomandazioni, AUROC per la capacità di escludere trial ineleggibili. Queste metriche sono robuste, standard in *information retrieval*, e calcolabili automaticamente sul benchmark dei 30 casi se il sistema Trial Matcher produce una lista ordinata di trial.

4.4 Vantaggio architetturale della tesi rispetto a TrialGPT

TrialGPT opera su testo libero: le note cliniche e i criteri dei trial vengono analizzati da un LLM in linguaggio naturale. La tesi ha i trial già nel grafo come nodi strutturati (nodo `ClinicalTrial` con archi `HAS_GENE`, `TESTS_DRUG`, `HAS_COMPANION_DIAGNOSTIC`), il che permette di sostituire il

retrieval testuale con una query Cypher strutturata — architetaturalmente più precisa e meno soggetta a errori di interpretazione linguistica. Il matching criterio per criterio diventa un match strutturato su proprietà del nodo invece di un’inferenza su testo libero.

5 Sintesi Comparativa e Posizionamento della Tesi

I quattro paper coprono tre livelli distinti del problema che la tesi affronta:

- **Livello Infrastrutturale** (come costruire e interrogare il grafo):
 - **Edge et al. (GraphRAG)**: giustifica teoricamente la superiorità del grafo per query di sensemaking globale rispetto al RAG vettoriale.
 - **Wu et al. (MedGraphRAG)**: valida la struttura tripartita [*dato* → *evidenza* → *fonte*] che la KB oncologica già implementa.
- **Livello Architettuale** (come orchestrare gli agenti):
 - **Kim et al. (MDAgents)**: fornisce il framework di orchestrazione adattiva Low/Moderate/High che sostituisce o affina il MoE Router.
- **Livello Applicativo** (come usare il sistema per i trial):
 - **Jin et al. (TrialGPT)**: fornisce il blueprint del Trial Matcher con matching criterio per criterio e validazione su clinici reali.

Il contributo distintivo della tesi rispetto a tutti e quattro è la KB pre-costruita e curata da fonti multiple (CIViC + OncoKB) con integrità referenziale verificata. MedGraphRAG, MDAgents e TrialGPT costruiscono la loro conoscenza on-the-fly da testo libero via estrazione LLM. La tesi separa nettamente costruzione offline (KB) e interrogazione runtime (agenti) — una scelta architettuale più appropriata per un dominio clinico ad alto rischio dove la qualità e la tracciabilità delle evidenze sono requisiti non negoziabili. Ed è proprio questa separazione che abilita l’Evidence Grounding come metrica originale: il grafo pre-costruito è il metro di misura, non il prodotto del sistema che si sta valutando.

Paper / Sistema	Livello	Approccio Grafo / Conoscenza	Focus Valutazione
GraphRAG (Edge et al.)	Infrastrutturale	Costruzione globale of- fine tramite community summaries	Sensemaking globale (Comprehensiveness, Diversity)
MedGraphRAG (Wu et al.)	Infrastrutturale	Struttura tripartita (dato-evidenza-fonte) estratta on-the-fly	Citation Precision & Re- call (valutazione clini- ca)
MDAgents (Kim et al.)	Architettuale	Orchestrazione adat- tiva dinamica (Low/ Moderate/High)	Decision-making su ben- chmark Q&A medici
TrialGPT (Jin et al.)	Applicativo	Matching paziente-trial criterio per criterio su testo libero	Risparmio tempo scree- ning, NDCG@10, AU- ROC
Tesi (Proposta)	Integrato	KB pre-costruita offli- ne da fonti curate (CI- ViC/OncoKB) con in- tegrità e interrogazione agantica runtime	Evidence Grounding (originale), LLM-as- judge, sanity check (PMID/drug), metriche trial

Tabella 1: Confronto sintetico tra i paper di riferimento e il sistema della tesi.

6 Schema delle Metriche di Valutazione Adottate

Le metriche sono organizzate in quattro livelli gerarchici per importanza e originalità rispetto allo stato dell'arte:

1. Evidence Grounding [*Metrica originale della tesi*]

Proporzione di evidenze clinicamente rilevanti presenti nel grafo per ogni profilo molecolare che il sistema ha recuperato nell'output. Calcolabile automaticamente via *set intersection* tra evidenze nel grafo e evidenze citate nell'output. Raffinabile per livello (solo A/B) e per pertinenza tumorale. Non richiede curazione manuale aggiuntiva.

→ *Risponde a: "Il sistema sfrutta la KB che è stata costruita?"*

2. LLM-as-judge su Comprehensiveness / Diversity / Clinical Actionability [*Ispirato a Edge et al., GraphRAG Microsoft*]

Valutazione qualitativa dell'output su tre dimensioni tramite LLM giudice con criteri espliciti. Applicato ai 30 casi benchmark in confronto tra GraphRAG agentico vs LLM zero-shot vs RAG vanilla.

→ *Risponde a: "La sintesi prodotta è utile per un oncologo al board?"*

3. Drug Anchor + Primary Citation Check [*Check accessorio*]

Drug anchor: il farmaco raccomandato coincide con `expected_drug` del CSV? **Primary citation:** il PMID fondante del caso è incluso nell'output? Calcolabili automaticamente, verificano che il sistema non abbia mancato la raccomandazione principale. Non sostituiscono l'Evidence Grounding ma lo integrano come *sanity check* rapido.

→ *Risponde a: "Il sistema ha almeno trovato la risposta principale?"*

4. Metriche Trial Matcher [*Ispirato a Jin et al., TrialGPT*]

NDCG@10 e P@10 per la qualità del ranking dei trial, AUROC per la capacità di escludere trial ineleggibili. Specifiche per l'agente *Trial Matcher*, applicabili sui 30 casi del benchmark.

→ *Risponde a: "I trial raccomandati sono ordinati correttamente?"*