

Sistema GraphRAG Agentico per Molecular Tumor Board

Report del lavoro svolto

Dalla Knowledge Base alla campagna sperimentale su RQ1

Periodo: 29 maggio — 8 giugno 2026

Stato del progetto

9 / 11

tipi di nodo / relazione

30 / 30

casi benchmark coperti

100%

integrità referenziale

3.96 / 5

score medio (rubrica v2)

100%

Evidence Grounding (+ Enricher)

0%

allucinazione PMID zero-shot

Sommaro esecutivo

Questo report consolida il lavoro tecnico e metodologico svolto nell'arco di due settimane sul sistema oggetto della tesi: una **pipeline agentica GraphRAG** per il supporto decisionale al Molecular Tumor Board (MTB) in oncologia di precisione. Il punto di partenza era un Knowledge Graph (KG) oncologico già costruito e caricato in Neo4j; il punto di arrivo è una pipeline multi-agente completa, end-to-end, valutata sistematicamente su un benchmark clinico di 30 casi reali.

Il percorso si articola in cinque blocchi logici, che corrispondono alle parti di questo documento: (i) il *consolidamento infrastrutturale* del KG e il suo audit quantitativo; (ii) la *costruzione del benchmark* clinico e la sua validazione sul grafo; (iii) l'*architettura multi-sorgente* che integra CIViC e OncoKB; (iv) il *disegno della pipeline* agentica e il suo posizionamento rispetto allo stato dell'arte; (v) la *metodologia di valutazione* e i risultati sperimentali che rispondono alle domande di ricerca.

1. **Verificabilità citazionale.** Il modello zero-shot allucina il 100% delle citazioni (115/115 PMID non pertinenti o inesistenti); il GraphRAG con Enricher raggiunge il 100% di Evidence Grounding, garantendo la tracciabilità totale delle fonti.
2. **Sicurezza clinica multi-sorgente.** Il routing CIViC + OncoKB corregge evidenze fuorvianti (caso 013, ALK G1202R) che un agente mono-sorgente avrebbe scartato, con un impatto di sicurezza clinica diretto.
3. **Knowledge fall-back.** L'arricchimento live via OncoKB risolve i gap strutturali del database locale (+3.35 di score sul caso ALK G1202R), confermando il valore dell'architettura ibrida.

Nota. Tutte le cifre, i conteggi e i risultati riportati provengono dai log di sessione del progetto. Le citazioni testuali dai paper di riferimento sono riportate tra virgolette con autore/anno; il resto è parafrasi o analisi originale.

Indice

Sommario esecutivo	1
I Contesto e cronologia	4
1 Introduzione e contesto	4
1.1 Il problema clinico	4
1.2 La soluzione proposta	4
1.3 Domande di ricerca	4
1.4 Cronologia sintetica del lavoro	4
II Infrastruttura: Knowledge Graph e audit	5
2 Costruzione del Knowledge Graph	5
2.1 Sorgenti dati	5
2.2 Pulizia dei dati e anomalie risolte	6
2.3 Lo schema del grafo	6
2.4 La topologia clinica del Knowledge Graph	7
2.5 Integrità referenziale e caricamento in Neo4j	7
2.6 Validazione con query reali	8
3 Esplorazione e audit della Knowledge Base	8
3.1 Data exploration quantitativa	8
3.2 Riqualficazione scientifica del notebook	8
3.3 Metriche grafo-teoriche formalizzate	9
3.4 Numeri chiave e curation bias	9
3.5 Azionabilità clinica e resistenze (Classificazione ESCAT-like)	10
3.6 Gap Analysis: Varianti orfane e disallineamento trial	10
3.7 Calibrazione per il Trial Matcher	10
3.8 Analisi Grafo-Nativa: Topologia e performance Cypher	11
III Benchmark clinico e architettura multi-sorgente	11
4 Costruzione del benchmark clinico	11
4.1 I primi 10 casi	11
4.2 Estensione a 30 casi	11
4.3 Validazione su Neo4j	11
4.4 Pattern emersi dall'analisi dei gap	12
5 Architettura multi-sorgente: integrazione OncoKB	12
5.1 I limiti di CIViC: gap e <i>misleading evidence</i>	12
5.2 Validazione delle API OncoKB	12
5.3 Integrazione nel grafo	13
5.4 Source Routing intelligente	13
5.5 Studio dettagliato delle API OncoKB	13
IV Disegno della pipeline e posizionamento	14

6	Posizionamento scientifico: i paper di riferimento	14
6.1	Edge et al. — GraphRAG (livello infrastrutturale)	14
6.2	Wu et al. — MedGraphRAG (livello infrastrutturale)	14
6.3	Kim et al. — MDAgents (livello architetturale)	15
6.4	Jin et al. — TrialGPT (livello applicativo)	15
6.5	Aldea et al. (2025) — IASLC Consensus Statement on Molecular Tumor Boards	15
6.6	Berman et al. (2025) — RAG_MTB: Retrieval Augmented Therapy Suggestion	16
6.7	Loaiza-Bonilla et al. (2026) — OncoMultiAgentKB	17
6.8	Sintesi comparativa e posizionamento della tesi	19
7	La pipeline agentica (v1 → v3)	21
7.1	Progettazione iterativa	21
7.2	Una decisione <i>data-driven</i> : Resistance Checker	21
7.3	Comportamento per tier di complessità	21
7.4	Pipeline v3: OncoKB Enricher e input formalizzato	21
7.5	Verifica delle query Cypher per <code>alteration_type</code>	23
V	Valutazione e risultati sperimentali	23
8	Metodologia di valutazione	23
8.1	Cosa stiamo davvero misurando	23
8.2	Valutazione a due livelli	23
8.3	La rubrica LLM-as-judge ricalibrata	24
8.4	La gerarchia delle metriche	24
9	Risultati sperimentali	24
9.1	Confronto Caso per Caso: I 30 Benchmark	24
9.2	Benchmark ricalcolato (v2)	24
9.3	OncoKB Enricher sui casi critici	24
9.4	RQ1: GraphRAG vs Zero-shot e il bias del giudice	26
9.5	Allucinazione bibliografica dello zero-shot	26
9.6	Retrieval Pollution e mitigazione	26
9.7	Confronto a tre vie finale	26
9.8	Ottimizzazione strutturale dell'ESCAT Interpreter	27
9.9	Analisi Casi Drug Anchor Check — Finding Narrativo Chiave	27
9.10	Lettura Corretta dei Risultati (LLM-as-judge)	28
10	Considerazioni etiche e limiti	28
11	Conclusioni e lavori futuri	28
12	Glossario e acronimi	29
	Glossario e acronimi	29
	Riferimenti bibliografici principali	33

PARTE I

Contesto e cronologia

1 Introduzione e contesto

1.1 Il problema clinico

In oncologia di precisione, il referto di un test genomico di nuova generazione (NGS) contiene decine di alterazioni molecolari, ciascuna potenzialmente associata a una terapia approvata, a un farmaco off-label, a un trial clinico aperto o a un meccanismo di resistenza noto. La valutazione collegiale di queste informazioni avviene nel **Molecular Tumor Board (MTB)**, una riunione multidisciplinare di oncologi, biologi molecolari, patologi e bioinformatici.

Il problema operativo è che preparare un singolo caso per il MTB richiede ore di lavoro manuale: consultare OncoKB e CIViC, cercare trial su ClinicalTrials.gov, leggere la letteratura su PubMed e assegnare i livelli di evidenza secondo classificazioni come ESCAT. I database curati sono affidabili ma richiedono interrogazioni manuali nodo per nodo; i modelli linguistici producono sintesi fluide ma possono allucinare, mescolano evidenze di livelli diversi e non citano in modo verificabile. Un sistema GraphRAG ben progettato può unire i vantaggi di entrambi.

1.2 La soluzione proposta

Il sistema è una pipeline agentica multi-stadio che riceve in input il profilo molecolare di un paziente e produce in output una raccomandazione terapeutica strutturata, con livelli di evidenza espliciti e citazioni verificabili. La componente centrale è un Knowledge Graph costruito in Neo4j: gli agenti specializzati lo interrogano con query Cypher invece di generare risposte dalla memoria parametrica di un LLM.

Il KG è come una biblioteca specializzata ben indicizzata. Gli agenti sono bibliotecari esperti che sanno esattamente dove cercare. L'LLM è il redattore che trasforma i risultati della ricerca in un report leggibile: senza la biblioteca, il redattore è costretto a inventare.

1.3 Domande di ricerca

Il lavoro è guidato da quattro domande di ricerca:

Domande di ricerca

- RQ1** Il sistema agentico è più accurato e *verificabile* di un LLM zero-shot nel produrre raccomandazioni terapeutiche su casi MTB pubblicati?
- RQ2** Il sistema assegna i livelli ESCAT in modo riproducibile e con citazioni verificabili (*faithfulness*)?
- RQ3** Quanta parte della preparazione del MTB può essere automatizzata?
- RQ4** Un router agentico che attiva dinamicamente solo gli agenti rilevanti migliora precisione e latenza rispetto a una pipeline sequenziale fissa?

1.4 Cronologia sintetica del lavoro

Il lavoro delle due settimane si dispiega lungo dieci sessioni, riassunte nella linea temporale seguente.

29 mag	●	KB oncologica completata e caricata in Neo4j: 41.426 nodi , 51.616 archi , 7 tipi di nodo, 9 relazioni, integrità referenziale al 100%.
30 mag	●	Data exploration quantitativa della KB (notebook Jupyter): struttura, copertura clinica, qualità per il benchmark, gap, analisi per il Trial Matcher.
31 mag	●	Primo benchmark di 10 casi MTB (tutti ESCAT Tier I-A) e aggiunta dei nodi <i>Disease</i> e <i>Publication</i> : tutti i 10 PMID benchmark entrano nel grafo.
1 giu	●	Estensione del benchmark da 10 a 30 casi su 5 categorie cliniche; validazione Cypher (20 PASS, 5 PARZIALI, 5 GAP) e audit scientifico del notebook.
2 giu	●	Note metodologiche sulla valutazione (rubrica + LLM-as-judge); integrazione OncoKB che risolve gli ultimi gap: copertura 30/30 .
4 giu	●	Incontro con il relatore: riflessioni sui quattro paper di riferimento e gerarchia delle metriche di valutazione.
5 giu	●	Progettazione della pipeline agentica ($v1 \rightarrow v2 \rightarrow v3$), studio delle API OncoKB e formalizzazione dello schema di input clinico.
6 giu	●	Verifica sistematica delle query Cypher per tutti i 6 tipi di <code>alteration_type</code> : KB pronta al 100% per l'integrazione con l'LLM.
7 giu	●	Sistema end-to-end attivo (FastAPI + LangGraph + React); ricalibrazione del judge a 4 criteri e ricalcolo del benchmark; confronto RQ1.
8 giu	●	Risultati finali: allucinazione PMID zero-shot al 100%, mitigazione del retrieval pollution, validazione dell'Enricher. RQ1 blindato.

PARTE II

Infrastruttura: Knowledge Graph e audit

2 Costruzione del Knowledge Graph

2.1 Sorgenti dati

Il grafo integra sei database pubblici, tutti open access e ampiamente usati nella ricerca clinica internazionale.

CIViC Clinical Interpretation of Variants in Cancer: evidenze cliniche sulle varianti genomiche, con livello di evidenza e PMID citabile. Scaricati quattro file TSV (evidenze accettate, varianti, profili molecolari, feature).

DGIdb Drug-Gene Interaction Database: interazioni farmaco-gene aggregate da una trentina di sorgenti.

OncoKB Cancer Gene List Lista curata da Memorial Sloan Kettering dei geni oncologici clinicamente rilevanti.

FDA Oncology Therapies Terapie oncologiche approvate FDA con classificazione precision oncology e biomarker richiesto.

FDA Companion Diagnostic Devices Dispositivi diagnostici companion (CDx) approvati FDA.

ClinicalTrials.gov Registro pubblico (API v2): trial oncologici attivi/in reclutamento per 38 geni principali. 5.570 trial unici dopo deduplicazione su NCT ID (da 9.389 record raw).

In totale sono stati ispezionati 11 file iniziali (TSV ed Excel) per oltre 400.000 righe di dati grezzi, più il dump di ClinicalTrials.gov.

2.2 Pulizia dei dati e anomalie risolte

L'ispezione preliminare ha evidenziato sei anomalie che avrebbero compromesso la qualità del grafo. Sono riepilogate qui sotto.

Anomalia	Diagnosi e correzione
Colonne shiftate CIViC	Pandas leggeva la prima colonna come indice di riga, spostando tutte le altre di una posizione (gli ID contenevano URL e viceversa). Risolto con <code>index_col=False</code> .
Farmaci duplicati DGIdb	81.572 righe per soli 24.501 farmaci unici (un alias per sorgente). Deduplicato su <code>concept_id</code> .
Scope oncologico DGIdb	98.239 interazioni includevano farmaci cardiologici/psichiatrici. Filtrate a 25.589 mantenendo <code>anti_neoplastic=True</code> o gene in cancer gene list.
Celle multi-valore CIViC	Colonne <code>therapies</code> , <code>nct_ids</code> , <code>aliases</code> esplose con <code>df.explode()</code> : ogni elemento diventa un arco.
Null strutturali FDA xlsx	52% di null su <code>biomarker</code> : non un errore, ma assenza fisiologica per i chemioterapici. Caricato il subset precision oncology.
Matching nomi farmaci	CIViC usa nomi misti, DGIdb uppercase. Normalizzato (<code>strip + uppercase</code>); 405 occorrenze non risolvibili salvate in log per revisione manuale.

2.3 Lo schema del grafo

Lo schema definitivo, dopo l'aggiunta dei nodi *Disease* e *Publication* (31 maggio), conta **9 tipi di nodo** e **11 tipi di relazione**.

Tipi di nodo		Tipi di relazione	
Nodo	Quantità	Relazione	Archi
Drug	24.501	INTERACTS_WITH	25.589
ClinicalTrial	5.570	TESTS_DRUG	8.018
Evidence	4.843	ASSOCIATED_GENE	5.501
Publication	2.222	CITED_IN	4.840
Variant	1.973	HAS_DISEASE	4.684
MolecularProfile	1.937	HAS_EVIDENCE	4.843
Gene	1.436	TARGETS_DRUG	3.347
Disease	334	IN_MOLECULAR_PROFILE	2.279
CompanionDiagnostic	166	HAS_VARIANT	1.725
		DIAGNOSES_GENE / HAS_COMP_DIAG.	163 / 150

Il nodo **Drug** è il più connesso del grafo: riceve relazioni da cinque direzioni diverse (Evidence, Gene via CIViC, Gene via DGIdb, CompanionDiagnostic, ClinicalTrial). È il punto centrale attorno a cui ruota tutta la conoscenza terapeutica.

2.4 La topologia clinica del Knowledge Graph

Come visibile nello schema (Figura 1), il modello dati non si limita al tracciamento diretto tra mutazione e terapia, ma implementa una topologia complessa a multi-hop che riflette le reali dipendenze dell'oncologia di precisione.

- **Il percorso biologico-clinico (6-Hop):** Il cammino principale (asse centrale) parte dal Gene, transita fisiologicamente per la Variant e il suo MolecularProfile, agganciandosi infine alla Clinical Evidence. È solo a questo livello — quello dell'evidenza clinica — che il grafo si dirama simultaneamente verso il farmaco (TARGETS_DRUG), la patologia bersaglio (HAS_DISEASE) e la fonte scientifica di supporto (CITED_IN). Questa catena impedisce le associazioni fuori contesto.
- **Interazioni Farmacodinamiche Dirette:** La relazione INTERACTS_WITH collega direttamente Gene e Drug, catturando i dati crudi di interazione molecolare di DGIdb (1-Hop).
- **Trial Matcher e Diagnostica:** L'ecosistema integra i Clinical Trial, mappati contemporaneamente ai geni (ASSOCIATED_GENE) e ai farmaci sperimentali (TESTS_DRUG); in modo speculare, i Companion Diagnostic correlano il farmaco al test genomico specifico (DIAGNOSES_GENE).




Figura 1: Schema topologico del Knowledge Graph oncologico in uso

2.5 Integrità referenziale e caricamento in Neo4j

Dopo l'ingestion in Neo4j Desktop 5.x (istanza locale GraphRAGTesi) sono stati creati i constraint di unicità e gli indici sugli attributi di lookup frequente (`hugo_symbol`, `drug_name`). Lo script di verifica ha accertato il **100% di allineamento referenziale**: ogni arco punta a nodi che esistono realmente, nessun riferimento rotto, nessun ID orfano — l'equivalente di un database relazionale senza foreign key violations.

2.6 Validazione con query reali

Il grafo è stato validato sul caso clinico più rappresentativo della tesi (NSCLC, EGFR L858R). La query del Variant Interpreter restituisce in 657 ms i farmaci con evidenza di livello A, ciascuno ancorato al PMID della pubblicazione di supporto.

Cypher — Variant Interpreter + Target Identifier (EGFR L858R)

```
MATCH (g:Gene {hugo_symbol:"EGFR"})
-[:HAS_VARIANT]->(v:Variant {variant_name:"L858R"})
-[:IN_MOLECULAR_PROFILE]->(mp:MolecularProfile)
-[:HAS_EVIDENCE]->(e:Evidence)
-[:TARGETS_DRUG]->(d:Drug)
WHERE e.evidence_level = "A" AND e.evidence_type = "Predictive"
AND e.significance CONTAINS "Sensitivity"
RETURN g.hugo_symbol, v.variant_name, mp.name, e.citation_id,
d.drug_name;
```

Risultato: *Afatinib*, *Dacomitinib*, *Osimertinib*, *Erlotinib*, *Gefitinib*, *Ramucirumab*, ciascuno con PMID verificabile. Sono stati validati anche i casi BRCA1/BRCA2 (PARP inhibitor), BRAF V600E (melanoma vs CRC con significance opposta), BCR::ABL1 (CML) e i companion diagnostic.

3 Esplorazione e audit della Knowledge Base

3.1 Data exploration quantitativa

È stato prodotto un notebook Jupyter che opera direttamente sui CSV puliti, articolato in cinque macro-sezioni più due analisi aggiuntive (matrice gene-tumore e benchmark Gold per tipo tumorale). I risultati più rilevanti:

- **Distribuzione nodi:** Drug domina con il 60.6% dei nodi, seguito da ClinicalTrial (13.8%) ed Evidence (12%).
- **Top geni per varianti:** VHL (313), EGFR (131), TP53 (113), PIK3CA (85), ABL1 (68).
- **Top profili per evidenze CIViC:** BRAF V600E (95), ERBB2 Amplification (65), KRAS Mutation (45), PIK3CA Mutation (40), EGFR L858R (37).
- **Tipo di evidenza:** Predictive domina con il 58.7% (2.843 evidenze) — il tipo direttamente utile alle raccomandazioni del MTB.
- **Coerenza biologica:** la matrice gene-tumore conferma i pattern attesi (ABL1 in CML, EGFR in NSCLC, KIT in GIST, FLT3 in AML, PIK3CA trasversale), validazione indiretta della qualità del grafo.

3.2 Riqualficazione scientifica del notebook

A seguito delle critiche metodologiche del relatore, il notebook è stato sottoposto a un audit completo. Erano emerse vulnerabilità che avrebbero potuto inficiare la solidità in sede di discussione; le più rilevanti, con la relativa soluzione:

Criticità	Soluzione applicata
Integrità referenziale fittizia	La cella si limitava a sommare le righe dei DataFrame. Introdotta <code>validate_referential_integrity()</code> con audit case-insensitive su tutti gli 11 archi: 0 archi orfani accertati.
Successo autoreferenziale ETL	“0 farmaci non mappati” era un artefatto: l’ETL normalizzava i nomi dei farmaci dei trial sulla stessa anagrafica, rendendo il match matematicamente inevitabile. Riconosciuto e documentato.
Superiorità Cypher non dimostrata	Aggiunto un benchmark statistico rigoroso Pandas vs Cypher a parità di carico (6-Hop, 5 ripetizioni + warm-up scartato, media e σ).
Conclusioni hardcoded	I KPI nelle conclusioni erano testo Markdown statico. Riscritti come estrazione dinamica via codice Python.
Sicurezza e portabilità	Rimossa la password Neo4j in chiaro; sostituiti i path assoluti Windows; aggiunti fallback espliciti per istanza disconnessa.
Ottimizzazione architetturale Neo4j	Sostituito il pattern usa-e-getta del driver di connessione (che saturava il pool) con un’istanza persistente, abbattendo i tempi di interrogazione da diversi minuti a meno di 4 secondi per l’intera suite di valutazione.

3.3 Metriche grafo-teoriche formalizzate

Le metriche, prima discorsive, sono state formalizzate. La densità globale di un grafo orientato è

$$D = \frac{|E|}{|V|(|V| - 1)},$$

fisiologicamente minuscola in un grafo multipartito eterogeneo. Per misurare la *concentrazione editoriale* (curation bias) sui geni dominanti sono stati introdotti il coefficiente di Gini e l’indice Herfindahl-Hirschman (HHI). Il vecchio gap score lineare DGIdb – CIViC è stato sostituito dal **Conoscenza Gap Index** normalizzato:


$$\text{CGI} = \frac{\text{DGIdb} - \text{CIViC}}{\text{DGIdb} + \text{CIViC} + 1} \in [-1, 1],$$

che normalizza scale diverse ed evidenzia i geni a massimo gap di conoscenza (alte interazioni teoriche, poche evidenze cliniche consolidate).

3.4 Numeri chiave e curation bias

La distribuzione dei livelli di evidenza fotografa una KB ricca ma prevalentemente di evidenza intermedia.

Livello	N.	Significato
A	225	Linee guida / FDA
B	1.620	Consenso clinico
C	1.668	Clinica preliminare
D	1.298	Preclinica
E	32	Case report



- Solo il **4.6%** delle evidenze è di livello A: la pipeline agentica opera intrinsecamente in contesti ad alta incertezza clinica.
- Solo **47/1.436** geni (3.27%) hanno almeno un trial clinico nel grafo: il Trial Matcher dovrà appoggiarsi all'API live di ClinicalTrials.gov.
- **809/1.973** varianti (41%) sono puramente diagnostiche o prognostiche, senza terapia predittiva associata: è ciò che giustifica un routing differenziato.

Curation bias (caso VHL): VHL risulta il gene a massima densità di evidenze, superando EGFR e ABL1, per la vastissima letteratura legata alla sindrome di Von Hippel-Lindau — un'asimmetria editoriale tipica delle banche dati pubbliche.

3.5 Azionabilità clinica e resistenze (Classificazione ESCAT-like)

Il sistema di cura nativo di CIViC classifica le evidenze secondo le linee guida AMP/ASCO/CAP. Tuttavia, ai fini di un sistema di supporto decisionale per il Molecular Tumor Board, è stata implementata una mappatura **ESCAT-like**. Mentre le linee guida AMP valutano la forza dell'evidenza biologica intrinseca, la scala ESCAT valuta l'efficacia clinica del *match* alterazione-farmaco in uno specifico tumore.

Come visibile nella distribuzione quantitativa, solo il **4.6%** (225 su oltre 4.800) delle evidenze appartiene al Livello A (comparabile al Tier I ESCAT, ovvero linee guida standard o approvazione FDA). Questo denota empiricamente che la *pipeline agentica* è chiamata a operare per il 95% dei casi in contesti ad alta incertezza clinica. Inoltre, l'interrogazione mirata del grafo ha permesso di mappare il cruciale problema delle **resistenze acquisite**. Un caso d'uso esemplare emerso dalla *Data Exploration* riguarda la variante **BRAF V600E**: squisitamente sensibile a inibitori BRAF nel melanoma (es. Vemurafenib), ma che conferisce forte resistenza agli anticorpi anti-EGFR (Cetuximab) nel carcinoma coloretale. Il campo `significance = Resistance` nel grafo impedisce all'agente di effettuare prescrizioni potenzialmente pericolose, filtrando topologicamente le co-occorrenze sfavorevoli.

3.6 Gap Analysis: Varianti orfane e disallineamento trial

L'audit esplorativo ha fatto emergere limitazioni informative intrinseche alla Knowledge Base, che giustificano l'introduzione di *tool* esterni live (API OncoKB e ClinicalTrials.gov). Circa il **41%** delle varianti (809 su 1.973) risulta "orfano" di terapie predittive, possedendo esclusivamente valenza diagnostica o prognostica. Inoltre, lo screening dei nodi `ClinicalTrial` ha rivelato un disallineamento ontologico: vari farmaci sperimentali inseriti nei trial non sono stati formalmente approvati o recensiti nelle ontologie primarie (DGIdb), causando discrepanze semantiche che l'agente risolve sfruttando la robustezza del *parsing* LLM e l'addestramento *few-shot*.

3.7 Calibrazione per il Trial Matcher

L'estrazione quantitativa sui nodi di tipo `ClinicalTrial` e `Drug` ha evidenziato che la distribuzione dei Trial clinici predilige fortemente le fasi intermedie e avanzate (Phase II e III), ma copre in modo estremamente frammentario i target biologici: solo il **3.27%** dei geni mappati (47 su 1.436) possiede connessioni dirette a un trial aperto nel grafo consolidato. Ciò ha dettato la necessità architetturale di integrare uno specialista (l'agente *Trial Matcher*) dotato di chiamate API live per interrogare esternamente i registri, non potendo fare esclusivo affidamento sui dati estratti in fase di ETL.

3.8 Analisi Grafo-Nativa: Topologia e performance Cypher

Per validare empiricamente il superamento di architetture tabulari in sede di tesi, si è condotto nel notebook uno studio prestazionale (Cypher vs Pandas *Hash Join*). L'estrazione di un percorso clinico ad elevata complessità (6-Hop: Gene → Variant → MolecularProfile → Evidence → Disease / Drug) si risolve in Neo4j con un tempo di accesso ordini di grandezza inferiore, mantenendo una scalabilità ottimale all'aumentare dei nodi interrogati.

Sotto il profilo analitico, lo studio topologico ha dimostrato come le interazioni dirette (1-Hop via DGIdb, Gene → Drug) spesso omettano il vincolo istologico, rivelandosi insufficienti per raccomandazioni MTB sicure. Al contrario, solo i percorsi indiretti a 4-Hop permettono di transitare fisiologicamente attraverso le entità Variant e Disease, filtrando contestualmente l'applicabilità della molecola in base al referto reale del paziente.

PARTE III

Benchmark clinico e architettura multi-sorgente

4 Costruzione del benchmark clinico

4.1 I primi 10 casi

È stato costruito un dataset di 10 casi MTB reali estratti dalla letteratura clinica (JCO Precision Oncology, ESMO Open, Oncotarget, PubMed), tutti ESCAT Tier I-A, con profilo molecolare, raccomandazione MTB, livello ESCAT e PMID verificabile. La validazione Cypher ha dato 8/10 casi coperti (80%), con due gap documentati: 002 (ALK Fusion prima linea, gap noto di CIViC) e 010 (Midostaurin assente, benchmark aggiornato a Gilteritinib). Tutti i 10 PMID benchmark sono stati portati nel grafo come nodi Publication — requisito fondamentale per RQ2.


4.2 Estensione a 30 casi

Il benchmark è stato esteso a 30 casi su cinque categorie cliniche, per coprire scenari clinicamente realistici oltre alle varianti attivanti classiche:

Categoria	Esempi
Resistenza acquisita	011 EGFR T790M, 013 ALK G1202R, 014 ABL1 T315I
Nuovi target approvati	012 KRAS G12C, 015 RET Fusion, 025 IDH1, 026 FGFR2
Tumor-agnostic / bio-marker	016 NTRK1, 017 MSI-High, 023 TMB-High
Off-label Tier II	020 BRAF V600E in NSCLC, 021, 022, 029
Baseline aggiuntivi	018 KRAS G12C in CRC, 024 EGFR Exon 19 del

4.3 Validazione su Neo4j

Le 20 nuove query Cypher (più una query riassuntiva UNWIND) hanno prodotto la distribuzione seguente sui 30 casi totali.



Caso	Profilo	Esito
010	FLT3 ITD / AML	PARZIALE
013	ALK G1202R / NSCLC	GAP
016	NTRK1 Fusion / Agnostic	PARZIALE
017	MSI-High / CRC	PARZIALE
023	TMB-High / Agnostic	GAP
025	IDH1 R132 / AML	PARZIALE
026	FGFR2 Fusion / Cholangio	PARZIALE
028	ROS1 Fusion / NSCLC	GAP
altri 22 casi		PASS

4.4 Pattern emersi dall'analisi dei gap

I gap non sono casuali: rivelano limiti sistematici della singola sorgente CIViC.

1. **Fusioni di prima linea sotto-rappresentate.** ALK (002) e ROS1 (028) confermano che CIViC modella prevalentemente le varianti di resistenza post-TKI, non la fusione semplice di prima linea.
2. **Biomarker quantitativi non modellati.** TMB-High (023) e MSI-High (017) non rientrano nello schema Gene → Variant → Evidence: serve un nodo Biomarker.
3. **Latenza editoriale di CIViC.** IDH1 R132 (025) è livello B nonostante l'approvazione FDA 2018; Larotrectinib (016) è assente nonostante l'approvazione 2018.
4. **Class-level vs drug-level.** FGFR2 (026): il grafo identifica la classe corretta (inibitori FGFR) ma non il farmaco specifico approvato (pemigatinib vs erdafitinib).

5 Architettura multi-sorgente: integrazione OncoKB

5.1 I limiti di CIViC: gap e misleading evidence

Due gap del benchmark (013 e 017) sono stati diagnosticati con query mirate. Il caso 013 ha rivelato un problema più grave di una semplice assenza.

Per ALK G1202R, CIViC non solo mancava dell'evidenza corretta, ma associava Lorlatinib come farmaco di **resistenza** nel mesotelioma pleurico (tumore errato e significato terapeutico invertito). Un agente decisionale basato solo su CIViC avrebbe *attivamente scartato* l'unico farmaco salvavita efficace per questa mutazione di resistenza.

5.2 Validazione delle API OncoKB

Le API OncoKB (token accademico) sono state validate sui due gap, confermando che non erano limiti del modello dati ma della singola sorgente:

- **ALK G1202R / NSCLC:** `variantExist=true`, livello massimo `LEVEL_2`, 6 evidenze — Lorlatinib (`LEVEL_2`, Sensitivity, PMID 30892989), Neladalkib (`LEVEL_3A`), e gli inibitori di generazioni precedenti come resistenza (`LEVEL_R2`).
- **MSI-High / Colorectal:** trovato via endpoint "Other Biomarkers" (`hugoSymbol = -2`), livello massimo `LEVEL_1` — Pembrolizumab (tumor-agnostic), Nivolumab, Ipilimumab+Nivolumab, Dostarlimab.

5.3 Integrazione nel grafo

È stata sviluppata una pipeline di arricchimento eseguita direttamente sui CSV di `Clean_Graph_Data`, preservando l'integrità referenziale: mantenuti i nodi `Variant/MolecularProfile` esistenti da CIViC e iniettati nuovi nodi `Evidence` con `source_type = 'OncoKB'`. Per MSI-High è stato creato un nodo `Gene` fittizio "Other Biomarkers" (`entrez_id: -2`) allineato allo standard OncoKB.

File CSV / Entità	Pre	Post	Δ
node_evidence.csv	4.843	4.859	+16
edge_has_evidence.csv	4.843	4.859	+16
edge_targets_drug.csv	3.347	3.369	+22
node_gene/variant/mp/drug	—	—	+1 ciascuno

Dopo il ricaricamento, il benchmark raggiunge la copertura massima: **30/30 casi risolti**. La distribuzione delle 16 nuove evidenze: 4 a `LEVEL_1`, 2 a `LEVEL_2`, 1 a `LEVEL_3A`, 5 a `LEVEL_3B`, 4 a `LEVEL_R2`.

5.4 Source Routing intelligente

L'integrazione dimostra che CIViC e OncoKB non sono ridondanti ma complementari. Il router agentico implementa una logica di instradamento per tipologia di query.

Tipologia di query / biomarker	Strategia di routing ottimale
Biomarker funzionale (MSI-H, TMB-H, HRD)	OncoKB (endpoint "Other Biomarkers")
Variante di resistenza acquisita	OncoKB (prioritario) + CIViC (contesto)
Mutazione attivante classica	CIViC (prioritario) + OncoKB (livello FDA)
Fusione genica	Entrambi (matching differenziato)

Senza il routing multi-sorgente, un agente clinico avrebbe scartato Lorlatinib (trattamento d'elezione) basandosi sull'evidenza fuorviante di CIViC. Con il routing integrato il sistema seleziona OncoKB e raccomanda la terapia corretta. Non è una differenza di sola completezza quantitativa, ma una differenza qualitativa di *sicurezza clinica*.

5.5 Studio dettagliato delle API OncoKB

La versione dati testata è la v7.2 (aggiornamento 02/05/2025). Gli endpoint rilevanti e il mapping verso ESCAT sono riassunti di seguito.

Endpoint per tipo di alterazione		Mapping livelli OncoKB → ESCAT	
Alterazione	Endpoint	OncoKB	ESCAT
point_mutation	byProteinChange	LEVEL_1	Tier I-A
fusion	structuralVariants	LEVEL_2	Tier I-B
cna	copyNumberAlterations	LEVEL_3A	Tier II-A
itd	byProteinChange (ITD)	LEVEL_3B	Tier II-B
biomarker	byProteinChange (no gene)	LEVEL_R1/R2	Resistenza
atypical	byProteinChange (Exon X)		

La chiamata di test (BRAF V600E / Melanoma) ha confermato l’oncogenicità e i trattamenti attesi, includendo un *abstract presentato ad ASCO 2026* (Kopetz et al.) non presente in alcun database statico offline — una validazione diretta del valore dell’interrogazione live.

PARTE IV

Disegno della pipeline e posizionamento

6 Posizionamento scientifico: i paper di riferimento

L’incontro con il relatore ha prodotto una riflessione sui paper che ancorano la tesi allo stato dell’arte, arricchita dalle ultime pubblicazioni (11 giugno). Il sistema proposto si colloca all’intersezione tra tre tendenze convergenti: la validazione clinica dell’uso di ESCAT come standard MTB (Aldea et al., 2025), la dimostrazione che il RAG testuale soffre di limitazioni strutturali nella gestione delle citazioni (Berman et al., 2025), e la validazione industriale su larga scala che KB oncologica strutturata e agenti LLM specializzati riducono le allucinazioni (Loaiza-Bonilla et al., 2026). I tre nuovi paper di riferimento analizzati coprono tre prospettive complementari e distinte rispetto ai paper già in uso nella tesi:

Tabella 1: Panoramica dei nuovi paper di riferimento e loro prospettiva

Paper	Venue	Anno	Prospettiva
Aldea et al. — IASLC MTB Consensus	J. Thorac. Oncol.	2025	Clinica — definisce lo standard MTB
Berman et al. — RAG_MTB	JMIR Med. Inform.	2025	Tecnica — RAG testuale per MTB
Loaiza-Bonilla et al. — OncoMultiAgentKB	ESMO Real World Data	2026	Tecnica — Multi-agente + KB oncologica

Nessuno dei cinque paper già in uso (Edge et al., Wu et al., Kim et al., Jin et al.) rappresenta un confronto diretto con un sistema RAG o multi-agente applicato specificamente al problema delle raccomandazioni terapeutiche in ambito Molecular Tumor Board (MTB). I tre nuovi lavori analizzati colmano esattamente questo gap.

6.1 Edge et al. — GraphRAG (livello infrastrutturale)

Introduce il concetto di *sensemaking query*, che richiede una comprensione globale del corpus e non il recupero di frammenti locali.

“vector RAG approaches do not support sensemaking queries, meaning queries that require global understanding of the entire dataset”

(Edge et al., 2025)

Il contributo più rilevante per la tesi è però *valutativo*: Edge et al. sviluppano e validano l’approccio **LLM-as-judge** su Comprehensiveness, Diversity ed Empowerment. È la risposta diretta allo scetticismo sull’LLM-as-judge: non un approccio “soft”, ma la metodologia adottata da Microsoft Research in un paper di riferimento.

6.2 Wu et al. — MedGraphRAG (livello infrastrutturale)

È il paper più vicino per dominio e architettura. La sua *Triple Graph Construction* (dato → evidenza → fonte) corrisponde al percorso MolecularProfile → Evidence → Publication già presente nel grafo. La differenza decisiva: nella tesi questa structure è *pre-costruita* da

fonti curate, non estratta on-the-fly da un LLM — più affidabile in un contesto clinico ad alto rischio. Le metriche di citation precision/recall sono robuste ma richiedono di conoscere a priori l'insieme completo delle fonti rilevanti, sforzo di curazione fuori scala per una tesi magistrale: di qui la metrica originale dell'Evidence Grounding (sez. 6.8).

6.3 Kim et al. — MDAgents (livello architetturale)

Risponde alla domanda del relatore sull'alternativa al routing agentico: un'orchestrazione adattiva che assegna la struttura di collaborazione in base alla complessità del caso (Low → agente singolo; Moderate → MDT; High → ICT).

"MDAgents achieved the best performance in seven out of ten benchmarks on tasks requiring an understanding of medical knowledge" (Kim et al., 2024)

Il *Complexity Check* è una valutazione dinamica della difficoltà, più corretta clinicamente del routing statico: ALK Fusion in prima linea è Low, ALK Fusion con resistenza G1202R acquisita è High. Limite da dichiarare: MDAgents è valutato su Q&A a scelta multipla, mentre il task della tesi è generazione strutturata multi-componente.

6.4 Jin et al. — TrialGPT (livello applicativo)

Fornisce il blueprint del Trial Matcher: tre moduli (Retrieval, Matching, Ranking) e un matching *criterio per criterio* con etichette strutturate, non un filtro binario.

"TrialGPT can reduce the screening time by 42.6% in patient recruitment" (Jin et al., 2024)

Vantaggio architetturale della tesi: i trial sono già nel grafo come nodi strutturati, quindi il retrieval testuale diventa una query Cypher — più precisa e meno soggetta a errori di interpretazione linguistica.

6.5 Aldea et al. (2025) — IASLC Consensus Statement on Molecular Tumor Boards

Riferimento bibliografico:

Aldea M, Rotow JK, Arcila M, et al. *Molecular tumor boards: a consensus statement from the International Association for the Study of Lung Cancer*. J Thorac Oncol. 2025;20:1594–1614. DOI: 10.1016/j.jtho.2025.07.009

Descrizione e contesto

Un consensus statement redatto dalla *International Association for the Study of Lung Cancer* (IASLC) che raccoglie le raccomandazioni di decine di oncologi esperti su come implementare e far operare un MTB. Non si tratta di un paper sperimentale sull'Intelligenza Artificiale, bensì del documento normativo clinico di riferimento per il problema medico che la tesi si propone di affrontare.

Contributo chiave per la tesi

Giustificazione clinica dell'uso di ESCAT come metrica primaria.

Il consensus statement afferma esplicitamente che l'uso di scale di azionabilità genomica è *critico* per gli MTB al fine di generare raccomandazioni consistenti ed evidence-based, riducendo la dipendenza dall'opinione del singolo esperto. Identifica la scala ESCAT e OncoKB come i due standard di riferimento, descrivendo la seguente mappatura:

- **ESCAT I / OncoKB 1–2:** biomarker pronti per l'uso routinario, associati ad un beneficio di sopravvivenza in trial clinici con terapia mirata (*matched*).

- **ESCAT II / OncoKB 3A:** richiedono ulteriore validazione (tasso di risposta migliorato ma beneficio di sopravvivenza incerto).
- **ESCAT III / OncoKB 3B:** evidenza clinica in altri tipi di tumore con la medesima alterazione genomica.
- **ESCAT IV:** evidenza derivante unicamente da dati preclinici.

Crucialmente, il documento riporta:

“each ranking applies to a specific drug–target pair, not the alteration alone” (Aldea et al., 2025)

Questa affermazione giustifica esattamente la scelta architetturale dell’interfaccia dell’ESCAT Interpreter sviluppata nella tesi, che valuta la quadrupla composta da `gene + variante + farmaco + tumore` piuttosto che basarsi sul solo livello di evidenza grezzo dell’alterazione.

Collocazione nel lavoro di tesi

- **Introduzione e Background:** per giustificare il motivo per cui un MTB necessita di un sistema di classificazione strutturato e per validare la scelta della scala ESCAT come standard europeo.
- **Sezione Metodologica (ESCAT Interpreter):** per citare la definizione formale dei tier ESCAT implementati all’interno della logica degli agenti.
- **Discussione dei risultati:** per confrontare le raccomandazioni generate dal sistema con lo standard clinico internazionalmente riconosciuto.
- **Limitazioni:** il consensus identifica forti disparità globali nell’accesso agli MTB; il nostro sistema si posiziona come uno strumento idoneo ad abbattere queste barriere automatizzando la fase di preparazione dei casi.

Differenziatore e posizionamento

Il consensus non affronta il tema dell’automazione tramite intelligenza artificiale. Rappresenta invece il quadro normativo-clinico che definisce le regole del problema che la tesi affronta e risolve dal punto di vista ingegneristico.

6.6 Berman et al. (2025) — RAG_MTB: Retrieval Augmented Therapy Suggestion

Riferimento bibliografico:

Berman E, Sundberg Malek H, Bitzer M, Malek N, Eickhoff C. *Retrieval Augmented Therapy Suggestion for Molecular Tumor Boards: Algorithmic Development and Validation Study*. JMIR Med Inform. 2025. DOI: 10.2196/64364. PMID: 40053768.

Descrizione e contesto

Una pipeline RAG sviluppata con LlamaIndex su dati estratti da PubMed (impiegando LLaMA come spina dorsale LLM) concepita per generare raccomandazioni terapeutiche per pazienti reali afferenti al Molecular Tumor Board dell’Università di Tubinga. La valutazione delle risposte generate dal sistema viene effettuata manualmente dai membri del board stesso.

Architettura del sistema

- **Input:** cartella clinica del paziente (profilo molecolare e diagnosi).
- **Retrieval:** interrogazione semantica di PubMed tramite LlamaIndex per ciascuna coppia (tipo di cancro, mutazione genica).
- **Filtro:** restrizione ai geni presenti nei livelli 1, 2 o 3 di OncoKB.

- **Output:** raccomandazione terapeutica, giustificazione testuale e referenze PubMed.
- **Ground Truth:** il protocollo MTB ufficiale precedentemente deliberato dall'istituzione ospedaliera.

Contributo chiave e confronto diretto

Rappresenta il confronto diretto più pertinente in letteratura, condividendo lo stesso dominio (MTB) e lo stesso compito (raccomandazioni terapeutiche), ma adottando un approccio basato su RAG testuale classico su PubMed anziché su una base di conoscenza strutturata a grafo (Neo4j). Le differenze evidenziano tre importanti vantaggi del nostro sistema:

1. **Fonte della Conoscenza:** Berman et al. interrogano PubMed in modo non strutturato tramite ricerca semantica. La tesi impiega una Knowledge Base pre-costruita e curata a partire da fonti validate (CIViC + OncoKB) con integrità referenziale verificata. Il sistema di Berman è esposto al recupero di paper non pertinenti o contraddittori; la tesi interroga esclusivamente record clinici validati da esperti.
2. **Gestione delle Allucinazioni:** Il sistema RAG_MTB non possiede meccanismi per garantire che i codici PMID citati nell'output esistano realmente o siano associati al profilo del paziente. La tesi effettua una verifica referenziale esplicita tramite la relazione `CITED_IN` nel grafo prima della sintesi, garantendo uno 0% di allucinazioni PMID.
3. **Classificazione ESCAT:** Berman et al. non assegnano un livello ESCAT. Il sistema proposto lo fa in modo sistematico e strutturato, allineandosi alle raccomandazioni del consensus statement clinico (Aldea et al., 2025).

Metrica di confronto disponibile

Il paper riporta che il sistema è stato valutato qualitativamente su rilevanza e correttezza, ma non introduce metriche quantitative riproducibili (come accuratezza o F1-score) calcolate su un benchmark standardizzato. La valutazione automatica e quantitativa effettuata nella tesi su 30 casi clinici risulta dunque metodologicamente più rigorosa.

Collocazione nel lavoro di tesi

- **Lavori Correlati (State of the Art):** come il confronto più affine in assoluto per dominio e obiettivi.
- **Metodologia:** per motivare e giustificare la scelta di un approccio GraphRAG strutturato a grafo rispetto ad un RAG puramente testuale su letteratura scientifica.
- **Discussione dei risultati:** per dimostrare come le tre limitazioni architetturali di Berman et al. vengano superate sistematicamente dal design del nostro sistema.

6.7 Loaiza-Bonilla et al. (2026) — OncoMultiAgentKB

Riferimento bibliografico:

Loaiza-Bonilla A, Yost C, Kurnaz S, et al. *Transforming oncology clinical trial matching through neuro-symbolic, multi-agent AI and an oncology-specific knowledge graph: a prospective evaluation in 3,804 patients*. ESMO Real World Data and Digital Oncology. 2026. DOI: 10.1016/j.esmorw.2026.100706.

Descrizione e contesto

Un sistema industriale (sviluppato da Massive Bio) valutato prospetticamente su 3.804 pazienti reali affetti da patologie metastatiche o progressive, su un arco temporale di 12 mesi. L'architettura unisce agenti LLM specializzati (*OncoAgents*) ad un grafo della conoscenza oncologica

(*OncoGraph*) all'interno di un framework neuro-simbolico (in cui agenti probabilistici operano su una logica deterministica di grafo). Il *gold standard* di riferimento è stato generato in modo indipendente da due oncologi (con un coefficiente κ di Cohen pari a 0.92). Il focus primario è il matching paziente-trial clinico.

Architettura del sistema

Il sistema si compone di quattro pilastri:

- **OncoAgents:** agenti LLM specializzati in estrazione di dati clinici, normalizzazione semantica e matching.
- **OncoGraph:** knowledge graph oncologico proprietario con ontologie e tassonomie validate.
- **OncoRecommend:** motore euristico di ordinamento e prioritizzazione.
- **OncoSet:** un corpus di regole cliniche costantemente validato da esperti.

Ha processato complessivamente oltre 157.000 pagine di documentazione clinica (~86.5 milioni di token).

Risultati chiave del paper

- Il sistema ottiene un punteggio $F_1 = 0.8246$ rispetto allo 0.78 registrezza escludendo l'apporto di OncoGraph (ablation study).
- La rimozione del grounding sul grafo riduce drasticamente la precisione e genera allucinazioni nelle citazioni, con conseguente violazione di criteri clinici temporali o quantitativi.
- Collapsare la fase di estrazione e quella di matching all'interno di un unico agente generalista declassa l' F_1 -score da 0.8246 a 0.78.

Contributo chiave e validazione esterna

Rappresenta l'unico sistema in letteratura che adotta un'architettura concettualmente analoga a quella proposta nella tesi: Knowledge Graph oncologico strutturato pre-costruito integrato ad un ecosistema di agenti LLM specializzati.

L'ablation study di Loaiza-Bonilla et al. offre una validazione esterna di enorme rilevanza per i risultati da noi descritti in RQ1: dimostra quantitativamente che la rimozione del grounding su grafo degrada le performance e innesca citazioni allucinate. La tesi traspone questo medesimo principio in ambito accademico e *open-source* (utilizzando modelli open-source eseguiti localmente), espandendolo ad un compito più complesso dal punto di vista dell'interpretazione molecolare (raccomandazioni terapeutiche basate su ESCAT e linee terapeutiche).

Differenze rispetto alla tesi e vantaggi del nostro lavoro

1. **Task:** OncoAgents opera esclusivamente sul matching paziente-trial. La tesi affronta la raccomandazione di terapie matched con annesso livello di evidenza ESCAT e citazioni bibliografiche verificate, richiedendo una sintesi clinica molto più complessa.
2. **Therapy Line:** Il sistema di Massive Bio non integra la linea terapeutica come vincolo logico strutturato. Nella tesi, la `therapy_line` è un input obbligatorio che altera dinamicamente le raccomandazioni del grafo.
3. **Scala vs. Profondità:** OncoAgents analizza 3.804 pazienti su un task specifico (trial). La tesi analizza un benchmark di 30 casi clinici in profondità, con un'interrogazione multi-agente a 5 stadi, classificazione ESCAT per ciascuna evidenza, controllo di sicurezza sulle resistenze e citazioni verificate.

4. **Modello Computazionale:** OncoAgents si appoggia interamente ad API commerciali chiuse e costose (GPT-4/GPT-4o). La tesi dimostra la fattibilità tecnica del medesimo impianto architettuale tramite un modello open-source locale da 31B parametri (Gemma 31B), abbattendo i costi di inferenza e garantendo la riservatezza locale dei dati sanitari del paziente.

Collocazione nel lavoro di tesi

- **Stato dell'Arte:** per descrivere il sistema industriale di riferimento più vicino alla nostra architettura.
- **Motivazione dei Risultati (Discussione):** per citare l'ablation study di Massive Bio al fine di supportare e contestualizzare i risultati di RQ1 (allucinazione dello zero-shot ed efficacia del grounding).
- **Discussione:** per posizionare la tesi come la prima pipeline accademica open-source in grado di replicare (ed espandere) le logiche di un sistema industriale proprietario.

6.8 Sintesi comparativa e posizionamento della tesi

Evoluzione del Posizionamento

Prima dell'integrazione di questi tre lavori, il posizionamento della tesi si articolava su cinque riferimenti privi di un legame esplicito con il dominio specifico dei Molecular Tumor Board (MTB):

- *Edge et al.* (GraphRAG) → Fondamento infrastrutturale del recupero globale.
- *Wu et al.* (MedGraphRAG) → Grounding su grafo in ambito medico generale.
- *Kim et al.* (MDAgents) → Architettura multi-agente adattiva per Q&A medici.
- *Jin et al.* (TrialGPT) → Motore per la sezione di matching dei trial clinici.

L'inclusione delle tre nuove opere colma il gap relativo alla specificità del dominio MTB e della sua validazione:

Tabella 2: Evoluzione del posizionamento della tesi per livelli

Livello	Paper	Funzione
Clinico — definizione	Aldea et al. (IASLC 2025)	ESCAT è lo standard clinico riconosciuto per gli MTB
Tecnico — confronto RAG	Berman et al. (JMIR 2025)	RAG testuale su PubMed ha limiti strutturali che la KB Neo4j risolve
Tecnico — validazione ind.	Loaiza-Bonilla et al. (ESMO 2026)	KB oncologica + multi-agente è l'architettura vincente anche su 3.804 pazienti reali
Contributo originale	Tesi (GraphRAG MTB)	ESCAT tier, therapy_line, resistance checker, open-source su modello gratuito

Narrativa per la Discussione con il Relatore

Il sistema proposto si colloca all’intersezione tra tre tendenze convergenti nella letteratura recente: la validazione clinica dell’uso di ESCAT come standard per le raccomandazioni MTB (Aldea et al., IASLC 2025), la dimostrazione che il RAG testuale su PubMed soffre di limitazioni strutturali nella gestione delle citazioni (Berman et al., JMIR 2025), e la validazione industriale su larga scala che la combinazione KB oncologica strutturata + agenti LLM specializzati riduce le allucinazioni e migliora la precision rispetto al solo LLM (Loaiza-Bonilla et al., ESMO 2026). La tesi contribuisce a questo panorama con una pipeline open-source completa che integra classificazione ESCAT, gestione della linea terapeutica e verifica strutturale delle citazioni — elementi assenti o parziali in tutti e tre i sistemi di riferimento.

La Tabella 3 colloca la pipeline proposta all’interno dello stato dell’arte internazionale recente, evidenziando il controllo strutturato delle allucinazioni tramite il grafo locale Neo4j e la modularità agentica.

Tabella 3: Tabella comparativa completa del posizionamento della tesi

Sistema	Task	KB	Agenti	ESCAT	Therapy Line	Controllo Alluc.	Scala
Berman et al. 2025	MTB recommendation	PubMed RAG testuale	No	No	No	Nessuno strutturale	Casi reali MTB
Loaiza-Bonilla et al. 2026	Trial matching	OncoGraph (KB propr.)	Sì (OncoAgents)	No	No	Grounding su grafo	3.804 pazienti
Ferber et al. 2025	Decision-making	OncoKB + web search	Sì (tool-based)	No	No	Tool grounding	20 casi multimodali
Tesi (GraphRAG MTB)	MTB rec. + trial	Neo4j (CI-ViC+OncoKB)	Sì (5 ag.)	Sì	Sì	CITED_IN verif.	30 casi benchmark

Evidence Grounding — metrica originale della tesi

Per ogni caso benchmark, misura la proporzione di evidenze clinicamente rilevanti presenti nel grafo per quel profilo molecolare (gene + variante + tumore) che il sistema ha effettivamente recuperato e citato nell’output. È calcolabile automaticamente via *set intersection* tra le evidenze nel grafo (query Cypher deterministica) e quelle citate, senza curazione manuale; raffinabile per livello (solo A/B) e per pertinenza tumorale.

Paper	Livello	Focus valutazione
GraphRAG (Edge)	Infrastrutturale	Sensemaking globale, LLM-as-judge
MedGraphRAG (Wu)	Infrastrutturale	Citation precision & recall (clinica)
MDAgents (Kim)	Architetturale	Decision-making su Q&A medici
TrialGPT (Jin)	Applicativo	Risparmio tempo screening, NDCG@10
Tesi	Integrato	Evidence Grounding, LLM-as-judge, sanity check

7 La pipeline agentica (v1 → v3)

7.1 Progettazione iterativa

La pipeline è stata progettata in iterazioni successive. La v1 prevedeva Complexity Check, Variant Interpreter, Target Identifier, Trial Matcher, Interaction Checker, Synthesizer ed Evaluation Layer, ma non sfruttava appieno la ricchezza del KG (i nodi CompanionDiagnostic non interrogati, la relazione ASSOCIATED_GENE non verificata, i nodi Publication non usati per validare le citazioni). La v2 ha esteso la copertura: Target Identifier con traversal di HAS_COMPANION_DIAGNOSTIC, Trial Matcher con verifica di ASSOCIATED_GENE, Synthesizer con verifica dei PMID tramite CITED_IN.


7.2 Una decisione *data-driven*: Resistance Checker

La verifica su Neo4j (23 query Cypher) ha imposto una deviazione motivata rispetto ai piani iniziali.

La relazione INTERACTS_WITH collega geni a farmaci (da DGIdb), non farmaci a farmaci, e i metadati `interaction_types/approved` sono interamente NULL: l'Interaction Checker non era implementabile in modo clinicamente significativo. È stato sostituito dal **Resistance Checker**, che filtra le evidenze per `significance = 'Resistance'` e traversa CITED_IN verso Publication, restituendo evidenze cliniche ricche e referenziate. Questa scelta va esposta in tesi come *decisione basata sui dati*.

7.3 Comportamento per tier di complessità

Il routing dinamico assegna il flusso in base alla complessità stimata del caso.



7.4 Pipeline v3: OncoKB Enricher e input formalizzato

Come visibile nello schema dettagliato (Figura 2), la v3 della pipeline introduce un'orchestrazione avanzata e un OncoKB Enricher integrato:

La v3 introduce tre aggiornamenti: (i) l'**OncoKB Enricher**, nodo opzionale post-report attivato con `enrich_with_oncokb=true` secondo un pattern *human-in-the-loop*; (ii) l'integrazione di DIAGNOSES_GENE nel Trial Matcher (il conteggio delle relazioni mappate sale a 11); (iii) un Complexity Check migliorato che considera `alteration_type`. Lo schema di input clinico è stato formalizzato.

Campo	Tipo	Valori ammessi	Obbl.
gene	string	HUGO symbol (null per biomarker agnostici)	Sì*
variant	string	Protein change, Fusion, MSI-High, TMB-High	Sì
tumor_type	string	Nome tumore o codice OncoTree	Sì
alteration_type	enum	point_mutation fusion cna itd atypical biomarker	Sì
therapy_line	string	first / second / later-line	No
enrich_with_oncokb	bool	true / false (default false)	No

*Il campo `category` del benchmark è escluso dall'input a runtime: è un metadato di classificazione e inserirlo provocherebbe overfitting nella valutazione. Il Complexity Check resta affidato a un LLM flessibile per preservare la generalizzabilità.




Figura 2: Diagramma architetturale della pipeline agentica GraphRAG v3.1

7.5 Verifica delle query Cypher per `alteration_type`

Oltre 15 query Neo4j hanno verificato la fattibilità del Variant Interpreter su tutti e sei i tipi di alterazione. Le point mutation seguono il percorso classico `Gene → Variant → MP → Evidence`; gli altri tipi richiedono ricerca diretta su `MolecularProfile.name` via `CONTAINS`.

Tipo	Casi	Percorso di query / nota
point_mutation	14	Gene → Variant → MP → Evidence (percorso classico)
fusion	6	<code>MolecularProfile.name CONTAINS gene</code> (es. <code>v::ALK Fusion</code>)
atypical	4	<code>MolecularProfile.name CONTAINS 'Exon X'</code>
cna	3	nome contiene gene + “amplif” / “deletion”; 030 è un GAP
itd	1	010 FLT3 ITD: 23 evidenze totali su AML e APL
biomarker	2	“TMB High” / “MSI High” (richiedono mapping verso le API)

1. **Branching obbligatorio** per `alteration_type`: non esiste una query Cypher unica; in LangGraph sarà un conditional edge o un if/else interno.
2. **Priorità ai profili semplici** rispetto ai composti (es. `BCR::ABL1 Fusion AND ABL1 T315I`): match esatto privilegiato, ordinando con `ORDER BY size(mp.name) ASC`.
3. **Dizionario di mapping KB ↔ OncoKB**: il database locale usa “TMB High” / “MSI High”, le API “TMB-H” / “MSI-H”; serve un dizionario di conversione esplicito.

PARTE V

Valutazione e risultati sperimentali

8 Metodologia di valutazione

8.1 Cosa stiamo davvero misurando

Durante lo sviluppo è emerso un dubbio fondamentale: il benchmark con la sola colonna `expected_drug` misura se il sistema “ha individuato il farmaco corretto”, ma questo non è l’obiettivo reale. Un oncologo del MTB non ha bisogno che gli si suggerisca “somministra Osimertinib”: conosce già la scelta standard. Il valore aggiunto è nella *giustificazione strutturata, completa e referenziata*.

Output povero

“Raccomandazione: Osimertinib” (mero esercizio di classificazione)

Output utile

“Osimertinib, evidenza A in CIViC per EGFR L858R in NSCLC; evidenze B per Erlotinib e Gefitinib; resistenza acquisita T790M (su cui Osimertinib resta attivo); 3 trial aperti, uno in fase III; evidenza primaria FLAURA, PMID 29151359.”

8.2 Valutazione a due livelli

Si mantiene il benchmark dei 30 casi come ancora quantitativa (*Drug Anchor*: Top-1/Top-3 accuracy) e vi si affianca una rubrica qualitativa semi-automatica applicata con LLM-as-judge. Il confronto isola il contributo del KG mettendo a paragone tre configurazioni: (A) LLM zero-shot, (B) RAG vanilla su testo, (C) GraphRAG agentic.

8.3 La rubrica LLM-as-judge ricalibrata

La rubrica iniziale a 5 criteri conteneva un criterio “struttura” che restituiva sistematicamente 5.0 (il Synthesizer impone una formattazione fissa), gonfiando in modo fittizio la media. È stata rimossa e i criteri ridefiniti a 4, ancorati alla letteratura.

Criterio	Ispirazione	Descrizione
Completezza	Edge et al., 2025	Copre variante, terapia, resistenze e trial?
Utilità clinica	Edge et al., 2025	Immediata usabilità al board (assorbe leggibilità/struttura)
Fedeltà evidenze	Wu et al., 2024	I PMID citati sono nel KG e pertinenti?
Accuratezza clinica	Criterio originale	Precisione di farmaci, CDx e tiering ESCAT

8.4 La gerarchia delle metriche

Le metriche sono organizzate per importanza e originalità: (1) **Evidence Grounding** [metrica originale]; (2) **LLM-as-judge** su Comprehensiveness/Diversity/Actionability [ispirato a Edge]; (3) **Drug Anchor + Primary Citation** [sanity check]; (4) **metriche Trial Matcher** (NDCG@10, P@10, AUROC) [ispirato a Jin].


9 Risultati sperimentali

9.1 Confronto Caso per Caso: I 30 Benchmark

La Tabella 4 riporta l’esecuzione integrale della pipeline valutativa sui 30 casi clinici estratti da OncoKB.

9.2 Benchmark ricalcolato (v2)

Sui 30 casi, lo score medio resta **3.96/5.0** (stabile rispetto alla v1): la rimozione del bias “struttura” ha allineato la valutazione a criteri più severi, e la stabilità dimostra la robustezza del sistema. La scomposizione per criterio:



Il divario tra la fedeltà delle fonti (4.48) e l’utilità clinica pratica (3.59) mostra che, sebbene la base dati strutturata garantisca il rigore bibliografico, la *traduzione automatica* delle evidenze grezze in indicazioni operative è lo snodo critico dell’ingegneria dei sistemi GraphRAG in ambito medico.

9.3 OncoKB Enricher sui casi critici

I tre casi con score inferiore a 3.0 sono stati rieseguiti abilitando l’arricchimento live.

Tabella 4: Confronto Caso per Caso: GraphRAG vs Zero-Shot (Giudice: MiniMax-M2.5)

ID	Gene/Variante	Tumore	Categoria	GR	ZS	Δ (GR-ZS)
BENCH-001	EGFR L858R	NSCLC	baseline	4.00	4.25	-0.25
BENCH-002	ALK Fusion	NSCLC	baseline	4.12	4.40	-0.28
BENCH-003	BRAF V600E	Melanoma	baseline	4.25	3.12	+1.12
BENCH-004	ERBB2 Amplification	Breast Cancer HER2+	baseline	4.38	4.12	+0.26
BENCH-005	BRCA1 Mutation	Ovarian Cancer	baseline	3.12	4.12	-1.00
BENCH-006	ABL1 BCR-ABL1 Fusion	CML	baseline	3.38	3.88	-0.50
BENCH-007	BRAF V600E	Colorectal Cancer	baseline	3.75	3.88	-0.12
BENCH-008	PIK3CA Mutation	Breast Cancer HR+	baseline	4.25	4.25	+0.00
BENCH-009	KIT Exon 11 Mutation	GIST	baseline	2.88	3.25	-0.38
BENCH-010	FLT3 ITD	AML	baseline	3.25	3.88	-0.62
BENCH-011	EGFR T790M	NSCLC	resistance	3.88	4.12	-0.25
BENCH-012	KRAS G12C	NSCLC	new_target	3.25	4.38	-1.12
BENCH-013	ALK G1202R	NSCLC	resistance	1.62	3.40	-1.77
BENCH-014	ABL1 T315I	CML	resistance	4.50	4.62	-0.12
BENCH-015	RET Fusion	NSCLC	new_target	4.25	3.50	+0.75
BENCH-016	NTRK1 Fusion	Solid Tumor	tumor_agnostic	4.38	4.50	-0.12
BENCH-017	MMR MSI-High	Colorectal Cancer	biomarker	3.25	4.62	-1.38
BENCH-018	KRAS G12C	Colorectal Cancer	new_target	3.25	4.50	-1.25
BENCH-019	KIT Exon 9 Mutation	GIST	resistance	4.38	3.50	+0.88
BENCH-020	BRAF V600E	NSCLC	off_label	3.25	3.75	-0.50
BENCH-021	ERBB2 Amplification	Gastric Cancer	off_label	3.88	3.38	+0.50
BENCH-022	BRCA2 Mutation	Prostate Cancer	off_label	3.50	3.75	-0.25
BENCH-023	TMB TMB-High	Solid Tumor	tumor_agnostic	3.88	3.75	+0.12
BENCH-024	EGFR Exon 19 Deletion	NSCLC	baseline	3.62	3.38	+0.25
BENCH-025	IDH1 R132	AML	new_target	1.62	3.88	-2.25
BENCH-026	FGFR2 Fusion	Cholangiocarcinoma	new_target	4.25	3.62	+0.62
BENCH-027	MET Exon 14 Skipping	NSCLC	new_target	3.38	3.00	+0.38
BENCH-028	ROS1 Fusion	NSCLC	new_target	4.12	4.00	+0.12
BENCH-029	BRAF V600E	Thyroid Cancer	off_label	4.00	4.25	-0.25
BENCH-030	ERBB2 Amplification	Gastric Cancer	new_target	4.62	4.50	+0.12

Caso	Profilo	Base	Arricch.	Δ	Esito
013	ALK G1202R / NSCLC	1.25	4.60	+3.35	GAP risolto
018	KRAS G12C / CRC	2.75	4.25	+1.50	Errore corretto
027	MET Exon 14 / NSCLC	2.88	2.88	+0.00	Limite arch.

018 è particolarmente istruttivo: il sistema base raccomandava Cetuximab in monoterapia per un CRC KRAS G12C, clinicamente *controindicato* (KRAS è biomarcatore di resistenza agli anti-EGFR). L'Enricher ha fornito le evidenze `LEVEL_1` per Sotorasib e Adagrasib. Il caso 027 mostra il limite dell'arricchimento *additivo*: non corregge errori citazionali preesistenti nel database locale.

9.4 RQ1: GraphRAG vs Zero-shot e il bias del giudice

La prima run usava Gemma come giudice — lo stesso modello dello zero-shot vanilla — producendo un vistoso bias di auto-valutazione (delta apparente -0.722 a favore dello zero-shot). Ripetendo con un giudice indipendente (MiniMax M2.5) il gap si riduce di $2.7\times$ (delta reale -0.264). È un'evidenza empirica di rilievo sui limiti dell'LLM-as-judge, che è stato di conseguenza retrocesso a metrica secondaria a favore delle metriche oggettive.

9.5 Allucinazione bibliografica dello zero-shot

Tutti i PMID citati nei 30 report zero-shot sono stati verificati contro PubMed/NCBI E-utilities.

Tasso di allucinazione clinica bibliografica: 100% (115/115 PMID). Il 96.52% dei codici esiste su PubMed ma tratta argomenti del tutto scorrelati (dall'istruzione superiore alle emulsioni stabilizzate); solo il 3.48% è del tutto inventato. I PMID dello zero-shot sono "token decorativi" privi di valore referenziale.

A titolo di esempio citabile in tesi: per 001 (EGFR L858R / NSCLC) lo zero-shot cita il PMID 29703322, il cui titolo reale è *"Disruptive trends in higher education: Leadership skills for successful leaders"*.


9.6 Retrieval Pollution e mitigazione

Il *retrieval pollution* si verifica quando le informazioni generali di gene (es. sensibilità di EGFR L858R a Erlotinib) inquinano il contesto per varianti specifiche di resistenza (es. EGFR T790M). La v3.1 introduce nel `resistance_checker.py` un filtro variante-specifico (`CYPHER_EXCLUDE_DRUGS`) che esclude preventivamente i farmaci inquinanti. Il Safety Pass Rate automatico sale da 86.7% a 90.0%; la safety clinica reale, al netto dei falsi negativi della regex, è del 96.7%.

I due falsi negativi (013, 014) menzionano i farmaci controindicati *solo* nella descrizione del profilo di resistenza (contesto informativo) e non come raccomandazione attiva — comportamento clinicamente corretto che il check string-matching non distingue.

9.7 Confronto a tre vie finale

Il confronto oggettivo sull'intero benchmark sintetizza il profilo di rischio opposto dei due approcci.



- Verificabilità (0% vs 100%):** lo zero-shot fornisce risposte corrette per memoria parametrica ma allucina i PMID; solo GraphRAG + Enricher garantisce tracciabilità totale.
- Retrieval pollution (safety 86.7% vs 96.7%):** il recupero a livello di gene immette farmaci storici non più indicati per varianti di resistenza; lo zero-shot, privo di questo rumore, non compie l'errore. Un finding non banale.
- Bias del benchmark:** il Therapeutic Match perfetto dello zero-shot (1.000) rivela che i casi sono ad alta ricorrenza in letteratura, facilitando la memoria parametrica.

Metriche oggettive definitive (post-fix ESCAT): **Drug Anchor Check** 96.7% (29/30) per entrambi i sistemi; **PMID Coverage Rate** 60.0% per GraphRAG (0% zero-shot); **ESCAT Tier Match** 100.0% (vs 0%); **PMID Hallucination Rate** 0.0% per GraphRAG (vs 100.0% dello zero-shot).

9.8 Ottimizzazione strutturale dell'ESCAT Interpreter

La prima iterazione dell'ESCAT Interpreter usava una mappatura statica dei livelli di evidenza ($A \rightarrow I-A$, $B \rightarrow II-B$) che produceva errori sistematici, fermando lo score al 73.3%. Il problema di fondo era l'assenza di confronto tra l'istologia dell'evidenza e quella del paziente (condizione necessaria secondo le linee guida ESMO). Per questo è stato implementato un *fix* a tre livelli:

- Fuzzy Matching Istologico:** introduzione della funzione `_is_same_tumor()` per verificare le inclusioni semantiche tra il campo `disease` del grafo e l'input del paziente.
- Fallback Contestuale:** abbandono della mappa statica. Se l'istologia differisce, l'evidenza viene degradata automaticamente per via del contesto *off-label* (da A/B a $II-B$); se l'evidenza ha `significance = Resistance`, viene declassata e mai associata a Tier predittivi di efficacia.
- Prompt Iniection:** inserimento del flag booleano `Match istologico: SI/NO` per ciascuna evidenza direttamente nel prompt del generatore.

Questi interventi correttivi hanno eliminato gli errori per le varianti tumor-agnostic e di resistenza, portando la *Tier Match accuracy* al 100.0% sui 30 casi del benchmark.

9.9 Analisi Casi Drug Anchor Check — Finding Narrativo Chiave

Sebbene il Drug Anchor Check sia identico per entrambi i sistemi (96.7%, 29/30 casi), gli errori sono **diversi e asimmetrici**, illustrando il rischio clinico dell'approccio zero-shot:

- BENCH-004 (GraphRAG sbaglia, Zero-Shot indovina):** ERBB2 Amplificazione nel tumore al seno. GraphRAG non restituisce la combinazione attesa (Trastuzumab + Pertuzumab)

per un errore tecnico: mancava il nodo della combinazione nella KB (identificato come bug e risolto). Lo Zero-Shot indovina grazie alla memoria parametrica su un protocollo storico consolidato.

- **BENCH-018 (Zero-Shot sbaglia, GraphRAG indovina):** KRAS G12C nel tumore del Colon-Retto. Questo caso illustra esattamente il rischio clinico del LLM *vanilla* in oncologia di precisione. Lo Zero-Shot raccomanda Sotorasib in monoterapia, che è lo standard per il carcinoma polmonare (NSCLC), ignorando totalmente che nel colon-retto l'inibizione di KRAS G12C causa una riattivazione del feedback mediato da EGFR. Questo rende obbligatorio associare un anti-EGFR (es. Panitumumab), approvazione FDA agosto 2023 basata sul trial CodeBreak 300 (NEJM 2023). Un medico che usasse lo zero-shot riceverebbe una raccomandazione clinicamente pericolosa. GraphRAG, basandosi sulle relazioni strutturate del Knowledge Graph che codificano la specificità istologica, fornisce la raccomandazione corretta, dimostrandosi immune al bias statistico dei dati di training.

Il caso 018 mostra il limite clinico dello zero-shot: il bias da distribuzione dei dati di training sovrascrive le specificità istologiche, portando a raccomandazioni potenzialmente pericolose.

9.10 Lettura Corretta dei Risultati (LLM-as-judge)

I risultati qualitativi con LLM-as-judge sembrano premiare lo zero-shot (Score totale 3.92 vs 3.72 di GraphRAG), ma questo rivela un vistoso *fluency bias*. Lo zero-shot ottiene 4.13 in “Fedeltà alle Evidenze” pur avendo un tasso di allucinazione dei PMID del 100%: il giudice LLM valuta la fluidità percepita del testo, non la correttezza fattuale delle fonti. Sulle metriche oggettive e verificabili, GraphRAG domina nettamente.

10 Considerazioni etiche e limiti

- Il sistema è un *decision support*, non un decision maker: le raccomandazioni vanno discusse in sede di MTB con giudizio clinico umano.
- Non è un dispositivo medico ai sensi della normativa MDR/IVDR; non si pone l'obiettivo della certificazione regolatoria in fase di tesi.
- OncoKB: i termini di servizio vietano l'uso dei dati per il training di modelli; il progetto usa il dump statico per il KG offline e chiamate API live solo a runtime su attivazione esplicita.
- I database curati sono *lagging indicators*: di qui l'integrazione live (ClinicalTrials.gov, OncoKB).
- Bias di rappresentazione (genomica dominata da popolazioni occidentali) e long-tail variants con evidenze deboli: il sistema deve segnalarlo esplicitamente.
- L'uso su dati di pazienti reali richiederebbe approvazione del Comitato Etico e gestione GDPR.

11 Conclusioni e lavori futuri

La narrazione del progetto si colloca all'intersezione tra tre tendenze convergenti: la validazione clinica dell'uso di ESCAT come standard MTB (Aldea et al., IASLC 2025), la dimostrazione che il RAG testuale soffra di limitazioni strutturali nella gestione delle citazioni (Berman et al., JMIR 2025), e la validazione industriale su larga scala che la KB oncologica strutturata + agenti LLM specializzati riduca enormemente le allucinazioni rispetto al solo LLM (Loaiza-Bonilla et al., ESMO 2026). Questa tesi contribuisce con una pipeline open-source completa che integra la classificazione ESCAT contestuale e la verifica strutturale delle citazioni — elementi assenti o solo parziali in tutti e tre i sistemi di riferimento.

Il lavoro ha portato il progetto dalla sola infrastruttura a un sistema agentico valutato. La narrativa della tesi si struttura attorno a quattro *finding* originali.

I quattro pilastri della tesi

1. **Allucinazione bibliografica sistematica (100%)** dello zero-shot: la verificabilità delle fonti è l'unico requisito non negoziabile in clinica.
2. **Retrieval pollution clinico**: i sistemi RAG, se interpellati a livello di gene, inquinano il contesto con farmaci non efficaci per varianti resistenti.
3. **Enricher live come knowledge fall-back**: l'integrazione ibrida risolve i gap strutturali locali garantendo il grounding.
4. **Safety automatica vs safety reale**: dimostrazione quantitativa del limite delle metriche string-matching nella valutazione della sicurezza clinica.

Prossimi passi. (i) Misurare il tasso di allucinazione bibliografica dello zero-shot anche via verifica PubMed sistematica; (ii) raffinare il Resistance Checker con regole di filtraggio rigido per scartare i farmaci storici controindicati; (iii) sviluppare un classificatore semantico per il Safety Check che isoli le menzioni informative dai falsi negativi delle regex; (iv) consolidare il "Clinical Correctness Score" ($TM \times EG \times Safety$) come metrica oggettiva primaria; (v) redigere la sezione metodologica della tesi descrivendo i 4 criteri e la base scientifica associata.

Fine del report — sintesi del lavoro dal 29 maggio all'8 giugno 2026

12 Glossario e acronimi

Di seguito si riporta il glossario completo dei termini scientifici, degli acronimi medici, dei geni bersaglio e delle sigle oncologiche utilizzate nel report e nelle valutazioni del benchmark.

ABL1

ABL Proto-Oncogene 1, Non-Receptor Tyrosine Kinase. Gene coinvolto nella fusione BCR::ABL1, target primario dell'imatinib nella leucemia mieloide cronica.

ALK

ALK Receptor Tyrosine Kinase (Chinasi del Linfoma Anaplastico). Oncogene coinvolto in fusioni patogenetiche e varianti di resistenza secondarie (es. G1202R) nel tumore al polmone.

AML

Acute Myeloid Leukemia (Leucemia Mieloide Acuta). Neoplasia del sistema emopoietico ad alta aggressività, analizzata nel benchmark su target quali FLT3 (ITD) e IDH1 (R132).

AMP/ASCO/CAP

Linee guida congiunte delle principali società di patologia molecolare e oncologia americane (*Association for Molecular Pathology, American Society of Clinical Oncology, College of American Pathologists*) per la classificazione clinica delle alterazioni genomiche nei tumori solidi.

API

Application Programming Interface (Interfaccia di Programmazione delle Applicazioni). Canale di connessione software usato a runtime per interrogare live i registri OncoKB e ClinicalTrials.gov.

atypical

Classe di alterazione utilizzata nel benchmark (*alteration_type*) per identificare varianti molecolari complesse che non corrispondono a singole mutazioni puntiformi ma coinvolgono interi esoni o domini (es. mutazioni degli esoni 9 o 11 di KIT, skipping dell'esone 14 di MET).

biomarker

Classe di alterazione utilizzata nel benchmark (*alteration_type*) per identificare marcatori biologici o quantitativi indipendenti da un singolo gene specifico, che descrivono invece profili genomici complessi o sistemici (es. TMB-High o MSI-High).

BRAF

B-Raf Proto-Oncogene, Serine/Threonine Kinase. Oncogene della via MAPK; la mutazione V600E è un target d'elezione nel melanoma e nel colon-retto.

BRCA1 / BRCA2

Geni oncosoppressori (*Breast Cancer gene 1/2*) responsabili del meccanismo di riparazione del DNA per ricombinazione omologa; bersagli ideali degli inibitori di PARP (es. Olaparib).

CDx

Companion Diagnostic (Diagnostica d'accompagnamento). Test in vitro approvato congiuntamente ad un farmaco specifico al fine di identificare i pazienti idonei alla terapia.

CGI

Conoscenza Gap Index. Metrica normalizzata formulata in tesi per misurare la discrepanza informativa tra le interazioni molecolari di DGIdb e le evidenze cliniche di CIViC.

CIViC

Clinical Interpretation of Variants in Cancer. Database pubblico, collaborativo e curato da esperti per l'interpretazione clinica delle varianti somatiche nel cancro.

CML

Chronic Myeloid Leukemia (Leucemia Mieloide Cronica). Disordine mieloproliferativo caratterizzato dal cromosoma Philadelphia (BCR::ABL1), trattato con inibitori di tirosin-chinasi.

CNA

Copy Number Alteration (Alterazione del Numero di Copie). Aberrazione genomica che determina l'amplificazione o la delezione di porzioni cromosomiche. Rappresenta anche una classe di alterazione nel benchmark (*alteration_type*), come l'amplificazione di ERBB2.

CRC

Colorectal Cancer (Carcinoma del Colon-Retto). Neoplasia intestinale analizzata nel benchmark in relazione a mutazioni di KRAS (G12C), BRAF (V600E) e instabilità microsatellitare.

CYPHER

Linguaggio dichiarativo di interrogazione proprietario del database a grafo Neo4j, usato in tesi per navigare le relazioni molecolari del Knowledge Graph.

DGIdb

Drug-Gene Interaction Database. Risorsa pubblica ad accesso aperto che raccoglie e normalizza le interazioni note tra farmaci e geni da letteratura e database.

DOID

Disease Ontology Identifier. Identificativo controllato e univoco per l'ontologia delle malattie umane, usato per la normalizzazione dei nodi Disease.

EGFR

Epidermal Growth Factor Receptor (Recettore del Fattore di Crescita Epidermico). Recettore tirosin-chinasico sovraespresso o mutato nel tumore del polmone non a piccole cellule.

ERBB2

Erb-B2 Receptor Tyrosine Kinase 2 (noto anche come HER2). Target amplificato in tumori mammari e gastrici, bersaglio di anticorpi monoclonali (Trastuzumab, Pertuzumab).

ESCAT

ESMO Scale for Clinical Actionability of molecular Targets. Scala standardizzata di classificazione

dell'azionabilità clinica dei target genomici in base alle evidenze scientifiche.

ESMO

European Society for Medical Oncology (Società Europea di Oncologia Medica). Associazione professionale di riferimento per lo sviluppo di linee guida cliniche in Europa.

ETL

Extract, Transform, Load (Estrazione, Trasformazione, Caricamento). Pipeline software per l'ingestion ed il consolidamento dei database biologici all'interno di Neo4j.

FDA

Food and Drug Administration. Agenzia governativa statunitense per la regolamentazione di prodotti alimentari, farmaceutici e dispositivi medici diagnostici.

FGFR2

Fibroblast Growth Factor Receptor 2. Recettore tirosin-chinasico; le sue fusioni rappresentano un target terapeutico recente nel colangiocarcinoma.

FLT3

Fms Related Receptor Tyrosine Kinase 3. Recettore tirosin-chinasico espresso in cellule emopoietiche progenitorie; mutazioni come l'ITD guidano la terapia mirata in AML.

fusion

Classe di alterazione utilizzata nel benchmark (`alteration_type`) per identificare fusioni geniche derivanti da riarrangiamenti strutturali cromosomici che uniscono porzioni di due geni distinti (es. fusioni di ALK, ROS1, RET o NTRK1).

GDPR

General Data Protection Regulation. Regolamento generale europeo sulla protezione dei dati, stringente vincolo etico per l'eventuale implementazione clinica con dati reali dei pazienti.

GIST

Gastrointestinal Stromal Tumor (Tumore Stromale Gastrointestinale). Neoplasia mesenchimale del tratto gastrointestinale legata a mutazioni attivanti dei geni KIT o PDGFRA.

GraphRAG

Evoluzione del paradigma RAG che utilizza database a grafo per contestualizzare la generazione di testo da parte di modelli LLM attraverso percorsi semantici strutturati.

HHI

Herfindahl-Hirschman Index. Indice di concentrazione economica, riadattato in tesi per valutare quantitativamente il curation bias (squilibrio editoriale) sui geni della KB.

HRD

Homologous Recombination Deficiency (Deficienza della Ricombinazione Omologa). Biomarcatore molecolare indicante il deficit di riparazione del DNA per ricombinazione omologa, bersaglio clinico degli inibitori di PARP.

IDH1

Isocitrate Dehydrogenase 1 (Isocitrato Deidrogenasi 1). Enzima mutato nel citoplasma di cellule leucemiche in AML (variante R132), bersaglio dell'ivosidenib.

ITD

Internal Tandem Duplication (Duplicazione Interna in Tandem). Aberrazione strutturale con duplicazione ripetuta in sequenza, tipica e prognostica del gene FLT3 in AML. Rappresenta anche una classe di alterazione nel benchmark (`alteration_type`), es. FLT3-ITD.

KG

Knowledge Graph (Grafo della Conoscenza). Rete di entità collegate da relazioni tipizzate, impiegata per memorizzare la conoscenza clinica oncologica in Neo4j.

KIT

KIT Proto-Oncogene, Receptor Tyrosine Kinase. Recettore tirosin-chinasico associato all'oncogenesi dei GIST (es. mutazioni dell'esone 9 o 11).

KRAS

KRAS Proto-Oncogene, GTPase. Oncogene centrale della via RAS/MAPK, storicamente ritenuto non targettabile e recentemente aggredito (es. mutazione G12C in NSCLC e CRC).

LLM

Large Language Model. Modelli linguistici artificiali addestrati su enormi dataset testuali per comprendere, sintetizzare e generare linguaggio naturale o semi-strutturato.

MDR/IVDR

Regolamenti dell'Unione Europea per i dispositivi medici (*Medical Device Regulation*) e diagnostici in vitro (*In Vitro Diagnostic Regulation*) per la marcatura CE dei sistemi software di supporto clinico.

MET

MET Proto-Oncogene, Receptor Tyrosine Kinase. Recettore tirosin-chinasico; alterazioni di skipping dell'esone 14 guidano terapie con inibitori specifici (es. Capmatinib).

MMR

Mismatch Repair (Riparazione del Disallineamento). Meccanismo cellulare di correzione degli errori di replicazione del DNA; la sua deficienza porta allo stato MSI-High.

MSI-High / MSI-H

Microsatellite Instability High (Instabilità Microsatellitare Elevata). Biomarcatore tumor-agnostico indicativo di elevata immunogenicità, bersaglio dell'immunoterapia (Pembrolizumab).

MTB

Molecular Tumor Board. Comitato oncologico multidisciplinare incaricato di analizzare i profili genomici complessi dei pazienti per formulare raccomandazioni terapeutiche personalizzate.

NCT ID

National Clinical Trial Identifier. Identificativo alfanumerico univoco (es. NCT00000000) assegnato a ciascun protocollo di sperimentazione clinica registrato su ClinicalTrials.gov.

NGS

Next-Generation Sequencing (Sequenziamento di Nuova Generazione). Tecnologia per il sequenziamento parallelo massivo degli acidi nucleici, sorgente primaria dei profili molecolari clinici.

NSCLC

Non-Small-Cell Lung Cancer (Carcinoma Polmonare Non a Piccole Cellule). La principale tipologia di tumore polmonare, fortemente caratterizzata da alterazioni molecolari targettabili (EGFR, ALK, ROS1, RET, KRAS).

NTRK1 / NTRK2 / NTRK3

Geni recettoriali di neurotrofine. Le loro fusioni strutturali rappresentano uno dei primi biomarker interamente tumor-agnostico approvati FDA per terapie con larotrectinib.

OncoKB

Oncology Knowledge Base. Database MSKCC contenente informazioni cliniche curate per l'effetto biologico e l'azionabilità clinica di alterazioni tumorali somatiche.

PIK3CA

Phosphatidylinositol-4,5-Bisphosphate 3-Kinase Catalytic Subunit Alpha. Gene della subunità catalitica della chinasi PI3K, target primario nel carcinoma mammario HR+.

PMID

PubMed Identifier. Codice numerico univoco assegnato a ciascun articolo della letteratura biomedica indicizzato su MEDLINE/PubMed, utilizzato per calcolare l'Evidence Grounding.

point_mutation

Classe di alterazione utilizzata nel benchmark (*alteration_type*) per indicare mutazioni puntiformi, ovvero variazioni di un singolo nucleotide che comportano la sostituzione di un

singolo amminoacido nella proteina risultante (es. EGFR L858R, BRAF V600E).

RAG

Retrieval-Augmented Generation. Tecnica che unisce modelli linguistici generativi a sistemi di recupero informativo esterni per ridurre allucinazioni e incrementare la fattualità.

RET

RET Proto-Oncogene. Recettore tirosin-chinasico; le sue fusioni molecolari o mutazioni guidano terapie mirate con selpercatinib e pralsetinib.

ROS1

ROS1 Proto-Oncogene, Receptor Tyrosine Kinase. Oncogene chinasi; fusioni oncogeniche guidano sensibilità a inibitori TKI quali crizotinib ed entrectinib.

TMB-High / TMB-H

Tumor Mutational Burden High (Carico Mutazionale Elevato). Biomarcatore tumor-agnostico che quantifica le mutazioni somatiche per megabase di DNA sequenziato; indicatore di risposta all'immunoterapia.

VHL

Von Hippel-Lindau Tumor Suppressor. Gene oncosoppressore coinvolto nella degradazione di HIF-1. È il gene a massima densità di evidenza scientifica clinica nella KB.

Riferimenti bibliografici principali

Edge et al. (2025)

From Local to Global: A GraphRAG Approach to Query-Focused Summarization. Microsoft Research, arXiv:2404.16130v2.

Wu et al. (2024)

Medical Graph RAG: Towards Safe Medical Large Language Model via Graph Retrieval-Augmented Generation. Oxford / CMU / Edinburgh, arXiv:2408.04187v2.

Kim et al. (2024)

MDAgents: An Adaptive Collaboration of LLMs for Medical Decision-Making. MIT / Google Research / Seoul National University, NeurIPS 2024.

Jin et al. (2024)

Matching Patients to Clinical Trials with Large Language Models (TrialGPT). NIH/NCBI — NCI — University of Pittsburgh, Nature Communications 15:9074.

Aldea et al. (2025)

IASLC Consensus Statement on Molecular Tumor Boards. J Thorac Oncol. 2025;20:1594–1614.

Berman et al. (2025)

RAG_MTB: Retrieval-Augmented Generation for MTB. JMIR Med Inform. 2025. PMID: 40053768.

Loaiza-Bonilla et al. (2026)

OncoMultiAgentKB: A Neuro-Symbolic System. ESMO Real World Data and Digital Oncology. 2026.