

Capitolo 1

Baseline denso biomedico: encoder o retrieval?

1.1 La domanda

Nel confronto principale il **RAG denso** è la configurazione più debole: la recall dei fatti-gold cresce da 0,14 (con 100 parole di contesto) a soli 0,39 (con 2.400 parole), sempre molto al di sotto del retrieval lessicale e lontanissima dal tetto del GraphRAG (1,00). Prima di concludere che «il retrieval denso non funziona su questa base di conoscenza» occorre isolare la causa. Il divario nasce dall'**encoder** — `all-MiniLM-L6-v2`, addestrato su testo generico, privo di vocabolario biomedico — oppure è un limite **strutturale** del dense retrieval su un corpus fatto di fatti brevi e nomi propri (geni, farmaci, varianti)?

Per rispondere ho sostituito l'encoder generico con encoder di **dominio biomedico**, mantenendo identica la metrica — recall dei fatti-gold nel contesto assemblato, deterministica e offline — e lo stesso sweep di budget dello studio di efficienza di contesto.

1.2 Sistemi confrontati

Il disegno sperimentale separa due contributi spesso confusi: il *pre-training di dominio* (esporre l'encoder a testo biomedico) e il *fine-tuning per il retrieval* (addestrarlo a rendere vicine coppie domanda-passaggio rilevanti). Per questo confronto due encoder biomedici, uno per ciascun contributo:

Sistema	Encoder	Natura
RAG denso (all-MiniLM)	<code>all-MiniLM-L6-v2</code> (384)	generico, retrieval-tuned
RAG denso (PubMedBERT grezzo)	BiomedBERT (768, mean-pool)	solo pre-training di dominio
RAG denso (PubMedBERT-MS)	<code>S-PubMedBert-MS-MARCO</code> (768)	dominio + fine-tuning retrieval

Tabella 1.1: I tre encoder densi a confronto. Il PubMedBERT grezzo (masked-LM con mean-pooling) isola l'effetto del solo dominio; `S-PubMedBert-MS-MARCO` aggiunge il fine-tuning contrastivo su MS-MARCO.

Riferimenti già misurati nello sweep: GraphRAG (1,00 piatto), BM25 e ibrido.

1.3 Risultati

Sistema	100 parole	900 parole	2.400 parole
GraphRAG	1,000	1,000	1,000
RAG BM25	0,541	0,835	0,934
RAG ibrido	0,563	0,825	0,889
RAG denso (PubMedBERT-MS)	0,369	0,639	0,764
RAG denso (all-MiniLM)	0,139	0,293	0,390
RAG denso (PubMedBERT grezzo)	0,017	0,144	0,244

Tabella 1.2: Recall dei fatti-gold nel contesto a tre budget rappresentativi.

Sistema	$\geq 60\%$	$\geq 70\%$	$\geq 80\%$
GraphRAG	36	36	36
RAG BM25	144	251	575
RAG ibrido	112	226	690
RAG denso (PubMedBERT-MS)	669	1.543	mai
RAG denso (all-MiniLM)	mai	mai	mai
RAG denso (PubMedBERT grezzo)	mai	mai	mai

Tabella 1.3: Parole di contesto necessarie per raggiungere una soglia di recall. «mai» indica che la soglia non viene raggiunta neppure a 2.400 parole.




Figura 1.1: (a) Recall dei fatti-gold in funzione delle parole di contesto (scala logaritmica): l'encoder biomedico retrieval-tuned (verde) si stacca nettamente dal generico (grigio), mentre il PubMedBERT grezzo (tratteggiato viola) resta il più basso. (b) Recall a budget 900 parole: il salto da PubMedBERT grezzo (0,144) a PubMedBERT-MS (0,639) misura l'effetto del solo fine-tuning per il retrieval.

1.4 Tre conclusioni

1. L’encoder biomedico recupera gran parte del divario — ma non tutto. Passando da all-MiniLM a S-PubMedBert-MS-MARCO la recall a budget 900 più che raddoppia: 0,293 → 0,639. Il denso biomedico supera le soglie del 60 % (a 669 parole) e del 70 % (a 1.543 parole), che l’encoder generico non raggiunge *mai*. Il divario del RAG denso era dunque in larga parte un **artefatto dell’encoder**, non un limite assoluto del metodo.

2. Non è il vocabolario biomedico a contare, ma il fine-tuning per il retrieval. Il controllo decisivo è il PubMedBERT **grezzo**: solo masked-LM su testo biomedico, mean-pooling, nessun obiettivo contrastivo. La sua recall a budget 900 è 0,144, **peggiore** persino dell’encoder generico (0,293). Il pre-training di dominio da solo produce embedding inadatti al retrieval; è il fine-tuning su coppie domanda-passaggio (MS-MARCO) a spostare la recall da 0,144 a 0,639. Per il retrieval conta **come** l’encoder è stato addestrato, non solo **su quale** dominio.

3. Anche il miglior encoder denso resta sotto il lessicale e lontano dal grafo. A budget 900 il denso biomedico (0,639) non raggiunge né BM25 (0,835) né l’ibrido (0,825); e anche a 2.400 parole (0,764) non tocca il tetto del grafo (1,00), che il GraphRAG raggiunge con 36 parole. Su una base di conoscenza fatta di nomi propri e fatti brevi — dove conta la corrispondenza esatta di un simbolo genico o di un nome di farmaco — il retrieval lessicale e quello strutturato del grafo restano più adatti della similarità densa, per quanto specializzata.

1.5 Implicazione per la tesi

Questo esperimento chiude una possibile obiezione al confronto principale («il RAG denso perde solo perché usa un encoder generico»). La risposta è articolata: un encoder biomedico *retrieval-tuned* recupera buona parte del divario e va adottato come baseline denso corretto; tuttavia neppure quel sistema raggiunge la recall del retrieval lessicale, né la compattezza e la completezza del GraphRAG. Il vantaggio del grafo — recall 1,00 con 36 parole di contesto — non è replicabile aumentando la dimensionalità o la specializzazione dell’encoder denso, perché deriva dal **modo** in cui i fatti sono collegati, non dalla loro rappresentazione vettoriale.