

Risultati Sperimentali

*GraphRAG per il Molecular Tumor Board:
confronto, robustezza, sicurezza e limiti*

Documento unificato degli esperimenti

Indice

1	Un confronto sperimentale: GraphRAG contro RAG testuale	3
1.1	Che cosa volevo verificare	3
1.2	I materiali	3
1.2.1	La knowledge base	3
1.2.2	Il testo per il RAG	3
1.3	Il banco di prova (benchmark)	4
1.4	I sistemi a confronto e le regole del gioco	4
1.5	I risultati	5
1.5.1	Accuratezza complessiva	5
1.5.2	Come cambia la cosa al crescere degli hop	5
1.5.3	È un caso? No	6
1.5.4	Perché il RAG fallisce	6
1.5.5	Meno contesto, non di più	7
1.6	Il vantaggio non dipende dal modello lettore	8
1.7	Robustezza al linguaggio: e se la domanda è riformulata?	8
1.7.1	Prima sorpresa: il router a parole chiave è fragile	9
1.7.2	La correzione: un router semantico	9
1.8	Sicurezza clinica: sa dire “non lo so”?	10
1.8.1	Un guardrail fail-safe	11
1.9	Limiti, detti con franchezza	12
1.10	Che cosa significa per il Molecular Tumor Board	13
1.11	Riproducibilità	13
2	La frontiera dell’automazione nel Molecular Tumor Board	14
2.1	La domanda	14
2.2	Il workflow MTB, decomposto	14
2.3	Sopra la frontiera: il lavoro fattuale è delegabile	16
2.4	La frontiera è sicura perché il sistema la conosce	16
2.5	Sotto la frontiera: il giudizio resta umano	16
2.6	Conclusione	16

3	Efficienza di contesto: recupero dei fatti al variare del budget	18
3.1	La domanda	18
3.2	Metrica e metodo	18
3.3	Risultati	19
3.4	Interpretazione	20
3.5	Conclusione	20
4	Baseline denso biomedico: encoder o retrieval?	21
4.1	La domanda	21
4.2	Sistemi confrontati	21
4.3	Risultati	22
4.4	Tre conclusioni	23
4.5	Implicazione per la tesi	23
5	Scaling della profondità dei salti	24
5.1	Domanda sperimentale	24
5.2	Disegno: una spina tipizzata, lo stesso gene ad ogni profondità	24
5.3	La covariata onesta: quanti passaggi separati servono	25
5.4	Risultati	25
5.4.1	Recall del fatto terminale	26
5.4.2	Chain-recall / completezza della catena	26
5.5	Conclusioni	27
A	Il test di McNemar: significato e ruolo negli esperimenti	28
A.1	Che cos'è il test di McNemar	28
A.2	Come funziona	28
A.3	Perché è appropriato per questi esperimenti	29
A.4	Come è stato usato nella tesi	29
A.5	Il ruolo nel quadro complessivo	29

Capitolo 1

Un confronto sperimentale: GraphRAG contro RAG testuale

1.1 Che cosa volevo verificare

La domanda di partenza è semplice. Quando un medico interroga la knowledge base oncologica, spesso la risposta non è scritta da nessuna parte in un unico punto: va *costruita* collegando più fatti. Per esempio, da un gene si arriva a una variante, dalla variante a un profilo molecolare, dal profilo a un’evidenza clinica e infine a un farmaco. Ogni collegamento è un “passo” di ragionamento, che qui chiamo *hop*.

L’ipotesi è che un sistema che ragiona sul grafo della conoscenza (**GraphRAG**) risponda meglio di un sistema che cerca testo per somiglianza (**RAG testuale**), e che il suo vantaggio *cresca* man mano che aumentano i passi da collegare. L’intuizione: il RAG testuale deve pescare più frammenti separati e rimetterli insieme dentro uno spazio di contesto limitato, e più frammenti servono, più è facile che ne manchi uno. Il GraphRAG invece segue il percorso nel grafo in modo diretto e raccoglie esattamente i fatti che servono.

1.2 I materiali

1.2.1 La knowledge base

Ho ricostruito il grafo in memoria a partire dai file CSV esportati dalla knowledge base. Per questo esperimento non serviva il database Neo4j: la ricostruzione dai CSV mantiene la stessa integrità dei collegamenti (17 join su 18 si risolvono al 100%).

Il grafo contiene 43.005 nodi di 9 tipi (farmaci, trial clinici, evidenze, pubblicazioni, varianti, profili molecolari, geni, malattie e test diagnostici) e 55.544 collegamenti di 11 tipi diversi. Le fonti sono tutte curate: CIViC per l’evidenza clinica, DGIdb per le interazioni gene–farmaco, ClinicalTrials.gov per i trial e FDA per i test diagnostici companion.

1.2.2 Il testo per il RAG

Per dare al RAG testuale una base di partenza equa, ho trasformato ogni fatto del grafo in un breve paragrafo che si spiega da solo, ottenendo 20.679 passaggi. Un dettaglio importante per la correttezza del confronto: questi passaggi formano un unico grande archivio, non separato per gene. Così il RAG deve davvero *trovare* i fatti giusti per somiglianza, senza ricevere in regalo la struttura del grafo.

1.3 Il banco di prova (benchmark)

Ho generato **169 domande** percorrendo il grafo in modo automatico. Per ognuna conosco la risposta corretta, gli identificatori dei nodi coinvolti, il percorso di supporto e il numero di hop. La risposta di riferimento nasce quindi dalla struttura del grafo, non dal giudizio di una persona o di un altro modello.

La regola chiave nel costruire le domande: le entità intermedie del percorso *non compaiono mai* nel testo della domanda. È questo che obbliga davvero a ragionare a più passi — il sistema deve ricostruire il percorso, non limitarsi a riconoscere parole già presenti nella domanda.

Tabella 1.1: Composizione del benchmark: 7 modelli di domanda, per numero di hop.

Hop	Modello di domanda	N	Percorso di supporto
2	drug_to_gene_cdx	30	Farmaco → Test → Gene
2	gene_to_trialdrug	11	Gene ← Trial → Farmaco
3	variant_to_drug	40	Variante → Profilo → Evidenza → Farmaco
4	gene_to_disease	20	Gene → Variante → Profilo → Evidenza → Malattia
4	gene_to_drug	20	Gene → Variante → Profilo → Evidenza → Farmaco
5	gene_evidence_trial_bridge	28	intersezione di due percorsi
5	gene_to_cdx	20	... → Farmaco → Test

Le domande a 5 hop comprendono il caso più difficile (**gene_evidence_trial_bridge**): chiedono i farmaci che sono *allo stesso tempo* supportati da un’evidenza clinica e testati in un trial per lo stesso gene. Serve incrociare due percorsi distinti, ed è qui che il RAG testuale è più in difficoltà.

1.4 I sistemi a confronto e le regole del gioco

Ho confrontato quattro sistemi, tenendo *uguale per tutti* il modello che legge il contesto e scrive la risposta (gemma3:27b via Ollama Cloud, temperatura 0) e lo *stesso limite di contesto* (900 parole):

1. **GraphRAG** — riconosce le entità nella domanda, traduce la domanda in uno schema di collegamenti da seguire (senza mai vedere la risposta corretta), percorre il grafo e restituisce i percorsi trovati.
2. **RAG denso** — cerca per somiglianza semantica con embedding all-MiniLM-L6-v2.
3. **RAG BM25** — cerca per corrispondenza di parole (metodo lessicale classico).
4. **RAG ibrido** — combina denso e BM25 in parti uguali.

Per rendere il confronto onesto ho tenuto fisse cinque cose: stesso modello lettore, stesso prompt e stessa temperatura; stesso limite di contesto (e il GraphRAG ne usa molto meno del massimo consentito); archivio testuale unico e non pre-suddiviso per gene; risposte di riferimento derivate dal grafo, non da un giudizio soggettivo; metrica di confronto identica per tutti.

1.5 I risultati

1.5.1 Accuratezza complessiva

Sulla media delle 169 domande, il GraphRAG è nettamente davanti a tutti, usando al contempo molto meno contesto (Tabella 1.2).

Tabella 1.2: Accuratezza media sulle 169 domande. “Recall fatti-ponte” misura quanti dei fatti intermedi necessari finiscono davvero nel contesto.

Sistema	F1	Precision	Recall	Exact	Recall ponte	Parole ctx
GraphRAG	0,994	0,994	0,994	0,994	1,000	35,8
RAG BM25	0,671	0,660	0,765	0,704	0,816	889,9
RAG ibrido	0,676	0,677	0,745	0,680	0,803	918,4
RAG denso	0,163	0,176	0,183	0,154	0,266	946,7




Figura 1.1: Accuratezza media per sistema su quattro metriche. Il GraphRAG (barre blu) è primo ovunque; fra i sistemi testuali, BM25 e ibrido sono vicini e ben sopra il denso.

1.5.2 Come cambia la cosa al crescere degli hop

Questo è il risultato centrale. Il RAG lessicale e ibrido reggono fino a 4 hop, ma **crollano a 5 hop** (F1 intorno a 0,30), proprio sulle domande a doppio vincolo. Il GraphRAG resta a 1,00 (Tabella 1.3, Figura 1.2).

Tabella 1.3: F1 medio per numero di hop. Il divario tra GraphRAG e BM25 passa da +0,26 (2 hop) a +0,69 (5 hop): il vantaggio si allarga, come previsto.

Hop	GraphRAG	RAG BM25	RAG ibrido	RAG denso
2	1,000	0,744	0,756	0,498
3	1,000	0,923	0,927	0,050
4	0,975	0,780	0,792	0,095
5	1,000	0,308	0,301	0,028




Figura 1.2: Curva di degrado: F1 medio in funzione del numero di hop, con bande di incertezza al 95%. La linea del GraphRAG resta piatta in alto; le linee testuali scendono ripide a 5 hop.

1.5.3 È un caso? No

Ho verificato la solidità del confronto con il test di McNemar sulle risposte esatte, appaiate domanda per domanda. Il GraphRAG risponde correttamente dove BM25 sbaglia in **50** domande, mentre il contrario accade una sola volta ($p = 4,6 \times 10^{-14}$). Contro l'ibrido il conto è +54/−1 ($p = 3,1 \times 10^{-15}$); contro il denso +142/−0 ($p = 3,6 \times 10^{-43}$). Le differenze sono nettamente significative in tutti i casi.

1.5.4 Perché il RAG fallisce

La spiegazione è nel recupero dei fatti-ponte, cioè i fatti intermedi del percorso. Il GraphRAG li porta nel contesto nel **100%** dei casi a ogni livello di hop. Il RAG testuale parte dall'82% circa (BM25) e scende molto sulle catene lunghe (Figura 1.3): se il fatto intermedio non entra nel contesto, il lettore non ha gli elementi per rispondere. Non è un difetto del modello che legge, ma di ciò che gli viene passato.




Figura 1.3: Recall dei fatti-ponte per numero di hop. Il GraphRAG resta a 1,00; i sistemi testuali crollano a 5 hop — ed è esattamente lì che crolla anche la loro accuratezza.

1.5.5 Meno contesto, non di più

Il GraphRAG raggiunge un'accuratezza quasi perfetta usando in media **35,8 parole** di contesto, contro le circa 890–950 dei sistemi testuali: circa **25 volte** in meno (Figura 1.4). In pratica questo significa risposte più rapide, meno costi e un contesto interamente rintracciabile alle fonti originali.




Figura 1.4: Accuratezza contro quantità di contesto usato (asse orizzontale in scala logaritmica). Il GraphRAG sta in alto a sinistra: massima accuratezza, minimo contesto.

1.6 Il vantaggio non dipende dal modello lettore

Un’obiezione ragionevole è che il divario dipenda dallo specifico modello che legge il contesto. Per escluderlo ho ripetuto l’esperimento cambiando *solo* il lettore — da **gemma3:27b** (Google) a **qwen3-coder-next** (Alibaba, famiglia e addestramento diversi) — e lasciando identici il recupero, il limite di contesto, l’archivio e il metodo di valutazione. Questo ricalca lo studio con secondo modello già previsto nel progetto.

L’esperimento copre l’intero banco di prova: tutte e **169** le domande, da 2 a 5 hop, a cui entrambi i lettori hanno risposto su tutti e quattro i sistemi — copertura *completa, senza esclusioni*. Le undici domande a 5 hop (Q159–Q169) inizialmente rimaste indietro per il limite d’uso dell’account Ollama (errore HTTP 429) sono state completate riutilizzando gli stessi contesti di recupero, verificati identici a quelli di gemma. Il recupero è deterministico e coincide tra i due lettori su tutte le 676 coppie domanda–sistema.

Tabella 1.4: Stesse 169 domande, due lettori diversi. La classifica non cambia.

Sistema	F1 gemma3:27b	F1 qwen3-coder-next	Δ
GraphRAG	0,994	0,991	−0,003
RAG ibrido	0,676	0,698	+0,022
RAG BM25	0,671	0,701	+0,030
RAG denso	0,163	0,164	+0,001




Figura 1.5: Confronto tra due lettori diversi sulle stesse 169 domande. La gerarchia resta invariata: il vantaggio è del metodo di recupero, non del modello che legge.

Cambiando del tutto il lettore, la classifica non si muove *a nessuna profondità di ragionamento*: il GraphRAG resta di fatto perfetto ($\sim 0,99$) da 2 a 5 hop, i sistemi testuali restano circa 30 punti sotto e nello stesso ordine, il denso resta molto indietro. Le piccole oscillazioni ($\pm 0,02$ – $0,03$) sono rumore e semmai vanno leggermente a favore di qwen sui sistemi testuali — il che rafforza la conclusione: il divario è una proprietà del recupero, non del lettore.

1.7 Robustezza al linguaggio: e se la domanda è riformulata?

Un’obiezione naturale è che il benchmark usi domande generate da schemi fissi, con un vocabolario regolare. Un clinico reale scrive in modo vario. Ho quindi generato una **parafrasi**

in linguaggio clinico di tutte le 169 domande (i nomi delle entità restano, cambia il modo di chiedere) e ho rieseguito i sistemi. La divergenza lessicale è forte: la somiglianza mediana (indice di Jaccard sulle parole) tra originale e parafrasi è **0,21**.

Il risultato va raccontato in due tempi, con onestà.

1.7.1 Prima sorpresa: il router a parole chiave è fragile

Nella prima implementazione, il GraphRAG sceglieva quale percorso seguire nel grafo con un router *a parole chiave*: cercava termini come “malattia”, “trial”, “companion” nel testo della domanda. Funziona benissimo sulle domande originali, ma è tarato sul loro vocabolario. Riformulando, quelle parole spariscono e il router sbaglia strada: la rotta **gene_to_disease** veniva preservata in 0 casi su 20, la **gene_evidence_trial_bridge** in 1 su 28. L’accuratezza del GraphRAG con router a parole chiave **crolla da 0,99 a 0,67** sulle parafrasi, con il recall di recupero che scende da 1,00 a 0,68. I sistemi testuali, che non hanno un router, restano quasi stabili (perdono circa 0,04 di F1). Questo va detto: non hanno un router *da rompere*, ma partono da molto più in basso.

1.7.2 La correzione: un router semantico

La causa non è l’entity linking (che resta quasi perfetto: 168 entità agganciate su 169) ma la scorciatoia ingegneristica del router. L’ho sostituito con un **router semantico**: un classificatore che riconosce l’*intento* della domanda fra sette categorie, indipendentemente dalle parole esatte usate. Il router non vede mai la risposta corretta né l’archivio: classifica solo l’intento, quindi il confronto resta equo. Con il router semantico il GraphRAG **risale a F1 0,895** (recall di recupero 0,95), restando davanti a tutti i sistemi testuali a ogni livello di hop e con circa 22 volte meno contesto (41 parole contro circa 900).

Tabella 1.5: Robustezza alla riformulazione. Il router a parole chiave crolla sulle parafrasi; il router semantico recupera gran parte del divario. I sistemi testuali sono stabili ma molto più in basso.

Sistema (condizione)	F1	Exact	Recall rec.	Contesto (par)
GraphRAG (orig., router parole chiave)	0,994	0,994	1,000	36
GraphRAG (parafrasi, router parole chiave)	0,667	0,751	0,679	50
GraphRAG (parafrasi, router semantico)	0,895	0,941	0,947	41
RAG BM25 (orig. → parafrasi)	0,671 → 0,634	—	0,816 → 0,809	~885
RAG ibrido (orig. → parafrasi)	0,676 → 0,626	—	0,803 → 0,788	~905
RAG denso (orig. → parafrasi)	0,163 → 0,193	—	0,266 → 0,285	~935




Figura 1.6: Robustezza alla riformulazione clinica. (a) La riformulazione non ribalta la gerarchia fra i sistemi. (b) Sulle domande riformulate, con router semantico, il GraphRAG resta in vantaggio a ogni numero di hop.

La lettura scientifica è netta: il *paradigma* — il recupero strutturato guidato dal grafo — è robusto alla variazione linguistica. Ciò che era fragile era una scorciatoia di ingegneria (il router a parole chiave). Un GraphRAG fatto come si deve comprende l'intento della domanda, ed è esattamente questo a ripristinare la robustezza.

1.8 Sicurezza clinica: sa dire “non lo so”?

In un tumor board un sistema che *inventa* un test diagnostico o un trial inesistente è pericoloso; uno che si *astiene* quando la risposta non c'è è sicuro. Ho costruito 34 domande-trappola senza risposta valida: 24 a *catena spezzata* (geni realmente presenti nella knowledge base, ma la specifica catena multi-hop non esiste — verificato: il grafo restituisce contesto vuoto) e 10 a *entità inesistente* (nomi di gene plausibili ma assenti). Ho aggiunto 16 domande valide di controllo, per verificare che i sistemi non rifiutino tutto indistintamente.

Su una domanda senza risposta, astenersi (rispondere “NON DETERMINABILE”) è il comportamento corretto; elencare entità è un'allucinazione.

Tabella 1.6: Test di astensione. GraphRAG è l'unico sistema che si astiene sulle trappole senza mai rifiutare una domanda valida.

Sistema	Astensione trappole ↑	Allucinaz. trappole ↓	Entità inventate (se allucina) ↓	Falsa astens. valide ↓
GraphRAG	0,94	0,06	1,5	0,00
RAG BM25	0,91	0,09	10,7	0,06
RAG ibrido	0,79	0,21	6,1	0,12
RAG denso	0,85	0,15	2,6	0,56




Figura 1.7: Sicurezza e astensione. (a) GraphRAG si astiene sulle trappole (barre piene) senza rifiutare le domande valide (barre tratteggiate). (b) Quando allucina, il RAG inventa fino a quasi 11 entità; il GraphRAG parte da contesto vuoto.

Tre cose emergono. Primo, il meccanismo è **architetturale**: il recupero dal grafo è vuoto su tutte le 34 trappole perché il cammino semplicemente non esiste, mentre il RAG recupera comunque 860–970 parole di passaggi superficialmente simili — il carburante dell’allucinazione. Secondo, quando il RAG allucina, allucina molto: BM25 elenca in media **10,7 entità** inventate per trappola, il caso clinicamente più pericoloso. Terzo, l’apparente prudenza del RAG denso è un miraggio: sembra sicuro sulle trappole (0,85) ma si astiene falsamente sul **56%** delle domande valide — non è cautela calibrata, è fallimento di recupero.

1.8.1 Un guardrail fail-safe

I due unici cedimenti del GraphRAG (2 trappole su 34) non vengono dal recupero — vuoto e corretto su tutte — ma dal lettore, che con contesto vuoto ha attinto una volta alla memoria del modello. La correzione è un **guardrail deterministico**: se il recupero dal grafo è vuoto, il sistema risponde “NON DETERMINABILE” senza nemmeno interpellare il lettore. Prima di adottarlo ho verificato che il GraphRAG produce contesto vuoto su tutte le 34 trappole ma su nessuna delle 16 domande valide: la separazione è netta, quindi il guardrail non introduce false astensioni.

Tabella 1.7: Effetto del guardrail “contesto vuoto → astieniti” sul GraphRAG. Sicurezza perfetta senza perdere risposte valide.

Metrica	Senza guardrail	Con guardrail
Astensione su trappole ↑	0,94	1,00
Allucinazione su trappole ↓	0,06	0,00
Entità inventate (media) ↓	1,5	0,0
Falsa astensione su valide ↓	0,00	0,00
Risponde a domande valide ↑	1,00	1,00




Figura 1.8: Il guardrail deterministico. (a) Porta il GraphRAG a sicurezza perfetta sulle trappole. (b) Nel piano sicurezza–competenza, GraphRAG con guardrail coincide con il punto ideale (nessuna falsa astensione, astensione totale sulle trappole).

Questo comportamento *fail-safe* è possibile solo grazie al grafo: “contesto vuoto” è un segnale affidabile di non-rispondibilità perché il recupero strutturato o trova un cammino o non lo trova. Applicare lo stesso guardrail al RAG non servirebbe a nulla: il RAG recupera sempre centinaia di parole, quindi il suo contesto non è mai vuoto e la trappola arriva comunque al lettore. Il RAG **non ha un segnale equivalente**. La raccomandazione per un sistema di supporto decisionale clinico è quindi diretta: recupero strutturato più guardrail deterministico danno un comportamento dimostrabile — o una risposta con supporto tracciabile nel grafo, o una dichiarazione esplicita di non sapere. Nessuna via di mezzo allucinata.

1.9 Limiti, detti con franchezza

- **Domande da modello:** il benchmark copre 7 schemi di percorso. Sono rappresentativi delle domande cliniche reali, ma non coprono tutto il linguaggio naturale libero.
- **L’unico “errore” del GraphRAG** (domanda Q112, 4 hop): il lettore ha risposto “Gemcitabina” (italiano) contro il riferimento “GEMCITABINE” (inglese). È clinicamente corretto, penalizzato solo dal confronto lettera per lettera. In pratica il GraphRAG è perfetto sul benchmark; il valore 0,975 a 4 hop è un artefatto della metrica, non un errore di ragionamento.
- **Il RAG denso è penalizzato dai passaggi brevi:** con paragrafi da poche decine di parole, l’embedding usato rende poco. Il confronto principale va letto contro BM25 e ibrido, che sono baseline testuali più eque.
- **Lo schema di percorso del GraphRAG è specifico:** rispecchia la logica del sistema di produzione, ma andrebbe esteso per domande fuori dallo schema. Non usa mai la risposta corretta, quindi il confronto resta equo.
- **Il router va scelto con cura:** come mostra l’esperimento sulle parafrasi, un router a parole chiave è fragile alla variazione linguistica. Il router semantico usato qui recupera la robustezza, ma introduce una dipendenza da un classificatore d’intento, la cui accuratezza (circa 88% sulle parafrasi) diventa un ulteriore anello da monitorare in produzione.

1.10 Che cosa significa per il Molecular Tumor Board

1. **Affidabilità dove serve:** le decisioni reali del tumor board sono a più passi (dal profilo molecolare del paziente alla terapia con evidenza, al trial arruolabile, al test richiesto). Proprio lì dove il RAG testuale crolla, il GraphRAG resta accurato.
2. **Tracciabilità:** ogni risposta del GraphRAG è un percorso esplicito nel grafo, che il clinico può verificare — requisito essenziale in ambito clinico.
3. **Efficienza:** usare circa 25 volte meno contesto significa meno tempo e meno costi, con un contesto ancorato a fonti curate.
4. **Una metrica-spia:** il recall dei fatti-ponte spiega *perché* il grafo vince, e conviene tenerlo monitorato anche in produzione.

1.11 Riproducibilità

Tutti i materiali sono salvati: il benchmark con risposte di riferimento e percorsi (`benchmark_multihop_qa.csv`), le risposte e i punteggi per ogni domanda e sistema con entrambi i lettori (`results_raw.csv`, `results_raw_qwen.csv`), le metriche aggregate (`metrics_summary.csv`, `metrics_by_hop.csv`), il confronto tra lettori (`reader_generalization_gemma_vs_qwen.csv`) e le cinque figure a 300 dpi. Lettore principale: `gemma3:27b`; lettore di controllo: `qwen3-coder-next`, entrambi via Ollama Cloud. Ambiente: Python 3.12 (`networkx`, `sentence-transformers`, `rank-bm25`, `scikit-learn`).

Per gli esperimenti aggiuntivi sono inclusi: le 169 parafrasi cliniche (`benchmark_multihop_qa_paraphrased.csv`), i risultati con router a parole chiave e con router semantico (`results_paraphrase_keywordrouter.csv`, `results_paraphrase_graphrag_routed.csv`), la sintesi di robustezza (`robustezza_parafrasi_summary.csv`), il set completo di domande-trappola e di controllo (`abstention_trap_questions.csv`, `abstention_control_questions.csv`), i risultati per-domanda del test di astensione (`results_abstention_raw.csv`), le metriche con e senza guardrail (`abstention_summary.csv`, `abstention_summary_guardrail.csv`, `guardrail_before_after.csv`) e le figure 1.6, 1.7 e 1.8. Il codice dei due sistemi e degli esperimenti è nella cartella `scripts/` (`01_sistemi_retrieval.py`, `02_esperimento_robustezza_parafrasi.py`, `03_esperimento_astensione_guardrail.py`).

Capitolo 2

La frontiera dell’automazione nel Molecular Tumor Board

2.1 La domanda

I capitoli precedenti hanno misurato *quanto bene* un sistema GraphRAG risponde a domande di oncologia di precisione rispetto a un RAG testuale. Ma il risultato che conta davvero per la pratica clinica è un altro, e più ambizioso: **quanta parte del lavoro di preparazione di un Molecular Tumor Board (MTB) può essere realisticamente automatizzata, e quale parte resta intrinsecamente nel dominio del giudizio multidisciplinare?**

La tesi che sostengo in questo capitolo è che la risposta non va *ipotizzata*: i quattro esperimenti condotti (accuratezza multi-hop, generalizzabilità tra reader, robustezza alla riformulazione, sicurezza e astensione) la *misurano* già. Messi insieme, tracciano empiricamente una “frontiera dell’automazione” che attraversa il workflow MTB in un punto preciso.

2.2 Il workflow MTB, decomposto

La preparazione di un Molecular Tumor Board non è un’operazione monolitica: è una catena di stadi con nature epistemiche molto diverse. Alcuni stadi sono *recuperi di fatti* — cercare, collegare e verificare informazioni già esistenti in banche dati curate. Altri sono *ponderazioni di giudizio* — pesare evidenze contrastanti, contestualizzare al singolo paziente, assumersi la responsabilità di una raccomandazione. Se si scompone il workflow in questi stadi, i risultati sperimentali si collocano in modo netto su ciascuno di essi (Tabella 2.1, Figura 2.1).

Tabella 2.1: I dieci stadi della preparazione MTB, classificati per grado di automatizzabilità sulla base dei risultati sperimentali. La “frontiera” passa tra lo stadio 5 e lo stadio 6.

#	Stadio della preparazione MTB	Natura
Automatizzabile — validato sperimentalmente		
1	Annotazione varianti (gene, tipo, HGVS/dbSNP)	look-up strutturato
2	Assemblaggio catene variante→gene→farmaco→evidenza→trial	cross-referencing multi-hop
3	Recupero companion diagnostics / approvazioni FDA	look-up relazionale
Parzialmente automatizzabile — assistivo		
4	Pre-screening eleggibilità trial (criteri strutturati)	matching su criteri
5	Armonizzazione livelli di evidenza (CIViC A–E vs OncoKB)	normalizzazione semantica
Intrinsecamente giudizio multidisciplinare		
6	Ponderazione di evidenze deboli o contrastanti	giudizio
7	Integrazione del contesto-paziente (comorbidità, linee, PS, organi)	giudizio clinico
8	Priorità tra alterazioni multiple azionabili	giudizio multidisciplinare
9	Off-label / uso compassionevole, etica, accesso, costi	giudizio + responsabilità
10	Raccomandazione terapeutica finale e accountability	responsabilità legale




Figura 2.1: La frontiera dell’automazione nella preparazione del Molecular Tumor Board. I dieci stadi sono mappati in tre zone; i numeri empirici (F1, bridge-recall) sono agganciati agli stadi che il sistema automatizza. La linea rossa marca il confine tra recupero fattuale e giudizio clinico.

2.3 Sopra la frontiera: il lavoro fattuale è delegabile

Gli stadi 1–3 sono esattamente la parte *tediosa e soggetta a errore* della preparazione: recuperare e incrociare decine di associazioni variante–farmaco–evidenza–trial da fonti eterogenee (CIViC, DGIdb, ClinicalTrials.gov, FDA). È il lavoro che oggi consuma le ore di un analista o di un biologo molecolare.

I risultati mostrano che questo lavoro è dimostrabilmente delegabile. Il GraphRAG risolve le catene di ragionamento con **F1 $\approx$ 0,99 fino a 5 hop**, recuperando il **100% dei fatti-ponte** necessari, e lo fa con circa **25 volte meno contesto** del RAG testuale. Il vantaggio non è un artefatto del particolare modello di lettura: sostituendo completamente il reader (da `gemma3:27b` a `qwen3-coder-next`, famiglie e addestramenti diversi) la gerarchia non si muove a nessuna profondità di hop. Ed è robusto alla riformulazione: le stesse domande espresse in linguaggio clinico naturale non degradano la capacità del grafo di seguire il cammino corretto.

2.4 La frontiera è sicura perché il sistema la conosce

Il punto concettualmente più importante non è l’accuratezza, ma l’*astensione*. Un sistema che automatizza il recupero fattuale in ambito clinico è difendibile solo se sa riconoscere *quando non ha una risposta*. È qui che la struttura del grafo offre una garanzia che il RAG testuale non può dare: quando la catena di fatti richiesta non esiste, il GraphRAG produce un **contesto vuoto in modo deterministico**, e con un guardrail elementare risponde “NON DETERMINABILE” invece di confabulare.

Sul benchmark di sicurezza il GraphRAG raggiunge il **punto ideale**: astensione perfetta (1,00) sulle domande-trappola, zero allucinazioni, e nessuna perdita sui controlli legittimi. In altre parole, il sistema **restituisce l’incertezza al board umano invece di mascherarla**. È proprio questa proprietà a tenerlo dal lato giusto della frontiera: non invade il territorio del giudizio spacciando congetture per fatti.

2.5 Sotto la frontiera: il giudizio resta umano

Gli stadi 6–10 non contengono “fatti da recuperare”: contengono *valutazioni da pesare*. Un’evidenza di livello D su un trial di fase I va bilanciata contro la tossicità attesa nel paziente specifico, le linee di terapia già fallite, l’accesso effettivo al farmaco, il performance status, le comorbidità. Nessuno di questi elementi è nel grafo — e non per un limite implementativo che una versione futura potrebbe colmare, ma perché **sono giudizi contestuali e responsabilità professionali**, non associazioni recuperabili da una banca dati.

Gli stadi 4 e 5 stanno sulla frontiera stessa: il pre-screening di eleggibilità e l’armonizzazione dei livelli di evidenza sono parzialmente automatizzabili come supporto, ma richiedono convenzioni esplicite e restano soggetti a verifica umana — come mostra lo stesso dataset, in cui coesistono scale di evidenza eterogenee (CIViC A–E e OncoKB LEVEL_x) che nessuna regola puramente sintattica può riconciliare senza una decisione di merito.

2.6 Conclusione

L’automazione non sposta il confine tra macchina e clinico *lungo* il workflow MTB; lo rende **esplicito e sicuro**. La preparazione fattuale — assemblaggio e cross-referencing dell’evidenza molecolare — è largamente automatizzabile con affidabilità e, soprattutto, con astensione determi-

nistica sui casi senza risposta. Il giudizio multidisciplinare — ponderazione, contestualizzazione al paziente, priorità, responsabilità — resta intrinsecamente umano.

Il valore di un sistema come questo non è dunque rispondere *di più*, ma sapere *dove smettere di rispondere*: consegnare al Molecular Tumor Board un dossier fattuale verificato, tracciabile fino alle fonti curate, e insieme i suoi limiti dichiarati. È il board, non il sistema, a prendere la decisione terapeutica — ed è esattamente così che deve essere.

Capitolo 3

Efficienza di contesto: recupero dei fatti al variare del budget

3.1 La domanda

Il confronto principale di questa tesi fissa il budget di contesto a 900 parole per tutti i sistemi. A quel budget il GraphRAG utilizza in media circa 36 parole per raggiungere una recall dei fatti-gold pari a 1,00, mentre il RAG testuale ne consuma quasi 900 per fermarsi molto più in basso. Un revisore può legittimamente obiettare: e se questo divario di efficienza fosse soltanto un artefatto del budget scelto? Concedendo al RAG testuale più contesto, il divario si chiuderebbe?

Questo capitolo risponde variando il budget su dodici livelli, da 100 a 2.400 parole, e misurando come degrada il recupero dei fatti a ciascun livello.

3.2 Metrica e metodo

La metrica è la **recall dei fatti-gold effettivamente presenti nel contesto** assemblato: quanta parte delle entità della risposta corretta il sistema riesce a portare sotto gli occhi del lettore. È una quantità *deterministica* che non dipende dal modello lettore, e questo rende lo sweep interamente offline e riproducibile senza alcuna chiave di servizio. Per ogni livello di budget il contesto è assemblato con la stessa procedura del sistema principale (accumulo di passaggi finché il budget è saturo). Il GraphRAG entra come riferimento: il suo contesto è già minimo (circa 36 parole) e per costruzione insensibile al budget.

3.3 Risultati

Tabella 3.1: Recall dei fatti-gold nel contesto assemblato, al variare del budget di contesto. Il GraphRAG è costante a 1,00; BM25 e ibrido crescono lentamente senza mai raggiungere il tetto del grafo; il denso resta molto in basso a ogni budget.

Budget (parole)	GraphRAG	RAG BM25	RAG ibrido	RAG denso
100	1,00	0,54	0,56	0,14
150	1,00	0,58	0,62	0,18
200	1,00	0,62	0,66	0,19
300	1,00	0,71	0,73	0,22
450	1,00	0,77	0,77	0,25
600	1,00	0,80	0,79	0,27
750	1,00	0,82	0,80	0,28
900 (budget tesi)	1,00	0,84	0,83	0,29
1100	1,00	0,86	0,84	0,31
1400	1,00	0,87	0,85	0,34
1800	1,00	0,89	0,88	0,36
2400	1,00	0,93	0,89	0,39

Tabella 3.2: Efficienza di contesto: parole necessarie per raggiungere una data soglia di recall dei fatti-gold. Il denso non raggiunge nessuna delle soglie a nessun budget testato.

Soglia di recall	GraphRAG	RAG BM25	RAG ibrido	RAG denso
$\geq 60\%$	36	144	112	mai
$\geq 70\%$	36	251	226	mai
$\geq 80\%$	36	575	690	mai




Figura 3.1: Efficienza di contesto. (a) Recall dei fatti-gold in funzione delle parole di contesto fornite al lettore (scala logaritmica): il GraphRAG è un singolo punto in alto a sinistra (36 parole, recall 1,00), i RAG testuali risalgono lentamente al crescere del contesto. (b) Parole di contesto necessarie per raggiungere le soglie di recall del 60, 70 e 80%: il denso non le raggiunge mai.

3.4 Interpretazione

Il vantaggio del GraphRAG non dipende dal budget scelto. Anche concedendo al RAG testuale 2.400 parole (circa 2,7 volte il budget della tesi), BM25 arriva a 0,93 e l'ibrido satura intorno a 0,89: nessuno dei due raggiunge il tetto del grafo (1,00 con circa 36 parole). Per la soglia di recall $\geq 80\%$ il GraphRAG è circa **16 volte** più efficiente di BM25 e **19 volte** più efficiente dell'ibrido.

Il RAG denso è limitato dall'encoder, non dal contesto. La sua recall passa da 0,14 a soli 0,39 lungo tutto lo sweep e non raggiunge mai neppure il 60%. Allargare il budget non lo aiuta: il collo di bottiglia è l'encoder generico, non lo spazio di contesto. Questo motiva, come esperimento distinto, la sostituzione con un encoder biomedico dedicato (MedCPT, PubMedBERT, SapBERT).

Per BM25 e ibrido il collo di bottiglia si sdoppia. Già a 900 parole la recall di retrieval (circa 0,83) supera la F1 end-to-end del lettore (circa 0,67 nella run principale): oltre un certo budget il limite non è più il recupero, ma il ragionamento del lettore su un contesto testuale lungo e rumoroso. Aggiungere parole recupera qualche fatto in più, ma introduce anche più distrattori.

3.5 Conclusione

La curva di degrado conferma che l'efficienza di contesto del GraphRAG è una proprietà **strutturale**, non un effetto della parametrizzazione. Il grafo consegna al lettore esattamente i fatti-ponte richiesti in poche decine di parole; il RAG testuale deve inondare il lettore di contesto per avvicinarsi, senza mai raggiungere lo stesso tetto di recall. Il confronto a 900 parole del capitolo principale non favorisce dunque il GraphRAG: semmai lo penalizza, perché gli assegna un budget molto più grande di quello che gli serve.

Capitolo 4

Baseline denso biomedico: encoder o retrieval?

4.1 La domanda

Nel confronto principale il **RAG denso** è la configurazione più debole: la recall dei fatti-gold cresce da 0,14 (con 100 parole di contesto) a soli 0,39 (con 2.400 parole), sempre molto al di sotto del retrieval lessicale e lontanissima dal tetto del GraphRAG (1,00). Prima di concludere che «il retrieval denso non funziona su questa base di conoscenza» occorre isolare la causa. Il divario nasce dall'**encoder** — `all-MiniLM-L6-v2`, addestrato su testo generico, privo di vocabolario biomedico — oppure è un limite **strutturale** del dense retrieval su un corpus fatto di fatti brevi e nomi propri (geni, farmaci, varianti)?

Per rispondere ho sostituito l'encoder generico con encoder di **dominio biomedico**, mantenendo identica la metrica — recall dei fatti-gold nel contesto assemblato, deterministica e offline — e lo stesso sweep di budget dello studio di efficienza di contesto.

4.2 Sistemi confrontati

Il disegno sperimentale separa due contributi spesso confusi: il *pre-training di dominio* (esporre l'encoder a testo biomedico) e il *fine-tuning per il retrieval* (addestrarlo a rendere vicine coppie domanda-passaggio rilevanti). Per questo confronto due encoder biomedici, uno per ciascun contributo:

Sistema	Encoder	Natura
RAG denso (all-MiniLM)	<code>all-MiniLM-L6-v2</code> (384)	generico, retrieval-tuned
RAG denso (PubMedBERT grezzo)	BiomedBERT (768, mean-pool)	solo pre-training di dominio
RAG denso (PubMedBERT-MS)	<code>S-PubMedBert-MS-MARCO</code> (768)	dominio + fine-tuning retrieval

Tabella 4.1: I tre encoder densi a confronto. Il PubMedBERT grezzo (masked-LM con mean-pooling) isola l'effetto del solo dominio; `S-PubMedBert-MS-MARCO` aggiunge il fine-tuning contrastivo su MS-MARCO.

Riferimenti già misurati nello sweep: GraphRAG (1,00 piatto), BM25 e ibrido.

4.3 Risultati

Sistema	100 parole	900 parole	2.400 parole
GraphRAG	1,000	1,000	1,000
RAG BM25	0,541	0,835	0,934
RAG ibrido	0,563	0,825	0,889
RAG denso (PubMedBERT-MS)	0,369	0,639	0,764
RAG denso (all-MiniLM)	0,139	0,293	0,390
RAG denso (PubMedBERT grezzo)	0,017	0,144	0,244

Tabella 4.2: Recall dei fatti-gold nel contesto a tre budget rappresentativi.

Sistema	$\geq 60\%$	$\geq 70\%$	$\geq 80\%$
GraphRAG	36	36	36
RAG BM25	144	251	575
RAG ibrido	112	226	690
RAG denso (PubMedBERT-MS)	669	1.543	mai
RAG denso (all-MiniLM)	mai	mai	mai
RAG denso (PubMedBERT grezzo)	mai	mai	mai

Tabella 4.3: Parole di contesto necessarie per raggiungere una soglia di recall. «mai» indica che la soglia non viene raggiunta neppure a 2.400 parole.




Figura 4.1: (a) Recall dei fatti-gold in funzione delle parole di contesto (scala logaritmica): l'encoder biomedico retrieval-tuned (verde) si stacca nettamente dal generico (grigio), mentre il PubMedBERT grezzo (tratteggiato viola) resta il più basso. (b) Recall a budget 900 parole: il salto da PubMedBERT grezzo (0,144) a PubMedBERT-MS (0,639) misura l'effetto del solo fine-tuning per il retrieval.

4.4 Tre conclusioni

1. L’encoder biomedico recupera gran parte del divario — ma non tutto. Passando da all-MiniLM a S-PubMedBert-MS-MARCO la recall a budget 900 più che raddoppia: 0,293 → 0,639. Il denso biomedico supera le soglie del 60 % (a 669 parole) e del 70 % (a 1.543 parole), che l’encoder generico non raggiunge *mai*. Il divario del RAG denso era dunque in larga parte un **artefatto dell’encoder**, non un limite assoluto del metodo.

2. Non è il vocabolario biomedico a contare, ma il fine-tuning per il retrieval. Il controllo decisivo è il PubMedBERT **grezzo**: solo masked-LM su testo biomedico, mean-pooling, nessun obiettivo contrastivo. La sua recall a budget 900 è 0,144, **peggiore** persino dell’encoder generico (0,293). Il pre-training di dominio da solo produce embedding inadatti al retrieval; è il fine-tuning su coppie domanda-passaggio (MS-MARCO) a spostare la recall da 0,144 a 0,639. Per il retrieval conta **come** l’encoder è stato addestrato, non solo **su quale** dominio.

3. Anche il miglior encoder denso resta sotto il lessicale e lontano dal grafo. A budget 900 il denso biomedico (0,639) non raggiunge né BM25 (0,835) né l’ibrido (0,825); e anche a 2.400 parole (0,764) non tocca il tetto del grafo (1,00), che il GraphRAG raggiunge con 36 parole. Su una base di conoscenza fatta di nomi propri e fatti brevi — dove conta la corrispondenza esatta di un simbolo genico o di un nome di farmaco — il retrieval lessicale e quello strutturato del grafo restano più adatti della similarità densa, per quanto specializzata.

4.5 Implicazione per la tesi

Questo esperimento chiude una possibile obiezione al confronto principale («il RAG denso perde solo perché usa un encoder generico»). La risposta è articolata: un encoder biomedico *retrieval-tuned* recupera buona parte del divario e va adottato come baseline denso corretto; tuttavia neppure quel sistema raggiunge la recall del retrieval lessicale, né la compattezza e la completezza del GraphRAG. Il vantaggio del grafo — recall 1,00 con 36 parole di contesto — non è replicabile aumentando la dimensionalità o la specializzazione dell’encoder denso, perché deriva dal **modo** in cui i fatti sono collegati, non dalla loro rappresentazione vettoriale.

Capitolo 5

Scaling della profondità dei salti

5.1 Domanda sperimentale

Fino a che punto la struttura del grafo continua a proteggere il recupero quando la catena di ragionamento clinico si allunga? Gli esperimenti precedenti hanno lavorato su domande a 2–5 salti. Qui portiamo la profondità fino a **8 salti** e misuriamo due grandezze distinte, entrambe in modo deterministico e offline (router = oracolo, nessun modello linguistico nel ciclo di misura):

1. **Recall del fatto terminale** — il nome dell’entità-obiettivo finale compare nel contesto recuperato?
2. **Chain-recall (completezza della catena)** — quale frazione dei nomi-ponte intermedi compare nel contesto?

La seconda metrica è il cuore di questo esperimento: una risposta a molti salti è utile non solo se contiene il fatto finale, ma se contiene *tutti gli anelli* che lo giustificano.

5.2 Disegno: una spina tipizzata, lo stesso gene ad ogni profondità

Il rischio metodologico in un esperimento di profondità è confondere la profondità con la scelta del sotto-grafo. Lo evitiamo con una **spina tipizzata unica**:

$$\begin{aligned} & Gene \rightarrow Variant \rightarrow MolecularProfile \rightarrow Evidence \rightarrow Drug \rightarrow CompanionDiagnostic \\ & \rightarrow Gene' \rightarrow Variant' \rightarrow MolecularProfile' \end{aligned}$$

Ogni gene-ancora che possiede un **cammino canonico completo** a profondità 8 (91 geni, selezionati fra 1.437; visita in profondità deterministica con successori mescolati dal seme 20240517) viene troncato a profondità crescenti. Poiché **lo stesso gene** genera la domanda ad ogni profondità, la profondità resta l’unica variabile manipolata.

La profondità 3 ha come terminale un nodo Evidence, che nel grafo **non ha attributo name**: non è nominabile in un test testuale, quindi è esclusa. Le profondità usate sono **1, 2, 4, 5, 6, 7, 8**, per un totale di 637 domande (91 ancore $\times$ 7 profondità).

5.3 La covariata onesta: quanti passaggi separati servono

Prima dei risultati documentiamo il meccanismo che spiega *perché* la profondità incide sul recupero testuale. Per ciascun cammino canonico si può contare quanti **passaggi distinti** del corpus servono per testimoniare l'intera catena: un passaggio “testimonia” un salto se il suo testo contiene i nomi di entrambi gli estremi dell'arco.

Finché la catena è corta — fino a circa 4 salti — la mediana del numero di passaggi necessari è **1**: l'intera catena vive dentro un singolo passaggio ricco, perché il corpus è *evidence-centric* e un passaggio raggruppa gene, variante, profilo molecolare, evidenza e farmaco. Questo spiega perché, a profondità basse, anche il RAG testuale riesce a recuperare buona parte dei fatti necessari: gli basta trovare il passaggio giusto e quello contiene tutto.

Da profondità 5 in poi la situazione cambia in modo qualitativo: la catena smette di vivere in un unico passaggio. La mediana dei passaggi necessari sale a **2** (profondità 5), poi a **3** (profondità 7) e a **4** (profondità 8). Il RAG testuale deve quindi **recuperare e unire passaggi separati**, ciascuno dei quali copre solo un segmento della catena. Ed è esattamente a questa transizione che ci aspettiamo — e osserviamo — il crollo del recupero testuale: la probabilità di recuperare *tutti* i segmenti necessari diminuisce moltiplicativamente con il numero di passaggi da assemblare.

5.4 Risultati




Figura 5.1: Scaling della profondità dei salti. (a) Recall del fatto terminale vs profondità. (b) Chain-recall (completezza della catena) vs profondità. GraphRAG (blu) è la linea focale.

5.4.1 Recall del fatto terminale

Profondità	GraphRAG	RAG BM25	RAG ibrido	RAG denso
1	1,000	0,802	0,846	0,275
2	1,000	0,835	0,868	0,143
4	0,989	0,879	0,879	0,198
5	0,967	0,473	0,418	0,165
6	0,989	0,637	0,637	0,231
7	0,582	0,099	0,088	0,044
8	0,451	0,022	0,022	0,000

Tabella 5.1: Recall del fatto terminale per sistema e profondità.

GraphRAG **domina ad ogni profondità**. Il salto 5 (Farmaco → Test diagnostico) è un vero scoglio per il RAG: la recall di BM25 crolla da 0,879 a 0,473 perché il farmaco e il suo test di accompagnamento **non sono più co-menzionati nello stesso passaggio**. GraphRAG, che attraversa l’arco HAS_COMPANION_DIAGNOSTIC esplicitamente, resta a 0,967.

Il calo di GraphRAG a profondità 7–8 è un **confondimento di fan-out documentato, non un guasto**. Il settimo salto è un secondo HAS_VARIANT: il gene raggiunto può ramificare in decine di varianti. Per ABCB1 la profondità 8 genera 162 cammini; sotto il budget di 900 parole solo circa 17 vengono serializzati, quindi lo *specifico* terminale canonico compete con i suoi fratelli e non sempre entra nel contesto. È recupero limitato dal budget su un ventaglio combinatorio — la stessa pressione che la covariata di fan-out anticipa.

5.4.2 Chain-recall / completezza della catena

Profondità	GraphRAG	RAG BM25	RAG ibrido	RAG denso
2	1,000	0,857	0,868	0,242
4	0,956	0,846	0,813	0,033
5	0,930	0,586	0,319	0,147
6	0,937	0,703	0,618	0,135
7	0,767	0,692	0,673	0,182
8	0,707	0,592	0,586	0,119

Tabella 5.2: Chain-recall (frazione dei nomi-ponte presenti nel contesto) per sistema e profondità. La profondità 1 non ha ponti intermedi.

Qui emerge la proprietà strutturale di GraphRAG. Ogni cammino serializzato è **internamente completo per costruzione** — nomina tutti i nodi-ponte lungo la spina — quindi la chain-recall **degrada con grazia** (1,000 → 0,707) invece di crollare. Il RAG denso, che deve coprire ogni salto in modo indipendente, resta **sotto** 0,20 a ogni profondità: la probabilità che un singolo recupero copra *tutti* gli anelli decade moltiplicativamente. BM25 e ibrido tengono meglio del denso ma restano circa 0,12–0,15 sotto GraphRAG per tutta la coda.

Si noti che a profondità 7–8 la chain-recall di GraphRAG (0,767 / 0,707) è **molto più alta** della sua recall terminale (0,582 / 0,451): anche quando il budget espelle lo specifico terminale, gli anelli intermedi della catena restano in gran parte nel contesto. La struttura preserva il *ragionamento* anche dove il ventaglio combinatorio mette sotto pressione la singola risposta finale.

5.5 Conclusioni

1. **La struttura protegge il recupero profondo.** Su terminale e catena, GraphRAG è superiore ad ogni profondità; il divario si allarga proprio dove la catena smette di vivere in un unico passaggio (profondità ≥ 5).
2. **La completezza della catena è la metrica che separa i paradigmi.** GraphRAG degrada con grazia perché ogni cammino è completo per costruzione; il RAG denso collassa perché deve coprire ogni salto in modo indipendente.
3. **Il limite di GraphRAG è il budget, non la connettività.** Il calo terminale a profondità 7–8 è ventaglio combinatorio sotto un budget fisso di 900 parole — un limite di *impaginazione*, non di *raggiungibilità*: la connettività del grafo garantisce che il terminale sia sempre a distanza finita; è la serializzazione a doverlo scegliere fra molti fratelli.

Appendice A

Il test di McNemar: significato e ruolo negli esperimenti

A.1 Che cos'è il test di McNemar

Il test di McNemar è un test statistico non parametrico che serve a confrontare le prestazioni di **due classificatori sullo stesso insieme di dati**. A differenza di un semplice confronto di percentuali, il test tiene conto del fatto che le osservazioni sono *appaiate*: ogni domanda è stata sottoposta a entrambi i sistemi, e ci interessa sapere se le differenze osservate sono sistematiche o frutto del caso.

A.2 Come funziona

Il punto di partenza è una tabella di contingenza 2×2 che classifica ogni domanda in base all'esito dei due sistemi:

	Sistema B corretto	Sistema B sbagliato
Sistema A corretto	a (entrambi corretti)	b (solo A corretto)
Sistema A sbagliato	c (solo B corretto)	d (entrambi sbagliati)

Tabella A.1: Tabella di contingenza per il test di McNemar. Le celle b e c (i casi “discordanti”) sono le uniche informative.

Le celle a e d — le domande su cui i due sistemi concordano — non contribuiscono al test: se entrambi rispondono bene o entrambi sbagliano, non c'è evidenza di una differenza. Tutta l'informazione sta nelle celle **discordanti** b e c : le domande su cui un sistema risponde correttamente e l'altro no.

L'ipotesi nulla è che i due sistemi abbiano la stessa probabilità di rispondere correttamente, il che implica $b = c$ in valore atteso. La statistica del test è:

$$\chi^2_{\text{McNemar}} = \frac{(b - c)^2}{b + c}$$

che segue approssimativamente una distribuzione χ^2 con 1 grado di libertà. Un valore grande indica che i casi discordanti pendono sistematicamente a favore di uno dei due sistemi.

A.3 Perché è appropriato per questi esperimenti

Nel confronto GraphRAG contro RAG testuale, ogni domanda del benchmark è stata sottoposta a tutti i sistemi nelle stesse condizioni. Le risposte sono binarie (corretta / sbagliata) e appaiate per domanda: esattamente la situazione per cui il test di McNemar è progettato.

Alternative come il test t o il test χ^2 di indipendenza sarebbero inappropriate: il primo assume normalità e osservazioni continue; il secondo non tiene conto dell'appaiamento e tratterebbe i risultati come se venissero da campioni indipendenti, perdendo potenza statistica e rischiando conclusioni errate.

A.4 Come è stato usato nella tesi

Nel Capitolo 1, il test di McNemar è stato applicato per verificare che il vantaggio del GraphRAG rispetto a ciascuno dei tre sistemi RAG testuali non fosse un artefatto del campione di domande. I risultati sono netti:

- **GraphRAG vs RAG BM25:** il GraphRAG risponde correttamente dove BM25 sbaglia in $b = 50$ domande; il contrario accade in $c = 1$ sola domanda. $p = 4,6 \times 10^{-14}$.
- **GraphRAG vs RAG ibrido:** $b = 54$, $c = 1$. $p = 3,1 \times 10^{-15}$.
- **GraphRAG vs RAG denso:** $b = 142$, $c = 0$. $p = 3,6 \times 10^{-43}$.

In tutti e tre i casi l'asimmetria è schiacciante e i valori p sono inferiori a qualsiasi soglia convenzionale (0,05, 0,01, 0,001). Questo significa che la superiorità del GraphRAG non è spiegabile dal caso: è una proprietà sistematica del metodo di recupero, non una fluttuazione statistica legata alle specifiche domande del benchmark.

A.5 Il ruolo nel quadro complessivo

Il test di McNemar svolge una funzione precisa nella catena argomentativa della tesi: trasforma un'osservazione descrittiva ("il GraphRAG ha un F1 più alto") in un'**affermazione statisticamente fondata** ("il divario è sistematico e non attribuibile al caso"). Senza questo passaggio, un critico potrebbe obiettare che le 169 domande del benchmark siano un campione sfortunato; con il test, questa obiezione è quantitativamente esclusa.