

Capitolo 1

Efficienza di contesto: recupero dei fatti al variare del budget

1.1 La domanda

Il confronto principale di questa tesi fissa il budget di contesto a 900 parole per tutti i sistemi. A quel budget il GraphRAG utilizza in media circa 36 parole per raggiungere una recall dei fatti-gold pari a 1,00, mentre il RAG testuale ne consuma quasi 900 per fermarsi molto più in basso. Un revisore può legittimamente obiettare: e se questo divario di efficienza fosse soltanto un artefatto del budget scelto? Concedendo al RAG testuale più contesto, il divario si chiuderebbe?

Questo capitolo risponde variando il budget su dodici livelli, da 100 a 2.400 parole, e misurando come degrada il recupero dei fatti a ciascun livello.

1.2 Metrica e metodo

La metrica è la **recall dei fatti-gold effettivamente presenti nel contesto** assemblato: quanta parte delle entità della risposta corretta il sistema riesce a portare sotto gli occhi del lettore. È una quantità *deterministica* che non dipende dal modello lettore, e questo rende lo sweep interamente offline e riproducibile senza alcuna chiave di servizio. Per ogni livello di budget il contesto è assemblato con la stessa procedura del sistema principale (accumulo di passaggi finché il budget è saturo). Il GraphRAG entra come riferimento: il suo contesto è già minimo (circa 36 parole) e per costruzione insensibile al budget.

1.3 Risultati

Tabella 1.1: Recall dei fatti-gold nel contesto assemblato, al variare del budget di contesto. Il GraphRAG è costante a 1,00; BM25 e ibrido crescono lentamente senza mai raggiungere il tetto del grafo; il denso resta molto in basso a ogni budget.

Budget (parole)	GraphRAG	RAG BM25	RAG ibrido	RAG denso
100	1,00	0,54	0,56	0,14
150	1,00	0,58	0,62	0,18
200	1,00	0,62	0,66	0,19
300	1,00	0,71	0,73	0,22
450	1,00	0,77	0,77	0,25
600	1,00	0,80	0,79	0,27
750	1,00	0,82	0,80	0,28
900 (budget tesi)	1,00	0,84	0,83	0,29
1100	1,00	0,86	0,84	0,31
1400	1,00	0,87	0,85	0,34
1800	1,00	0,89	0,88	0,36
2400	1,00	0,93	0,89	0,39

Tabella 1.2: Efficienza di contesto: parole necessarie per raggiungere una data soglia di recall dei fatti-gold. Il denso non raggiunge nessuna delle soglie a nessun budget testato.

Soglia di recall	GraphRAG	RAG BM25	RAG ibrido	RAG denso
$\geq 60\%$	36	144	112	mai
$\geq 70\%$	36	251	226	mai
$\geq 80\%$	36	575	690	mai




Figura 1.1: Efficienza di contesto. (a) Recall dei fatti-gold in funzione delle parole di contesto fornite al lettore (scala logaritmica): il GraphRAG è un singolo punto in alto a sinistra (36 parole, recall 1,00), i RAG testuali risalgono lentamente al crescere del contesto. (b) Parole di contesto necessarie per raggiungere le soglie di recall del 60, 70 e 80%: il denso non le raggiunge mai.

1.4 Interpretazione

Il vantaggio del GraphRAG non dipende dal budget scelto. Anche concedendo al RAG testuale 2.400 parole (circa 2,7 volte il budget della tesi), BM25 arriva a 0,93 e l'ibrido satura intorno a 0,89: nessuno dei due raggiunge il tetto del grafo (1,00 con circa 36 parole). Per la soglia di recall $\geq 80\%$ il GraphRAG è circa **16 volte** più efficiente di BM25 e **19 volte** più efficiente dell'ibrido.

Il RAG denso è limitato dall'encoder, non dal contesto. La sua recall passa da 0,14 a soli 0,39 lungo tutto lo sweep e non raggiunge mai neppure il 60%. Allargare il budget non lo aiuta: il collo di bottiglia è l'encoder generico, non lo spazio di contesto. Questo motivava, come esperimento distinto, la sostituzione con un encoder biomedico dedicato (MedCPT, PubMedBERT, SapBERT).

Per BM25 e ibrido il collo di bottiglia si sdoppia. Già a 900 parole la recall di retrieval (circa 0,83) supera la F1 end-to-end del lettore (circa 0,67 nella run principale): oltre un certo budget il limite non è più il recupero, ma il ragionamento del lettore su un contesto testuale lungo e rumoroso. Aggiungere parole recupera qualche fatto in più, ma introduce anche più distrattori.

1.5 Conclusione

La curva di degrado conferma che l'efficienza di contesto del GraphRAG è una proprietà **strutturale**, non un effetto della parametrizzazione. Il grafo consegna al lettore esattamente i fatti-ponte richiesti in poche decine di parole; il RAG testuale deve inondare il lettore di contesto per avvicinarsi, senza mai raggiungere lo stesso tetto di recall. Il confronto a 900 parole del capitolo principale non favorisce dunque il GraphRAG: semmai lo penalizza, perché gli assegna un budget molto più grande di quello che gli serve.