

Scaling della profondità dei salti

Domanda sperimentale

Fino a che punto la struttura del grafo continua a proteggere il recupero quando la catena di ragionamento clinico si allunga? Gli esperimenti precedenti hanno lavorato su domande a 2–5 salti. Qui portiamo la profondità fino a **8 salti** e misuriamo due grandezze distinte, entrambe in modo deterministico e offline (router = oracolo, nessun modello linguistico nel ciclo di misura):

1. **Recall del fatto terminale** — il nome dell’entità-obiettivo finale compare nel contesto recuperato?
2. **Chain-recall (completezza della catena)** — quale frazione dei nomi-ponte intermedi compare nel contesto?

La seconda metrica è il cuore di questo esperimento: una risposta a molti salti è utile non solo se contiene il fatto finale, ma se contiene *tutti gli anelli* che lo giustificano.

Disegno: una spina tipizzata, lo stesso gene ad ogni profondità

Il rischio metodologico in un esperimento di profondità è confondere la profondità con la scelta del sotto-grafo. Lo evitiamo con una **spina tipizzata unica**:

$$\begin{aligned} & Gene \rightarrow Variant \rightarrow MolecularProfile \rightarrow Evidence \rightarrow Drug \rightarrow CompanionDiagnostic \\ & \rightarrow Gene' \rightarrow Variant' \rightarrow MolecularProfile' \end{aligned}$$

Ogni gene-ancora che possiede un **cammino canonico completo** a profondità 8 (91 geni, selezionati fra 1.437; visita in profondità deterministica con successori mescolati dal seme 20240517) viene troncato a profondità crescenti. Poiché **lo stesso gene** genera la domanda ad ogni profondità, la profondità resta l’unica variabile manipolata.

La profondità 3 ha come terminale un nodo Evidence, che nel grafo **non ha attributo name**: non è nominabile in un test testuale, quindi è esclusa. Le profondità usate sono **1, 2, 4, 5, 6, 7, 8**, per un totale di 637 domande (91 ancore $\times$ 7 profondità).

La covariata onesta: quanti passaggi separati servono

Prima dei risultati documentiamo il meccanismo. La Figura 1 conta, per ciascun cammino canonico, quanti **passaggi distinti** del corpus servono per testimoniare l’intera catena (un passaggio testimonia un salto se il suo testo contiene i nomi di entrambi gli estremi). Fino alla profondità 4 la mediana è **1**: l’intera catena vive dentro un solo passaggio ricco, perché il corpus è *evidence-centric* e un passaggio raggruppa gene, variante, profilo, evidenza e farmaco. Da profondità 5 la mediana sale a 2, poi a 3 (profondità 7) e a 4 (profondità 8): il RAG deve **recuperare e unire passaggi separati**, ed è lì che ci aspettiamo il crollo del recupero testuale.




Figura 1: Passaggi distinti del corpus necessari a testimoniare l'intera catena, in funzione della profondità. Fino a 4 salti basta un passaggio; da 5 in poi il recupero testuale deve unire fonti separate.

Risultati




Figura 2: Scaling della profondità dei salti. (a) Recall del fatto terminale vs profondità. (b) Chain-recall (completezza della catena) vs profondità. GraphRAG (blu) è la linea focale.

Recall del fatto terminale

Profondità	GraphRAG	RAG BM25	RAG ibrido	RAG denso
1	1,000	0,802	0,846	0,275
2	1,000	0,835	0,868	0,143
4	0,989	0,879	0,879	0,198
5	0,967	0,473	0,418	0,165
6	0,989	0,637	0,637	0,231
7	0,582	0,099	0,088	0,044
8	0,451	0,022	0,022	0,000

Tabella 1: Recall del fatto terminale per sistema e profondità.

GraphRAG **domina ad ogni profondità**. Il salto 5 (Farmaco $\rightarrow$ Test diagnostico) è un vero scoglio per il RAG: la recall di BM25 crolla da 0,879 a 0,473 perché il farmaco e il suo test di accompagnamento **non sono più co-menzionati nello stesso passaggio**. GraphRAG, che attraversa l’arco HAS_COMPANION_DIAGNOSTIC esplicitamente, resta a 0,967.

Il calo di GraphRAG a profondità 7–8 è un **confondimento di fan-out documentato, non un guasto**. Il settimo salto è un secondo HAS_VARIANT: il gene raggiunto può ramificare in decine di varianti. Per ABCB1 la profondità 8 genera 162 cammini; sotto il budget di 900 parole solo circa 17 vengono serializzati, quindi lo *specifico* terminale canonico compete con i suoi fratelli e non sempre entra nel contesto. È recupero limitato dal budget su un ventaglio combinatorio — la stessa pressione che la covariata di fan-out anticipa.

Chain-recall / completezza della catena

Profondità	GraphRAG	RAG BM25	RAG ibrido	RAG denso
2	1,000	0,857	0,868	0,242
4	0,956	0,846	0,813	0,033
5	0,930	0,586	0,319	0,147
6	0,937	0,703	0,618	0,135
7	0,767	0,692	0,673	0,182
8	0,707	0,592	0,586	0,119

Tabella 2: Chain-recall (frazione dei nomi-ponte presenti nel contesto) per sistema e profondità. La profondità 1 non ha ponti intermedi.

Qui emerge la proprietà strutturale di GraphRAG. Ogni cammino serializzato è **internamente completo per costruzione** — nomina tutti i nodi-ponte lungo la spina — quindi la chain-recall **degrada con grazia** (1,000 $\rightarrow$ 0,707) invece di crollare. Il RAG denso, che deve coprire ogni salto in modo indipendente, resta **sotto** 0,20 a ogni profondità: la probabilità che un singolo recupero copra *tutti* gli anelli decade moltiplicativamente. BM25 e ibrido tengono meglio del denso ma restano circa 0,12–0,15 sotto GraphRAG per tutta la coda.

Si noti che a profondità 7–8 la chain-recall di GraphRAG (0,767 / 0,707) è **molto più alta** della sua recall terminale (0,582 / 0,451): anche quando il budget espelle lo specifico terminale, gli anelli intermedi della catena restano in gran parte nel contesto. La struttura preserva il *ragionamento* anche dove il ventaglio combinatorio mette sotto pressione la singola risposta finale.

Conclusioni

1. **La struttura protegge il recupero profondo.** Su terminale e catena, GraphRAG è superiore ad ogni profondità; il divario si allarga proprio dove la catena smette di vivere in un unico passaggio (profondità ≥ 5).
2. **La completezza della catena è la metrica che separa i paradigmi.** GraphRAG degrada con grazia perché ogni cammino è completo per costruzione; il RAG denso collassa perché deve coprire ogni salto in modo indipendente.
3. **Il limite di GraphRAG è il budget, non la connettività.** Il calo terminale a profondità 7–8 è ventaglio combinatorio sotto un budget fisso di 900 parole — un limite di *impaginazione*, non di *raggiungibilità*: la connettività del grafo garantisce che il terminale sia sempre a distanza finita; è la serializzazione a doverlo scegliere fra molti fratelli.